Planejamento e avaliação de modelos de análise fatorial confirmatória

Um tutorial reprodutível com R e Quarto

Pablo Rogers and Sérgio Murilo Georgeto

23 de outubro de 2026

Resumo

Este artigo-tutorial articula orientações para a Análise Fatorial Confirmatória (AFC) a um projeto executável e reprodutível, dirigido a pesquisadores de ciências sociais aplicadas. Seus objetivos são sistematizar decisões analíticas fundamentadas na literatura, demonstrar sua implementação em uma aplicação empírica e disponibilizar os materiais que permitem examinar, executar e adaptar o percurso apresentado. A aplicação utiliza a WHOQOL-Bref e desenvolve a seleção do modelo de medida, a análise de poder, o pré-processamento, a estimação, a avaliação do ajuste e as comparações e modificações dos modelos, com tratamento contínuo dos itens e estimação robusta. A proposta didática conecta cada decisão aos procedimentos que produzem as tabelas, figuras e estatísticas do artigo. No HTML, blocos expansíveis explicam a finalidade, a preparação, o procedimento e a execução de cada análise; os códigos incorporam comentários por operação e links para a documentação das funções. O PDF preserva a apresentação contínua do artigo científico. Dados, funções reutilizáveis, resultados e documentos-fonte são organizados segundo o ARTE (Article Reproducibility Template & Environment), articulando a implementação em R à redação em Quarto. O conjunto oferece um percurso para estudar as decisões de uma AFC, reproduzir sua aplicação e reutilizar a organização do projeto na elaboração de outros artigos-tutoriais.

Palavras-chave: Análise Fatorial Confirmatória, Modelagem de Equações Estruturais, Validade da Estrutura Interna, Ciência Aberta, Reprodutibilidade, Quarto, *lavaan*.

1 Introdução

A Análise Fatorial Confirmatória (AFC) é uma das principais ferramentas para se coletar evidências de validade de um instrumento de medida baseada na estrutura interna (Bandalos, 2018; Hughes, 2018; Sireci & Sukin, 2013). A validade é sem dúvida a qualidade mais importante de um modelo de medida (Furr, 2021), pois está relacionada com a questão de medição fundamental: o que os instrumentos de medida estão realmente medindo (Bandalos, 2018). Inclusive, esse aspecto se entrelaça com o próprio conceito clássico de validade: grau em que um teste mede o que ele pretende medir (Bandalos, 2018; Furr, 2021; Sireci & Sukin, 2013; Urbina, 2014); condizente com o modelo tripartite e ainda utilizado por muitos pesquisadores (Widodo, 2018).

A visão tripartite de validade é uma forma de conceber a validade de um teste ou instrumento de medida baseada em três tipos de evidência: conteúdo, critério e construto (Bandalos, 2018). A validade de conteúdo se refere à adequação e representatividade dos itens do teste em relação ao domínio ou objetivo que se pretende medir (Cohen et al., 2022). A validade de critério se refere à relação entre os escores do teste e algum critério externo relevante, como o desempenho em outra medida ou em alguma situação futura (Cohen et al., 2022). A validade de construto se refere à capacidade do teste de mensurar o construto teórico que se propõe a medir, considerando as hipóteses e evidências empíricas sobre esse construto (Cohen et al., 2022).

A visão tripartite de validade foi proposta no "*Standards for Educational and Psychological Testing*" da *American Psychological Association* (APA) em 1966, considerada a maior autoridade sobre padrões de medição nas ciências sociais (Bandalos, 2018), e foi amplamente aceita por décadas. No entanto, essa visão veio recebendo severas críticas por ser limitada, fragmentada e confusa (Sireci & Sukin, 2013) e já não mais prevalece: vários tipos de validade dessa visão tradicional foram substituídos por uma nova visão (Widodo, 2018).

O lançamento dos *standards* de 1999 (AERA et al., 1999), seguidos pelos *standards* de 2014 (AERA et al., 2014), marcou uma mudança substancial no conceito de validade dos testes, que passou a ser associado à interpretação e uso dos escores dos testes (Furr, 2021). Com a nova estrutura, a validação passou a exigir várias evidências teóricas e empíricas. Atualmente, a visão prevalecente é da validade como um conceito unitário (validade de construto) e a existência de várias fontes de evidência que podem ser usadas para avaliar possíveis interpretações de escores de testes para fins específicos (Furr, 2021; Urbina, 2014).

Assim, de acordo com as principais autoridades em avaliação psicológica, validade refere-se ao grau que as evidências e a teoria apoiam a interpretação das pontuações dos testes para o propósito que foi concebido (AERA et al., 2014). Validade é um julgamento avaliativo integrado do grau em que as evidências empíricas e os fundamentos teóricos apoiam a adequação e apropriação das inferências e ações baseadas em pontuações de testes ou outros modos de avaliação (Bandalos, 2018; Furr, 2021; Urbina, 2014).

De acordo com os *standards* da APA (AERA et al., 2014), existem cinco fontes de evidências de validade para testes e medidas: baseadas no conteúdo, no processo de resposta, na relação com variáveis externas, nas consequências do uso do teste e na estrutura interna. A primeira tem a ver com o grau em que o conteúdo incluído em um teste fornece uma representação adequada do domínio a ser medido e somente o domínio mensurado (Furr, 2021). A segunda se refere ao ajuste entre o construto e a natureza detalhada do desempenho ou resposta dos examinados (Sireci & Sukin, 2013). A validade baseada na relação com variáveis externas se refere à correlação do teste com outros testes ou construtos que se espera que estejam relacionados ou não com o construto medido (Furr, 2021). A validade baseada nas consequências do uso do teste se refere aos efeitos positivos ou negativos que o uso do teste pode ter para os indivíduos ou grupos avaliados (Bandalos, 2018).

As evidências com base na estrutura interna estão relacionadas com o grau em que as relações entre os itens do teste e seus componentes estão em conformidade com o construto no qual as interpretações dos escores do instrumento de medida são baseadas (AERA et al., 2014; Rios & Wells, 2014). A evidência de validade baseada na estrutura interna pode vir de muitas fontes diferentes (Rios & Wells, 2014), incluindo a análise da

(a) confiabilidade, (b) dimensionalidade e (c) invariância de medida.

A confiabilidade se refere à precisão dos escores e, na teoria clássica dos testes, é definida como a proporção da variância do escore verdadeiro em relação à variância total observada. Uma de suas formas de avaliação é a consistência interna dos itens (Rios & Wells, 2014). Na avaliação da dimensionalidade se está interessado, principalmente, em determinar se as inter-relações entre os itens suportam as inferências que serão produzidas pelo escore do modelo de medida proposto (Rios & Wells, 2014). Para análise da invariância torna-se útil fornecer evidências de que as características do item são comparáveis entre grupos conhecidos, como sexo ou raça.

Através da AFC podemos atacar essas três diferentes fontes para obter evidências da validade da estrutura interna (Bandalos, 2018; Flora & Flake, 2017; Hughes, 2018; Reeves & Marbach-Ad, 2016; Rios & Wells, 2014). Na maioria das situações em ciências sociais aplicadas o pesquisador tem uma estrutura dimensional teórica em mente (Sireci & Sukin, 2013), e o emprego da AFC torna-se recomendado para comparar a estrutura do modelo de medida hipotético ao observado (Rios & Wells, 2014).

A AFC é uma das principais ferramentas dentro do arcabouço da modelagem de equações estruturais (*Structural Equation Modeling* — SEM) baseada em covariâncias (CB-SEM) (Brown, 2023; Harrington, 2009; Jackson et al., 2009; Kline, 2023; Nye, 2022). A SEM é uma das ferramentas estatísticas mais utilizadas nas ciências sociais aplicadas (Hoyle, 2023; Kline, 2023). Ela é uma generalização da regressão múltipla e análise fatorial (Hoyle, 2023) e permite que os componentes dessas técnicas sejam integrados analiticamente. A SEM busca resolver problemas de pesquisa que envolvam mais de uma relação entre variáveis e que podem conter erros de mensuração (Hoyle, 2023), condizente com a necessidade para validações de modelos de medida.

As aplicações da AFC envolvem escolhas metodológicas que dependem da estrutura dos dados, do formato de resposta dos itens e dos objetivos do estudo (Crede & Harms, 2019; Flake et al., 2017; Flake & Fried, 2020; Jackson et al., 2009; Nye, 2022; Rogers, 2024). Essas escolhas também afetam a viabilidade da análise: a complexidade do modelo, a quantidade e a distribuição das categorias de resposta e o tamanho amostral podem influenciar a precisão das estimativas e o desempenho dos procedimentos de estimação (Rhemtulla et al., 2012). Por isso, considerar as implicações analíticas dos instrumentos ainda no planejamento da pesquisa pode evitar dificuldades nas etapas subsequentes.

Nesse sentido, surge o seguinte questionamento: **quais escolhas metodológicas podem tornar a aplicação da AFC mais viável e flexível para obter evidências de validade baseadas na estrutura interna?** Com esse questionamento não estamos de forma alguma sugerindo que se paute os objetivos da pesquisa a partir dos métodos quantitativos empregados. Objetivos da pesquisa são o norte da investigação científica, pois definem o que se quer descobrir e o que se considera relevante. O método quantitativo é um meio para atingir esses objetivos, mas não é o fim em si mesmo. O método quantitativo é apenas uma das muitas ferramentas disponíveis para os cientistas, e o objetivo da pesquisa é o que deve orientar a escolha do método (Pilcher & Cortazzi, 2023).

Na Psicometria, diversas questões metodológicas admitem mais de uma abordagem defensável. Nesses casos, a escolha deve considerar os objetivos da pesquisa e as consequências da modelagem para a interpretação dos resultados. Nesse artigo, adotamos uma recomendação prática: entre instrumentos adequados ao construto e à população

de interesse, privilegiar aqueles cujos itens possam ser tratados como contínuos. Essa decisão deve ser planejada e justificada, pois oferece acesso às possibilidades analíticas da máxima verossimilhança (ML) sem exigir que o formato ordinal das respostas seja considerado, por si só, um impedimento (Rhemtulla et al., 2012; Robitzsch, 2020, 2022).

Para esse propósito, recomendamos instrumentos com itens de cinco ou mais categorias de resposta, preferencialmente sete, quando houver alternativas apropriadas e com evidências de validade para o uso pretendido. Estudos de simulação em AFC sustentam o emprego de ML robusta com cinco a sete categorias em diversas condições, com resultados particularmente favoráveis quando os limiares das categorias são aproximadamente simétricos (Rhemtulla et al., 2012).

O tratamento contínuo permite utilizar a ML e suas correções robustas, além de articular a estimação a procedimentos de avaliação e comparação de modelos e ao tratamento de dados ausentes (Rhemtulla et al., 2012; Robitzsch, 2020). A modelagem ordinal, por sua vez, também envolve pressupostos: a abordagem usual baseada em correlações policóricas pressupõe respostas contínuas subjacentes com distribuição normal. Portanto, não se trata de escolher entre uma abordagem com pressupostos e outra livre deles, mas de justificar qual representação é adequada aos objetivos da pesquisa (Robitzsch, 2020, 2022).

Essas vantagens tornam o tratamento contínuo uma escolha prática para o artigo. Na presença de dados ausentes, por exemplo, a máxima verossimilhança com informação completa (*Full Information Maximum Likelihood* — FIML) permite incorporá-los à estimação, observadas as condições relativas ao modelo e ao mecanismo de ausência. A literatura também identifica cenários em que ML robusto apresenta desempenho favorável em amostras menores (Rhemtulla et al., 2012).

O presente artigo-tutorial tem três objetivos: sistematizar orientações para decisões em AFC, demonstrar sua implementação em uma aplicação empírica e disponibilizar um projeto executável e reprodutível que articule dados, análises e redação dos resultados. O percurso abrange a seleção do modelo de medida, a análise de poder (AP), o pré-processamento, a estimação, a avaliação do ajuste e as comparações e modificações dos modelos. As decisões são discutidas sob as perspectivas do que fazer (Flake et al., 2017; Nye, 2022; Rogers, 2024), do que evitar (Crede & Harms, 2019; Rogers, 2024) e do que reportar (Flake & Fried, 2020; Jackson et al., 2009; Rogers, 2024).

A aplicação utiliza a WHOQOL-Bref e retoma a base empírica empregada por Rogers (2024) e Rogers (2022), explicitando o processamento desde os registros brutos. A implementação em R utiliza o pacote lavaan (Rosseel, 2023) e funções reutilizáveis para organizar operações recorrentes. As tabelas, figuras e estatísticas são produzidas pelo código associado ao manuscrito em Quarto, permitindo acompanhar como as decisões analíticas se traduzem nos resultados apresentados.

O público considerado reúne pesquisadores com conhecimentos básicos de estatística e de AFC no contexto da CB-SEM, com diferentes níveis de familiaridade com programação. Para esse público, o tutorial apresenta as justificativas das decisões ao longo da análise e explica os procedimentos junto às saídas correspondentes. Essa organização busca apoiar a compreensão do percurso e sua execução, oferecendo também aos leitores mais experientes acesso aos materiais para examinar e adaptar a aplicação.

Artigos-tutoriais têm como finalidade apresentar técnicas e aplicações a leitores que não são especialistas no campo (Martins, 2021; Mendes-Da-Silva, 2023). Nesta proposta, a

contribuição didática se desenvolve em três frentes: compreender as decisões de uma AFC, reproduzir a aplicação apresentada e reutilizar a organização do projeto para produzir outros tutoriais. Protocolos explícitos, dados e códigos acessíveis permitem examinar as escolhas realizadas e oferecem materiais para o ensino de métodos quantitativos, em consonância com as práticas de Ciência Aberta (Gilroy & Kaplan, 2019; Kathawalla et al., 2021; Klein et al., 2018). A organização e a documentação desses materiais são orientadas pelos princípios FAIR (Findable, Accessible, Interoperable, and Reusable) (Wilkinson et al., 2016).

A adoção da Ciência Aberta envolve incorporar práticas de documentação, compartilhamento e formação à rotina de pesquisa (Limongi & Rogers, 2025a). Sua articulação em um fluxo de trabalho requer organizar os materiais, registrar as alterações e conectar as análises à redação dos resultados (Limongi & Rogers, 2025b). Para operacionalizar essa articulação, adotamos o ARTE (Article Reproducibility Template & Environment), que integra a organização do projeto, o controle de versões, a gestão de dependências computacionais e a elaboração de documentos dinâmicos (Rogers & Limongi, 2025).

O ARTE propõe uma adoção gradual dessas práticas, desde a organização e o compartilhamento dos materiais até o controle do ambiente computacional por meio de contêineres, conforme as necessidades do projeto e a familiaridade do pesquisador com as ferramentas (Rogers & Limongi, 2025). No tutorial, essa estrutura conecta os dados de entrada aos procedimentos de preparação e análise, aos resultados exportados e ao texto do artigo. Os materiais disponibilizados permitem acompanhar esse percurso e adaptar sua organização a outras aplicações de AFC.

O artigo é apresentado em dois formatos complementares. O PDF preserva a narrativa científica contínua, com as justificativas metodológicas, os resultados e sua interpretação. O HTML acrescenta uma camada didática: abaixo das tabelas e figuras, blocos expansíveis organizam a finalidade, a preparação, o procedimento e a execução das análises. O texto desses blocos explica como as operações produzem cada saída; os códigos apresentam comentários curtos por operação e links para a documentação das funções. As funções próprias são documentadas nos scripts do projeto. Essa distribuição permite aprofundar a leitura da implementação conforme o interesse e a familiaridade do leitor.

Além desta introdução, o artigo compreende uma fundamentação, seis etapas aplicadas e uma conclusão. A Seção 2 reúne as recomendações que orientam as decisões da aplicação. A Seção 3 apresenta o instrumento e as especificações dos modelos; a Seção 4 examina o planejamento amostral por AP; e a Seção 5 documenta a obtenção da amostra analítica e a descrição dos indicadores. A estimação e a verificação das soluções são desenvolvidas na Seção 6. A Seção 7 reúne evidências de ajuste global, confiabilidade e diagnóstico local, que informam as comparações e modificações da Seção 8. A Seção 9 encerra o artigo. Essa organização segue a proposta de artigos-tutoriais de Martins (2021) e vincula as recomendações metodológicas aos procedimentos e materiais que permitem reproduzir a aplicação.

2 Fundamentação das decisões analíticas

O presente tutorial retoma o contexto de aplicações discutido por Rogers (2024): modelos de fator comum, com estrutura multifatorial definida e propriedades psicométricas previamente investigadas, frequentemente empregados como etapa de uma pesquisa mais

ampla. A diferença está no caminho analítico aqui recomendado: planejar a escolha de instrumentos cujos itens permitam o tratamento contínuo, utilizando ML robusto como estratégia de estimação. A fundamentação dessa escolha exige distinguir o formato de resposta, o objeto da análise e os pressupostos do modelo.

Itens individuais e escores agregados de uma escala não são intercambiáveis nessa discussão. A possibilidade de analisar uma soma ou média de itens como contínua não basta para justificar o mesmo tratamento de cada indicador em uma AFC. Harpe (2015) faz essa distinção e recomenda que itens individuais com formatos numéricos de pelo menos cinco categorias podem, em geral, ser tratados como contínuos. Norman (2010) complementa essa perspectiva ao mostrar que a avaliação de procedimentos paramétricos deve considerar sua robustez, em vez de rejeitá-los automaticamente pela classificação ordinal dos dados. Essas contribuições apoiam a discussão geral; a justificativa específica para a AFC vem dos estudos sobre seus modelos e estimadores.

Nessa direção, Rhemtulla et al. (2012) encontrou desempenho aceitável de ML robusto com cinco a sete categorias em diversas condições, embora a assimetria dos limiares e a magnitude das cargas fatoriais influenciassem os resultados. Com sete categorias e limiares aproximadamente simétricos, a abordagem contínua frequentemente apresentou desempenho tão bom quanto ou melhor que a alternativa categórica estudada. Esses resultados oferecem suporte à nossa preferência prática, sem estabelecer cinco categorias como um limiar que garanta bom desempenho em qualquer aplicação.

Por outra perspectiva, Robitzsch (2020) e Robitzsch (2022) argumentam que a escolha entre modelar as relações entre os escores observados e modelar respostas contínuas subjacentes envolve diferentes definições dos parâmetros de interesse. A modelagem ordinal não é universalmente superior apenas porque os itens apresentam categorias ordenadas. Assim, nossa recomendação combina a possibilidade de defender o modelo contínuo com evidências de desempenho e vantagens operacionais. Recomendamos esse caminho desde o planejamento, mantendo a adequação do instrumento ao objetivo da pesquisa como critério prioritário.

As seções seguintes verbalizam analiticamente alguns tópicos discorridos na literatura (Crede & Harms, 2019; Flake et al., 2017; Flake & Fried, 2020; Jackson et al., 2009; Nye, 2022; Rogers, 2024), que foram apenas sintetizado por Rogers (2024) no contexto de uma AFC com itens ordinais. Os mesmos assuntos são abordados sob a perspectiva do que fazer (Flake et al., 2017; Nye, 2022; Rogers, 2024), o que não fazer (Crede & Harms, 2019; Rogers, 2024), e o que reportar (Flake & Fried, 2020; Jackson et al., 2009; Rogers, 2024), para escolhas de modelos de medidas cujos dados possam ser tratados como contínuos.

Partimos da hipótese que o leitor possui algum conhecimento introdutório sobre o assunto, e por isso, deixamos certas nuances para alguns bons manuais (Brown, 2015; Kline, 2023) ou artigos científicos que oferecem uma boa introdução à CB-SEM (Davvetas et al., 2020; Shek & Yu, 2014). O contexto é da AFC dentro do arcabouço da CB-SEM (Brown, 2015; Jackson et al., 2009; Kline, 2023; Nye, 2022). Não abordaremos ajustes de modelos de medidas na SEM baseada em variâncias (VB-SEM), que podem ser encontradas, principalmente, na literatura sobre *Partial Least Squares* SEM (PLS-SEM) (J. F. Hair et al., 2017, 2022; Henseler, 2021).

2.1 Seleção do Modelo de Medida

Na seleção do modelo de medida, recomendamos privilegiar instrumentos cujos itens tenham cinco ou mais categorias de resposta, preferencialmente sete, entre as alternativas com evidências de validade para o construto, a língua e a população de interesse. A preferência por sete categorias decorre do desempenho favorável observado em condições estudadas de AFC e da possibilidade de maior diferenciação das respostas; não representa uma garantia de maior poder ou de melhor mensuração em qualquer contexto (Harpe, 2015; Rhemtulla et al., 2012). Essa orientação se aplica à escolha entre instrumentos apropriados e não autoriza alterar arbitrariamente o formato de resposta de uma escala validada, pois modificações podem exigir nova avaliação de suas propriedades psicométricas (Harpe, 2015).

O número de categorias oferecidas também deve ser confrontado com a forma como elas são utilizadas. Um item com cinco ou sete opções pode apresentar respostas concentradas em apenas duas ou três categorias, como destaca Harpe (2015). Por isso, recomendamos examinar, no planejamento, evidências de aplicações anteriores na população-alvo e, após a coleta, as frequências das categorias e a distribuição de cada item. A descrição dos indicadores no pré-processamento permitirá documentar essas características e informar a avaliação da estratégia de estimação. As correções robustas não dispensam essa análise nem corrigem automaticamente uma especificação inadequada do modelo de medida (Rhemtulla et al., 2012).

Ao selecionar um modelo de medida, é importante dar prioridade para escalas que já foram validadas na língua de aplicação e utilizadas na população-alvo da pesquisa (Flake et al., 2017). Além disso, é crucial confirmar se essas escalas não são proprietárias ou privativas de uma profissão. Uma varredura inicial no Sistema de Avaliação de Testes Psicológicos do seu país pode ser útil, e se não encontrar o que procura, busque por escalas financiadas por entidades públicas ou não governamentais, grupos/centros de pesquisas ou universidades que, geralmente, empreendem maior esforço (recursos humanos, tempo e dinheiro) para validar modelos de medidas para fins de políticas públicas.

Esgote seu esforço de pesquisa para a seleção do modelo de medida, consultando periódicos especializados, livros, relatórios técnicos e dissertações ou teses. Schumacker et al. (2021) fornecem uma lista extensa para busca de testes e medidas como ponto de partida. Existem diversas revisões sistemáticas (ou meta-análise) da literatura de modelos de medida sobre um tema, área ou construto. Nunca deixe de conferir os artigos originais da escala e relevantes aplicações subsequentes. Kline (2016, p. 29) apresenta um interessante checklist para avaliar modelos de medidas potenciais.

Evite se aventurar em modelos de medida construídos para propósitos específicos e sem rigor psicométrico (Flake & Fried, 2020; Kline, 2016). A simples existência de uma escala não indica que ela é válida (Flake et al., 2017). Além disso, não confie indiscriminadamente em escalas utilizadas pouquíssimas vezes ou construídas há muito tempo, pois isso pode ser um indicativo de fracas propriedades psicométricas. Evite também pegar uma escala aplicada em outra língua e fazer um processo de tradução/retradução "rápido", aplicando-a em uma única amostra. Não oculte estruturas fatoriais alternativas (modelos de ordem superior ou bifactor) para um mesmo modelo de medida, pois se o pesquisador acha que terá mais "trabalho", essas estruturas alternativas, com alguma relevância e justificativa teórica, pode ser a salvação da pesquisa (Crede & Harms, 2019).

Justifique as boas propriedades psicométricas da escala selecionada, indicando as evidências empíricas anteriores de emprego na população almejada, medidas de confiabilidade e validade (Flake & Fried, 2020; Jackson et al., 2009; Kline, 2016). Se para uma mesma escala existir diferentes estruturas fatoriais esperadas (modelos de ordem superior ou bifactor), justifique as comparações que serão empreendidas para não utilizar a AFC para fins exploratórios (Jackson et al., 2009).

Especifique seu modelo preferido e apoie sua escolha discutindo os méritos de seu modelo preferido em relação a modelos teóricos equivalentes e concorrentes (Jackson et al., 2009). Represente graficamente os modelos testados (Jackson et al., 2009). Defina e descreva, a priori, a partir das evidências empíricas anteriores, as suspeitas de cross-loadings (Brown, 2023; Nye, 2022).

Considerando que a escala selecionada poderá estar no contexto de um questionário de pesquisa mais amplo, em linha com as propostas de triagem procedimental da literatura sobre respostas descuidadas ou com esforço insuficiente (*Careless or Insufficient Effort Responding* — C/IER) (Curran, 2016; Huang et al., 2026; Ward & Meade, 2023), como detalharemos adiante, recomenda-se planejar desde o desenho do instrumento a inclusão de itens de atenção explícita (por exemplo, instructed response items e, quando apropriado, bogus/infrequency items) e o registro do tempo de resposta do questionário, se possível em nível de página, de modo a permitir, em um nível mínimo de triagem, a identificação de respondentes que não leram os itens ou que completaram o questionário em velocidade incompatível com um processamento cuidadoso das perguntas (Ward & Meade, 2023).

2.2 Análise de Poder

Primeiramente, uma das questões mais importantes a se ressaltar sobre a AP é o que não fazer: não justifique a decisão de tamanho amostral com base em regras de bolso. Existem regras de bolso que vão ao encontro das mais diversas demandas: i) alguns estudos indicam tamanho mínimo (n) de 50, 100, 200, 300, 400, 500 e 1.000; outros estudos indicam ii) critérios número de observações/quantidade de parâmetros (n/p): 20/1, 10/1, 5/1 (Kline, 2023; T. A. Kyriazos, 2018). Essas sugestões são baseadas em situações específicas, estudos de simulação com design particular, e podem não estar de acordo com o cenário da sua pesquisa.

É importante ressaltar que não se deve confiar em tamanhos amostrais de limite inferior para substituir a AP para detectar efeitos-alvo (Westland, 2010). Esse tamanho de amostra representa o n mínimo necessário para qualquer modelo, e praticamente garantirá poder inadequado para detectar efeitos-alvo de tamanho equivalente no modelo em estudo (Wang, 2023). Nesse sentido, deveria ser evitada a calculadora de Soper (2026), disponível em: https://www.danielsoper.com/statcalc; e muito utilizada nos estudos empíricos (em 14/09/2026, com cerca de quatro anos de existência, acumulava mais de 2.000 citações no Google Scholar).

Regras gerais para requerimentos de tamanho amostral no contexto da SEM, devido ser uma técnica complexa, são impraticáveis (T. A. Kyriazos, 2018), e uma estratégia mais produtiva e moderna tem sido adaptar o poder amostral para cada estudo, acomodando o contexto específico da pesquisa e considerando suas questões focais (Feng & Hancock, 2023; Moshagen & Bader, 2024). Não existe "regra-de-ouro" sobre tamanho amostral ou tamanho mínimo de amostra para todos os estudos (Kline, 2023).

Apesar da opção de se executar a AP *a posteriori,* sugere-se que o planejamento amostral seja realizado antes de coletar os dados (*a priori*) (Feng & Hancock, 2023). Procedendo dessa forma, naturalmente, o pesquisador adquirirá maior entendimento sobre sua pesquisa (Leite et al., 2023). Isso porque, como veremos, algumas decisões devem levar em conta algum conhecimento sobre a literatura subjacente e parâmetros populacionais conhecidos sobre o modelo de medida em avaliação (Feng & Hancock, 2023). Se o pesquisador levou a primeira etapa a sério, a AP *a priori* torna-se um trabalho menos árduo.

A AP *a priori* permite estimar o tamanho amostral necessário para alcançar o poder desejado, sob os pressupostos adotados. Isso aumenta a confiabilidade de obter resultados válidos, replicáveis e comparáveis com outras pesquisas na área, facilitando as metas-análises, por exemplo. Também evita o desperdício de tempo e recursos, coletando dados de uma amostra maior do que o necessário, e ajuda a definir o orçamento para a coleta de dados, otimizando o planejamento da pesquisa (Feng & Hancock, 2023).

Dentro da SEM a AP pode ser realizada analiticamente, com base na teoria assintótica, ou por meio de simulação. A abordagem analítica requer a definição do efeito de interesse em termos de uma medida que mostre uma relação direta com o parâmetro de não centralidade. A AP simulada obtêm uma estimativa empírica do poder através de um modelo populacional ou considerado verdadeiro (Moshagen & Bader, 2024). Existem duas avaliações principais para as quais o poder é relevante: o ajuste global do modelo e os parâmetros do modelo. Em qualquer uma dessas avaliações podemos utilizar tanto métodos analíticos quanto de simulação (Feng & Hancock, 2023).

Geralmente, numa AFC, estamos procedendo a validação de um modelo de medida para um passo posterior e nesse sentido recomenda-se, no mínimo, que se avalie o poder relevante de um ajuste global do modelo de medida (Nye, 2022; Wang, 2023). Apesar das limitações das soluções analíticas (Feng & Hancock, 2023), podemos utilizá-las como ponto de partida e complementar aos métodos de simulação (Moshagen & Bader, 2024).

Existem formas acessíveis de se proceder as soluções analíticas para a AP do ajuste global (Wang, 2023): 1) baseada no teste qui-quadrado não central (solução Saris-Satorra); ou 2) baseada na estatística RMSEA de um modelo corretamente/incorretamente especificado (solução de MacCallum e outros). Como exemplos dessas opções temos os ShinyApps: i) https://sjak.shinyapps.io/power4SEM/ de Jak et al. (2021); ii) https://sempower.shinyapps.io/sempower/ de Moshagen & Bader (2024); iii) https://yilinandrewang.shinyapps.io/pwrSEM/ de Wang & Rhemtulla (2021); e o aplicativo WebPower (https://webpower.psychstat.org/) de Zhang & Yuan (2018).

Esse último é o mais completo e apresenta soluções baseadas na Simulação de Monte Carlo (SMC), nos permite contemplar valores *missing* e dados não-normais, e principalmente, podemos fazer tudo através de diagramas, sem necessidade de *script*. A solução de Wang & Rhemtulla (2021) também tem a opção de utilizar simulação, e todas elas também incorporam a AP de um efeito específico (parâmetro do modelo). Para uma visão geral sobre essas soluções e revisão dos métodos analíticos veja Feng & Hancock (2023), Jak et al. (2021), Nye (2022) e Wang (2023).

Para a AP de um modelo AFC, uma escolha pragmática é executar uma SMC com ferramentas que permitam documentar e reproduzir as condições e os resultados da análise. Nesse sentido, até mesmo as soluções analíticas, que o pesquisador pode tomar como ponto de partida, sugere-se o ambiente *R* através dos pacotes semTools (Jak et al.,

2021) e semPower 2 (Jobst et al., 2023; Moshagen & Bader, 2024).

Para a SMC no contexto da SEM, o pacote simsem (Pornprasertmanit et al., 2022) oferece uma alternativa flexível. Essa recomendação reúne razões pragmáticas e teóricas:

- A abordagem analítica depende fortemente das distribuições de amostragem conhecidas e propriedades assintóticas da estatística de teste. Entretanto, muitas dessas suposições podem ser facilmente relaxadas ao usar a SMC, que se mostra cada vez mais popular devido à sua flexibilidade para se adaptar a vários cenários de pesquisa (dados categóricos, valores ausentes, estudos longitudinais, ajuste local e global, etc.) (Feng & Hancock, 2023), inclusive, com a possibilidade de se utilizar as versões robustas do estimador ML, como veremos adiante;
- A SMC exige que o pesquisador forme a base de conhecimento do seu modelo de medida populacional, no qual os verdadeiros valores dos parâmetros são conhecidos, e ajuda apoiar a validade das inferências obtidas de suas análises (Leite et al., 2023). Por exemplo, os resultados obtidos com a SMC podem indicar os pontos de cortes dos índices de ajustes globais utilizados nas etapas posteriores;
- A desvantagem que a SMC exige substancial poder de computação e tempo, para modelos complicados (Nye, 2022), se sustenta parcialmente na prática (Byrne, 2016). Primeiro, porque na maioria das aplicações empíricas os modelos AFC não são tão complexos. Segundo, porque o poder computacional atual e a computação em nuvem oferecem soluções escaláveis e acessíveis para pesquisas que demandam alto poder computacional. Diversos caminhos podem ser utilizados para otimizar a SMC, tal como a seleção de parâmetros eficientes, algoritmos de estimação avançados e dividir o estudo em etapas (Leite et al., 2023). E por último, somente a SMC produz uma solução realista para modelos complexos (Moshagen & Bader, 2024);
- Por mais que possa ressoar contraintuitivo e/ou alguns cientistas sociais encarar com ceticismo: a SMC é fácil de aprender (Nye, 2022; Wang, 2023; Wang & Rhemtulla, 2021) ou tão difícil quanto a abordagem analítica Saris-Satorra para analisar o efeito de um parâmetro específico. A lógica por trás da SMC é relativamente simples (Leite et al., 2023), e o conhecimento básico de estatística é suficiente para compreender os princípios da técnica. Tutorais e documentações completas facilitam o aprendizado e a utilização da SMC no contexto da SEM, como é o caso do pacote simsem (https://simsem.org/), cujos exemplos são variados e didáticos. Esse pacote faz uso da syntax do lavaan, e caso o cientista social já o utilize ou pretende seguir os passos desse manuscrito executável, estará bem adiante na curva de aprendizado. Nesse sentido, se considerar as habilidades necessárias para o entendimento das soluções analíticas, e o conforto de funções predefinidas para calcular o poder estatístico para diferentes tipos de modelos e designs de pesquisa, a partir de uma syntax conhecida, a flexibilidade da SMC mais do que compensa qualquer esforço marginal que possa existir (Feng & Hancock, 2023).

Cremos que a prática de reportar o planejamento amostral para o(s) modelo(s) de medida auxilia na replicabilidade e reprodutibilidade da ciência (Flake et al., 2017; Flake et al., 2022), contribuindo para acumular evidências de validade da estrutura interna (Flake & Fried, 2020) e externa (Leite et al., 2023). No contexto da AFC, um baixo poder porventura que deixamos passar, pode acender um sinal de alerta para as inferências procedidas a partir do modelo completo (modelo de medida + estrutural). A SMC

permite avaliar o poder sob cenários relevantes para o modelo de medida. A relevância desses cenários deve acompanhar a avaliação da precisão: informações precisas sobre um resultado irrelevante são muitas vezes menos úteis do que informações imprecisas sobre um resultado relevante (Leite et al., 2023).

2.3 Pré-processamento

A qualidade dos dados é condição necessária, embora não suficiente, para que os parâmetros estimados numa AFC sejam válidos e interpretáveis. Além das inconsistências técnicas (e.g., vide Whittaker & Schumacker (2022)) e do Common Method Bias (CMB, vide Podsakoff et al. (2012)), a etapa de pré-processamento deve considerar sistematicamente o C/IER. C/IER designa as respostas fornecidas sem atenção ou esforço suficiente ao conteúdo dos itens, abrangendo padrões aleatórios e não aleatórios, como *straightlining*, respostas concentradas no meio da escala e padrões repetitivos (Curran, 2016; Huang et al., 2015).

É importante distinguir C/IER de outros fenômenos de resposta: a Desejabilidade Social e a Aquiescência, por exemplo, constituem ameaças à validade baseada nos processos de resposta, conforme discutido na introdução deste artigo. O C/IER opera em nível distinto: quando respostas desatentas contaminam múltiplas medidas autorrelatadas na mesma direção, elas introduzem variância compartilhada não substantiva que funciona como uma fonte de *Common Method Variance* (CMV) e pode gerar CMB, distorcendo correlações, cargas fatoriais e inferências (Huang et al., 2015). Assim, C/IER pode ser entendido como um caso particular e contingente de CMV/CMB, distinguindo-se da simples noção de erro aleatório de medição. A revisão de Huang et al. (2026) evidencia que a triagem de C/IER ainda carece de padronização, reforçando a necessidade de incorporá-la formalmente ao workflow de pré-processamento.

Uma vez os dados originais tabulados, de preferência em arquivos não binários (.csv, .txt, .json, etc.), a primeira ação a se tomar é excluir as respostas dos entrevistados que, efetivamente, abandonaram a pesquisa. Às vezes acontece desse indivíduo ficar na base de dados e somente ao final do pré-processamento nos darmos conta. Enquanto isso, ele serviu de informação para o tratamento dos *missings*, *outliers* e a multicolinearidade.

Os itens de controle (*instructed response items* ou *infrequency items*) e o tempo de resposta do questionário ou por página (*page time*) são métodos procedurais de detecção de C/IER que devem ser planejados desde a concepção do instrumento (Curran, 2016; Huang et al., 2026). A regra de falhas nos controles e o limite de tempo devem considerar as características do questionário. A literatura apresenta limiares de dois a quatro segundos por item: dois segundos constituem uma referência para identificar preenchimentos extremamente rápidos (Curran, 2016), enquanto Jones et al. (2023) examinam limites de três e quatro segundos por item. Esses valores são referências para definir o protocolo, não limites universais de processamento das respostas.

No âmbito dos métodos *post hoc* de detecção de C/IER, calcule o índice *Intraindividual Response Variability* (IRV) de cada indivíduo para avaliar a variabilidade das respostas aos itens. O IRV representa o desvio-padrão das respostas do indivídulo, e valores iguais a zero ou muito perto de zero correspondem, na literatura C/IER, a *straightlining*, uma forma sistemática de C/IER que pode inflar artificialmente a consistência interna da escala. Complementarmente, o *Longstring* quantifica a maior sequência de respostas idênticas consecutivas, sendo especialmente sensível a respondentes que selecionam repetidamente a mesma opção (Curran, 2016; Hong et al., 2020). Em casos que o IRV é

alto há indicíos de padrões de resposta aleatórios, inconsistente com respostas esperadas de itens dentro de um mesmo constructo (Curran, 2016; Hong et al., 2020).

A detecção de *outliers* deve ser integrada ao protocolo de triagem C/IER e tratada como etapa do pré-processamento. Padrões de resposta aberrantes comprometem a estrutura de covariância dos dados e podem distorcer a solução fatorial antes mesmo de qualquer ajuste de modelo. A distância de Mahalanobis é o indicador multivariado mais utilizado: estima a distância entre o vetor de respostas de cada indivíduo e o vetor médio da amostra, sendo sensível a padrões de resposta aleatórios (Curran, 2016; Hong et al., 2020).

A recomendação consolidada é empregar um subconjunto complementar de índices, tal como, por exemplo: algum método procedural, IRV e distância de Mahalanobis (*best subset approach*); pois cada indicador captura manifestações distintas de C/IER; a combinação de todos os índices disponíveis (*kitchen sink approach*) tende a reduzir a especificidade sem ganho equivalente de sensibilidade (Hong et al., 2020).

A combinação dos indicadores pode ser operacionalizada por múltiplos obstáculos (*multiple-hurdle approach*), em que a falha em qualquer critério previamente definido determina a exclusão (Curran, 2016; DeSimone et al., 2015). Essa estratégia não exige que o mesmo respondente seja sinalizado simultaneamente por todos os índices, pois cada um identifica manifestações distintas de C/IER. A escolha de critérios e limiares deve ser explicitada, considerando tanto a detecção de respostas descuidadas quanto o risco de excluir respondentes atentos. No caso dos itens de atenção, deve-se definir quantas falhas constituem um obstáculo, em vez de equiparar qualquer erro isolado à desatenção.

Sobre a multicolinearidade, calcule o fator de inflação de variância (VIF) dos itens e investigue valores elevados, considerando a redundância entre indicadores e possíveis dificuldades de estimação (Whittaker & Schumacker, 2022). Na AFC, cujo foco reside em constructos reflexivos, a correlação entre os itens é desejável (Grewal et al., 2004), mas nem tanto ao ponto de causar problemas de convergência dos modelos (Flora et al., 2012; Kline, 2023; Whittaker & Schumacker, 2022). A alta colinearidade ou multicolinearidade entre as variáveis observadas é uma das principais causas de uma matriz não-positiva definida (Flora et al., 2012; Kline, 2023), e mesmo se o modelo convergir com sua presença, pode acarretar em interpretações equivocadas (Marsh et al., 2004) e/ou indicar falta de validade discriminante (Grewal et al., 2004).

O tratamento dos *missings* pode ser realizado na etapa de estimação. A exclusão de casos incompletos (*listwise*) ou o uso dos pares disponíveis (*pairwise*) devem ser distinguidos da imputação única, como a substituição pela média ou por valores preditos por regressão. A imputação única não incorpora adequadamente a incerteza dos valores substituídos e pode subestimar os erros-padrão (Enders, 2023). A imputação múltipla e o FIML oferecem alternativas para o tratamento das ausências; sua escolha deve considerar o modelo e o mecanismo de ausência, mesmo quando a proporção de dados faltantes é pequena (Kline, 2023).

O FIML representa uma escolha prática para aplicações de AFC com ML ou MLR, pois utiliza diretamente as informações observadas de cada participante na estimação, sem exigir a criação e a combinação de bancos imputados (Brown, 2023). Seu uso pressupõe condições compatíveis com ausência completamente ao acaso ou ao acaso condicionada às variáveis observadas, além de especificação adequada do modelo (Enders, 2023; Kline,

2023). A imputação múltipla também é uma alternativa válida, embora envolva decisões adicionais sobre o modelo de imputação e a combinação dos resultados (Kline, 2023).

A disponibilidade de procedimentos de estimação robustos reduz a necessidade de transformar os dados apenas para aproximá-los da normalidade (Brown, 2023). Outra recomendação é não parcelar os itens, pois (i) existem muitas estratégias de fazer isso e (ii) pode mascarar a multidimensionalidade (Brown, 2023; Crede & Harms, 2019).

Inspeções visuais e descritivas dos itens do modelo de medida estão implícitas, recomendadas e salutares em qualquer análise estatística. Existem várias formas para isso, mas debruçar sobre esses procedimentos, assim como outras questões do pré-processamento abordadas na literatura (Brown, 2023; Collier, 2020; Flora et al., 2012; J. Hair et al., 2019; Kline, 2023; Whittaker & Schumacker, 2022), considera-se desnecessário para os fins desse manuscrito.

Em suma, reporte todos os procedimentos para limpar os dados. Seja transparente em relação aos *missings*. Todo pesquisador enfrenta esse problema, e em doses pequenas, é possível de tratamento e não invalida o estudo (Crede & Harms, 2019). Execute e reporte estratégias para avaliar o engajamento dos respondentes e a triagem de C/IER, incluindo os índices utilizados, os pontos de corte adotados e a proporção de casos removidos (Huang et al., 2026). Reporte indícios de multicolinearidade mesmo antes de começar a AFC. Reporte o software e/ou pacotes utilizados com suas devidas versões (Flake & Fried, 2020; Jackson et al., 2009). Disponibilize os dados brutos ou a matriz de covariância/correlação dos itens (Crede & Harms, 2019; Flake et al., 2022; Flake & Fried, 2020).

2.4 Processo de Estimação

Numa AFC cujos itens são ordinais, ou seja, com opções de resposta do tipo Likert de até cinco pontos, Rogers (2024) argumenta, através de uma extensa literatura, que devemos utilizar os estimadores da família OLS (Ordinary Least Squared), preferencialmente ULS (Unweighted LS) na sua versão robusta (RULS), para amostras menores, ou DWLS (Diagonally Weighted LS) na sua versão robusta (RDWLS), para amostras maiores.

No entanto, conforme argumentado da introdução, algumas evidências empíricas (Rhemtulla et al., 2012; Robitzsch, 2022) e argumentos teóricos (Robitzsch, 2020) sugerem que metodologia contínua na presença de dados ordinais produzirá resultados aceitáveis quando o número de categorias for cinco ou mais. Com 6-7 categorias, os estudos (Rhemtulla et al., 2012) encontram semelhanças entre os métodos para muitas condições e recomendam o uso de um grande número de alternativas de resposta (5) para aumentar o poder de detectar modelos incorretos (Maydeu-Olivares et al., 2017).

Apesar do estimador ML ser robusto a pequenos desvios de normalidade (Brown, 2015), nessas condições: presença de assimetria e excesso de curtose, ou seja, onde a falta de normalidade (moderada ou severa) é a regra e não exceção; alguns argumentos (Robitzsch, 2020) são direcionados para se utilizar as versões robustas do estimador ML, particularmente o MLR.

Existem vários métodos para gerar erros-padrão robustos e estatísticas de teste ajustadas com propriedades semelhantes (Kline, 2023), mas o MLR tem aplicações mais amplas, como a estimativa de modelos com dados faltantes tratados por FIML (Brown, 2015; Rosseel, 2012). Adicionalmente, acumulam algumas evidências empíricas favoráveis, ou que não desabonam o MLR, comparativamente às outras opções de estimadores

(Bandalos, 2014; Holgado-Tello et al., 2016; Li, 2016a; Nalbantoğlu-Yılmaz, 2019; Yang & Liang, 2013; Yang-Wallentin et al., 2010).

Dito isso, inicialmente, inspecione se existem casos Heywood: cargas fatoriais padronizadas > 1 ou variâncias negativas (Nye, 2022). De qualquer forma, reporte e justifique o método de estimação utilizado a partir das características dos dados disponíveis e modelo a ser ajustado (Crede & Harms, 2019). Reporte todos os problemas ocorridos com a estimação, tal como não convergência dos algoritmos e modelos não identificados (Nye, 2022). Na presença desses problemas, investigue a identificação, a especificação do modelo e as características dos dados antes de considerar alternativas de estimação. Além disso, indique se fixou a variância ou uma variável marcadora (=1) para definir a escala da variável latente (Jackson et al., 2009) e reporte os parâmetros padronizados e não padronizados (Nye, 2022).

2.5 Ajuste do Modelo

Nessa seção também nos parece sensato começar com a indicação do que não fazer: não utilize os cutoffs tradicionais, seja aqueles mais conservadores (SRMR .06, RMSEA .06 e CFI .95) ou menos conservadores (RMSEA .08, CFI .90 e SRMR .08). Ultrapassar um conjunto de valores de corte não deve ser a principal justificativa para aceitar um modelo (Xia & Yang, 2019). Os cutoffs tradicionais foram concebidos a partir de estudos de simulação que levaram em conta no máximo uma estrutura com 3 fatores, 15 itens e cargas fatoriais entre 0.7 e 0.8 (West et al., 2023). Os cutoffs tradicionais são sensíveis ao número de itens e fatores, graus de liberdade do modelo, magnitude das cargas fatoriais, tipo de desajuste e missing data (Groskurth et al., 2024; Niemand & Mai, 2018; West et al., 2023).

Todos os índices globais têm suas limitações e vantagens (West et al., 2023). Analise os principais índices globais (SRMR, RMSEA e CFI) em conjunto e não tome um em particular (Mai et al., 2021; Niemand & Mai, 2018). Se algum índice global indicar um desajuste, mesmo que pequenos desvios dos cutoffs tradicionais (SRMR .06, RMSEA .06 e CFI .95), pode ser necessária uma investigação mais aprofundada para demonstrar que o desajuste se deve às características dos dados ou a uma limitação do índice em vez de uma especificação incorreta do modelo (Nye, 2022). O ajuste exato corresponde à ausência de discrepância populacional entre a matriz de covariâncias implicada pelo modelo e a matriz populacional. O ajuste aproximado admite discrepâncias e procura avaliar sua magnitude. Assim, rejeitar o ajuste exato não determina, por si só, se o desajuste é substantivamente importante; essa avaliação depende da referência de magnitude e das relações que o modelo deixa de representar (McNeish & Wolf, 2024).

Nesse sentido, trate os índices convencionais de ajuste global mais como um tamanho de efeito, como originalmente foram concebidos (McNeish & Wolf, 2023), do que um teste de hipótese *ad hoc* em que se toma uma decisão de rejeitar/não rejeitar o modelo (McNeish, 2023b). O SRMR parece ser mais robusto sob a uma variedade maior de situações (Mai et al., 2021), como a falta de normalidade e/ou nível de mensuração dos itens (Maydeu-Olivares et al., 2017; Shi et al., 2020; Shi & Maydeu-Olivares, 2020). No mais, utilizar o par SRMR/CFI parece ser suficiente para balancear os erros Tipo I/Tipo II, e empregar diversos índices poder inflar o erro do Tipo I (Mai et al., 2021; Niemand & Mai, 2018).

Os pontos de corte dinâmicos (*Dynamic Fit Index* — DFI) adaptam a avaliação dos índices às características do modelo e dos dados em estudo. Sua lógica retoma a

estratégia de simulação que originou os limites tradicionais: gerar dados sob condições de referência e de má especificação, ajustar o modelo a esses dados e examinar as distribuições dos índices resultantes. Os pontos de corte são escolhidos para distinguir essas condições, considerando a sensibilidade ao desajuste e a rejeição de modelos corretamente especificados. O caráter dinâmico está em recalcular essas referências para o modelo, o tamanho amostral e as condições de análise, em vez de transportar os valores produzidos por uma simulação particular para qualquer aplicação (McNeish & Wolf, 2023; McNeish & Wolf, 2024).

O DFI reúne abordagens desenvolvidas para diferentes estruturas e características dos dados, incluindo modelos unifatoriais e multifatoriais, distribuições não normais e itens Likert tratados como contínuos (McNeish, 2023a; McNeish & Wolf, 2023). Nas versões baseadas em caminhos omitidos (*omitted paths DFI* — OP-DFI), a má especificação é produzida acrescentando relações à estrutura geradora e omitindo-as no modelo ajustado. Essa construção exige algoritmos próprios para diferentes modelos e pode atribuir significados distintos ao mesmo nível de desajuste: omitir uma carga cruzada não afeta proporcionalmente da mesma forma um modelo com poucos indicadores e outro com muitos (McNeish & Wolf, 2024).

Para ampliar essa estratégia, McNeish & Wolf (2024) propõem o DFI por discrepância direta (*direct discrepancy DFI* — 3DFI). O procedimento parte da matriz de correlações implicada pelo modelo estimado e gera perturbações aleatórias para construir matrizes populacionais que esse modelo não reproduz. A magnitude das perturbações é definida pela discrepância média absoluta (*Mean Absolute Discrepancy* — MAD), a média dos valores absolutos dos elementos fora da diagonal da matriz de discrepâncias. Em cada replicação, uma nova matriz de discrepâncias é sorteada, com magnitude média orientada pelo MAD escolhido. Geram-se dados sob essas perturbações e sob a condição consistente com o modelo; o modelo original é ajustado aos dados simulados, e as distribuições dos índices permitem derivar os limites de ajuste.

Essa formulação oferece três vantagens para a avaliação do ajuste: dispensa definir previamente quais caminhos estariam omitidos; aplica o mesmo princípio a diferentes modelos de estrutura de covariâncias, como AFC, bifactor e mediação; e utiliza uma escala de discrepância proporcional ao tamanho da matriz, permitindo uma interpretação mais consistente da magnitude do desajuste entre modelos. Assim, a calibração considera diferentes perturbações possíveis, em vez de depender de uma única omissão estrutural. A generalidade se refere aos modelos de covariâncias de um único grupo contemplados pela proposta, com estrutura de médias ausente ou saturada (McNeish & Wolf, 2024).

O método também permite incorporar características dos dados à geração das réplicas, como não normalidade, frequências de categorias e padrão de ausências, e utilizar estimação robusta, como MLR (McNeish & Wolf, 2024). Essas possibilidades e a definição do desajuste por sua magnitude fundamentam a escolha do 3DFI em diversos cenários. A dispensa de um caminho omitido específico não elimina a decisão sobre o tamanho do desajuste relevante: assim como o tamanho de efeito na AP, o MAD é uma entrada da simulação. Os valores de 0,038, 0,050 e 0,060 propostos pelos autores oferecem referências para ajuste próximo, razoável e medíocre, respectivamente. Foram obtidos relacionando discrepâncias no modelo de Hu e Bentler a limites tradicionais de RMSEA; funcionam como referências heurísticas de magnitude, enquanto os limites de CFI e RMSEA são recalculados para o modelo em avaliação (McNeish & Wolf, 2024).

Outras estratégias incluem os pontos de corte flexíveis (*Flexible Cutoffs* — FCO) e os

testes de equivalência (*Equivalence Testing* — EQT). O FCO simula dados consistentes com o modelo estimado e utiliza os extremos das distribuições dos índices como referências para identificar desajuste, adaptando os limites às características do modelo e dos dados (Mai et al., 2021; Niemand & Mai, 2018). Essa abordagem dispensa definir uma má especificação particular, mas concentra a avaliação no afastamento do ajuste exato, sem estabelecer qual magnitude de desajuste seria substantivamente tolerável (McNeish & Wolf, 2024). O EQT, por sua vez, inverte a lógica usual do teste: parte da hipótese de que o desajuste alcança ou excede um limite e permite endossar um nível de ajuste quando essa hipótese é rejeitada. Sua implementação analítica incorpora a variabilidade amostral à avaliação de CFI e RMSEA, sem exigir simulação (Marcoulides & Yuan, 2017; Yuan et al., 2016). Entretanto, os limites de referência ajustados ainda se apoiam em classificações convencionais de ajuste, e sua sensibilidade à má especificação pode variar conforme as características do modelo (McNeish & Wolf, 2024).

Complementando o que não fazer: não utilize o Alfa de Cronbach como medida de confiabilidade (Bell et al., 2023; Cho, 2022; T. J. Dunn et al., 2014; Flora, 2020; Goodboy & Martin, 2020; Green & Yang, 2015; Hayes & Coutts, 2020; Kalkbrenner, 2023; McNeish, 2018; Trizano-Hermosilla & Alvarado, 2016). Não utilize o 2 sem o devido ajuste (Yuan-Bentler scaled 2, por exemplo) (Crede & Harms, 2019).

Avalie os índices de ajuste local: baixa carga fatorial, cross-loadings, correlação residual (>0,10), índices de modificação (MI; >3,84) e mudanças esperadas nos parâmetros (*Expected Parameter Change* — EPC) (Nye, 2022). Esses valores orientam a inspeção e devem ser interpretados em conjunto com a magnitude das relações e o conteúdo dos itens. Use como medida de confiabilidade o Ômega de McDonald e/ou o maior limite inferior de confiabilidade (*Greatest Lower Bound* — GLB) no contexto do modelo AFC ajustado (Bell et al., 2023; Cho, 2022; T. J. Dunn et al., 2014; Flora, 2020; Goodboy & Martin, 2020; Green & Yang, 2015; Hayes & Coutts, 2020; Kalkbrenner, 2023; McNeish, 2018; Trizano-Hermosilla & Alvarado, 2016).

Reporte o 2 ajustado e os graus de liberdade (df) (Crede & Harms, 2019). Reporte no mínimo os seguintes índices de ajuste global: RMSEA, CFI e SRMR. Note que, como utilizará o scaled 2, essas medidas também devem ser ajustadas tendo em vista o método empregado (Nye, 2022). Reporte, no mínimo, o Ômega de McDonald, mas preferencialmente, acompanhado do GLB ou outra medida de confiabilidade compósita (Trizano-Hermosilla & Alvarado, 2016). Reporte todas as decisões de ajuste do modelo (Flake & Fried, 2020), condizentes com a avaliação das medidas de ajuste local (baixa carga fatorial, cross-loadings, correlação residual, MI e EPC). Reporte o tamanho das correlações residuais e MI (Crede & Harms, 2019).

2.6 Comparações e Modificações dos Modelos

Já na primeira etapa sugerimos aos pesquisadores não ocultar estruturas fatoriais alternativas para um mesmo modelo de medida. Uma boa prática seria considerá-las na pesquisa desde o início (planejamento da pesquisa) e compará-las formalmente. O pesquisador pode ter um modelo preferido, mas selecione-o discutindo seus méritos em relação a modelos teóricos equivalentes e concorrentes (Jackson et al., 2009). Nenhum modelo pode refletir perfeitamente a verdade, então consideramos os modelos como aproximações plausíveis da realidade (Preacher & Yaremych, 2023).

Para que o conhecimento nas ciências sociais se acumule de forma genuína, é crucial que as diferentes teorias sejam comparadas e testadas ao longo do tempo, construindo

um histórico de acertos e erros. Diversas características definem um bom modelo, como interpretabilidade, simplicidade e capacidade de generalização. No entanto, o mais importante é que ele apresente desempenho superior a seus rivais em aspectos relevantes. Dessa forma, a teoria escolhida se torna uma "melhor hipótese de trabalho" até que uma alternativa mais eficiente surja (Preacher & Yaremych, 2023).

Os índices de ajuste são mais úteis para avaliar a qualidade de um único modelo isoladamente. Um bom ajuste transmite apenas que o modelo é uma representação plausível da estrutura real subjacente. Assumindo que os modelos concorrentes foram selecionados *a priori*, baseados em teorias substantivas, a comparação de múltiplos modelos é uma abordagem preferível à avaliação de modelos individuais (Preacher & Yaremych, 2023).

Na seleção de modelos, o pesquisador ajusta um conjunto de modelos ao mesmo conjunto de dados, utilizando o mesmo software e método de estimação. Isso garante que os graus de liberdade do pesquisador sejam mantidos relativamente constantes, mitigando o risco de manipulação dos resultados. Essa padronização promove uma abordagem mais honesta e científica para a investigação (Preacher & Yaremych, 2023).

Ao comparar o desempenho de diferentes modelos em aspectos relevantes, a seleção de modelos identifica a melhor opção para explicar o fenômeno em estudo. Essa abordagem não se limita à escolha de um único modelo, permitindo descartar aqueles com desempenho ruim e manter um conjunto de modelos de bom desempenho para análises posteriores. Essa flexibilidade garante uma investigação mais profunda e completa do problema em questão (Preacher & Yaremych, 2023). Em suma, a seleção de modelos é uma ferramenta valiosa para o avanço do conhecimento nas ciências sociais, promovendo rigor e transparência na análise (Preacher & Yaremych, 2023).

De qualquer forma, se um modelo individual não apresentar boas medidas de ajuste, modificações podem ser necessárias: certifique-se de que elas sejam teoricamente sustentáveis, verificando, por exemplo, se desvios semelhantes já foram documentados na literatura prévia (Nye, 2022). Achar que nenhum ajuste deve ser feito em um modelo de medida previamente validado, persistindo com desajustes substanciais, pode ser danoso: falhas de ajuste na AFC frequentemente proliferam para o modelo estrutural (Brown, 2023), enquanto correções criteriosas na mensuração dirimem distorções nas relações estruturais (Flake et al., 2017; Jackson et al., 2009).

No entanto, não se recomendam mudanças drásticas nos modelos de medida (Brown, 2023): diante de inconsistências severas, convém considerar uma análise fatorial exploratória preliminar ou outro instrumento de coleta. Por outro lado, caso o desajuste decorra apenas da rigidez do modelo confirmatório clássico, que restringe todas as cargas cruzadas a zero, pode-se recorrer a modelos ESEM (*Exploratory SEM*) para acomodar cargas secundárias de forma estruturada e eficiente (Crede & Harms, 2019).

Em tese, o pesquisador pode modificar o modelo sucessivamente até alcançar o ajuste perfeito aos dados (modelo saturado), porém à custa da capacidade de generalização (validade externa): modificações guiadas exclusivamente pelos dados alteram o status epistemológico da análise de confirmatório para exploratório, elevando o risco de capitalização sobre o acaso (*capitalization on chance*) (West et al., 2023). Covariâncias residuais só devem ser liberadas quando houver justificativa substantiva inequívoca para uma associação entre itens não explicada pelo fator latente, como conteúdos estritamente específicos ou características de redação compartilhadas (Brown, 2023; Nye, 2022). Para

salvaguardar a estabilidade do modelo reespecificado diante de buscas pós-hoc, a literatura metodológica recomenda estratégias de validação cruzada (*cross-validation*), seja por meio de novas amostras independentes ou pela divisão aleatória da amostra disponível (*split-sample*) em subamostras de calibração (onde as modificações são exploradas) e validação (onde o modelo refinado é testado de modo estritamente confirmatório) (Preacher & Yaremych, 2023).

Nesse sentido, toda e qualquer mudança no modelo de medida deve ser explicitamente relatada (Flake & Fried, 2020). O ideal é que eventuais ajustes plausíveis sejam antecipados *a priori* (Flake & Fried, 2020) para preservar o caráter confirmatório, mas, como na prática científica as modificações são regras e não exceções (Flake et al., 2017; Nye, 2022), a conduta ética reside na transparência (Flake et al., 2022; Flake & Fried, 2020). Exclusões de itens devem ser detalhadas a partir dos diagnósticos psicométricos da pesquisa, e qualquer correlação residual adicionada deve vir acompanhada de sua justificativa teórica e metodológica (Nye, 2022). Atualmente, não se sustenta a justificativa de limitação de espaço dos periódicos: o pesquisador pode disponibilizar scripts, matrizes e saídas analíticas completas em repositórios abertos permanentes.

Porém, quais medidas utilizar para comparar e selecionar modelos alternativos? Os índices de ajuste descritivo (SRMR, RMSEA e CFI) foram concebidos precipuamente para avaliar modelos isolados e possuem limitações para a seleção direta de modelos (Preacher & Yaremych, 2023), embora haja evidências e pontos de corte para contrastar variações (Δ) desses índices tanto em modelos aninhados quanto não aninhados (P.-H. Huang, 2017), inclusive sob desvios de normalidade (Lai, 2020) ou variáveis categóricas (Lai, 2021a).

No caso de modelos parametricamente aninhados (em que um modelo decorre de restrições de parâmetros sobre o outro), a ferramenta formal de comparação é o teste de diferença de χ^2 ajustado (Brown, 2015). Quando se empregam estimadores robustos, como MLM (Satorra-Bentler scaled χ^2) ou MLR (Yuan-Bentler scaled χ^2), a diferença simples entre os valores ajustados de χ^2 não fornece o teste de diferença com a correção necessária (Brown, 2015). Dessa forma, é imperativo aplicar o teste formal de diferença de χ^2 escalonado específico para o estimador adotado (Brown, 2015).

Para comparar modelos não aninhados (ou aninhados) na estrutura de parâmetros, a recomendação clássica recai sobre os critérios de informação, como o AIC (*Akaike Information Criterion*) e o BIC (*Bayesian Information Criterion*) (Preacher & Yaremych, 2023). Esses critérios equilibram o ajuste e a parcimônia paramétrica a partir da função de verossimilhança da estimação de ML, herdando características dessa abordagem, como sensibilidade a certas más especificações e premissas distribucionais (Preacher & Yaremych, 2023). Sob dados omissos tratados via FIML, sua interpretação exige cautela adicional, pois omissões combinadas a erros estruturais podem favorecer modelos divergentes daqueles selecionados com dados completos (Lai, 2021b).

É essencial destacar, contudo, uma premissa matemática fundamental frequentemente negligenciada no uso de critérios de informação: AIC e BIC são válidos para comparar modelos estimados sobre o **exato mesmo conjunto de variáveis observadas** (Preacher & Yaremych, 2023). A função de verossimilhança conjunta e o valor de discrepância F_{ML} dependem diretamente do número de variáveis manifestas (p) e da ordem da matriz de covariâncias analisada (Preacher & Yaremych, 2023). Portanto, quando um modelo é alterado pela exclusão de itens (por exemplo, eliminando indicadores com cargas baixas ou resíduos elevados), o espaço amostral é alterado e as verossimilhanças tornam-se

incomensuráveis (Preacher & Yaremych, 2023). O AIC ou BIC não podem ser utilizados para "provar" que uma escala com menor número de itens ajusta melhor do que a escala completa original. Nessas situações de refinamento e exclusão de itens, a decisão deve apoiar-se no julgamento teórico sobre a representatividade do domínio do construto e na inspeção de resíduos locais, cabendo à avaliação em dados não utilizados na seleção dos itens examinar a estabilidade da estrutura reduzida (Preacher & Yaremych, 2023).

Já quando os modelos concorrentes compartilham as mesmas variáveis observadas (como a comparação entre uma estrutura unidimensional, fatores correlacionados ou um modelo bifator), o AIC e o BIC operam com respaldo (Preacher & Yaremych, 2023). Em amostras moderadas, a penalidade do AIC privilegia a eficiência preditiva assintótica, enquanto o BIC impõe uma penalização mais severa pela complexidade, favorecendo modelos mais parcimoniosos e priorizando a consistência (P.-H. Huang, 2017; Preacher & Yaremych, 2023). Como consistência e eficiência não podem ser maximizadas simultaneamente, é prudente relatar e contrastar ambos os critérios (Preacher & Yaremych, 2023), complementando-os, se desejado, com procedimentos de validação cruzada preditiva (*k-fold*) (Preacher & Yaremych, 2023).

Quando a validação utiliza uma divisão amostral, a estabilidade pode ser examinada pela AFC multigrupo, considerando calibração e validação como grupos distintos e mantendo o mesmo conjunto de indicadores. A comparação passa a avaliar a equivalência dos parâmetros do modelo retido entre as parcelas. A proximidade dos índices globais é informativa, mas não estabelece, por si só, que cargas, interceptos ou variâncias residuais sejam equivalentes (Fischer & Karl, 2019; Putnick & Bornstein, 2016).

Para indicadores tratados como contínuos, a avaliação distingue quatro níveis. A invariância configural mantém o mesmo padrão de fatores e cargas livres nos grupos; a métrica acrescenta igualdade das cargas não padronizadas; a escalar acrescenta igualdade dos interceptos; e a estrita acrescenta igualdade das variâncias residuais (Putnick & Bornstein, 2016). O modelo configural é estimado simultaneamente nos grupos, preservando sua identificação, e não corresponde a um ajuste único que ignora a divisão. As restrições sucessivas produzem modelos aninhados, permitindo avaliar sua compatibilidade com os dados por testes de diferença e mudanças nos índices de ajuste (Fischer & Karl, 2019).

Em uma divisão aleatória da mesma amostra, calibração e validação representam parcelas da mesma população de origem. Quando o objetivo é avaliar se as cargas fatoriais se mantêm entre essas parcelas, a invariância configural seguida da métrica atende à pergunta de estabilidade das relações entre indicadores e fatores (Fischer & Karl, 2019). Avançar para a escalar é necessário quando se pretende comparar médias latentes; a estrita acrescenta a avaliação da igualdade das variâncias residuais (Putnick & Bornstein, 2016). Esses níveis adicionais podem ampliar a caracterização da medida, mas não são requisitos para examinar a estabilidade das cargas (Fischer & Karl, 2019; Putnick & Bornstein, 2016).

O teste de diferença de χ^2, com a correção correspondente quando se utiliza estimação robusta, pode ser acompanhado pelas mudanças de CFI, RMSEA e SRMR (Chen, 2007; Cheung & Rensvold, 2002). Definindo Δ como o índice do modelo mais restrito menos o do anterior, quedas de CFI próximas de 0,010 e aumentos de RMSEA próximos de 0,015 são referências frequentemente utilizadas para sinalizar deterioração. Sua interpretação é conjunta e condicionada ao tamanho e ao equilíbrio dos grupos, à estrutura do modelo e ao padrão de não invariância; esses valores não constituem limites universais (Chen, 2007).

Uma referência empírica adicional pode ser obtida por permutação dos rótulos de grupo. A redistribuição dos participantes e a reestimação dos modelos produzem uma distribuição das diferenças dos índices sob a hipótese de invariância. O valor-p empírico localiza a mudança observada na cauda de deterioração dessa distribuição, reduzindo a dependência de pontos de corte fixos (Jorgensen et al., 2018). A permutação deve respeitar as condições do desenho que justificam a redistribuição dos rótulos; em uma divisão estratificada, isso implica preservar a alocação dentro dos estratos. A não rejeição das restrições sustenta sua compatibilidade com os dados (Jorgensen et al., 2018; Putnick & Bornstein, 2016).

Considerando que a literatura sobre seleção de modelos em SEM continua em evolução (Preacher & Yaremych, 2023) e que todos os índices possuem particularidades, a diretriz central é que a decisão seja ancorada na experiência e no julgamento substantivo do pesquisador (Preacher & Yaremych, 2023). Sem fundamento teórico, métricas estatísticas de comparação tornam-se inócuas. Antes das análises, a teoria deve delimitar o conjunto restrito de modelos plausíveis; durante a seleção, a parcimônia e a coerência conceitual devem prevalecer; e, ao final, a teoria guia a interpretação das relações encontradas (Preacher & Yaremych, 2023).

A Figura 1 antecipa os procedimentos desenvolvidos nas próximas seções e suas conexões. O mapa permite localizar as análises e acompanhar como as especificações, os dados e os diagnósticos sustentam as decisões sobre os modelos.

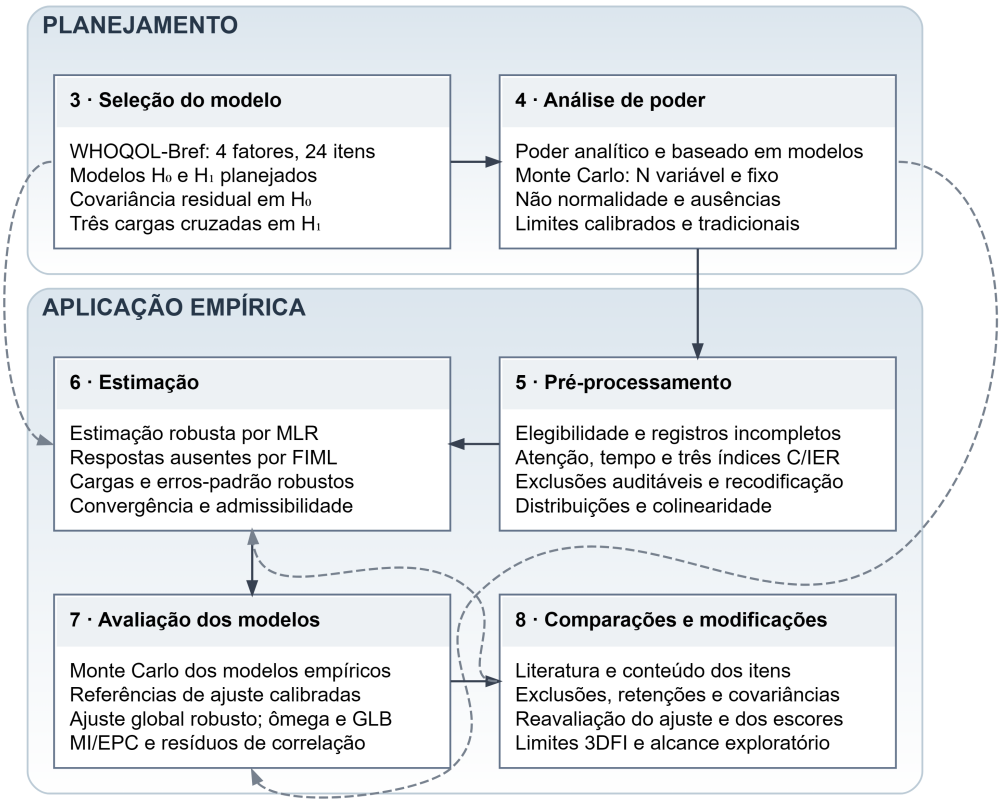


Figura 1: Mapa das decisões, procedimentos e evidências desenvolvidos na aplicação de AFC. As setas contínuas indicam o percurso de leitura; as tracejadas conectam as especificações planejadas à estimação, a calibração por simulação à avaliação empírica e as modificações à reestimação.

3 Seleção do modelo de medida

Utilizamos como exemplo a World Health Organization Quality of Life – Abbreviated Version (WHOQOL-Bref), um instrumento de autorrelato amplamente empregado na avaliação da qualidade de vida em diferentes populações e contextos culturais (Lin & Yao, 2022; Mosqueira Taipe et al., 2026; Skevington & Epton, 2018). O instrumento contém 26 itens com cinco categorias de resposta. Os dois primeiros abordam a percepção geral da qualidade de vida e a satisfação com a saúde; os demais 24 compõem os domínios físico (FIS), psicológico (PSI), relações sociais (SOC) e ambiente (AMB).

A escolha da WHOQOL-Bref permite desenvolver a recomendação apresentada na Seção 2.1: partir de um instrumento com estrutura teórica definida e evidências psicométricas acumuladas, cujos itens admitam uma estratégia de análise com dados que podem ser considerados contínuos. A presença de cinco categorias de resposta oferece suporte inicial a essa estratégia, conforme a fundamentação anterior, e suas implicações serão examinadas na descrição dos itens (Seção 5.3) e na estimação robusta (Seção 6). O objetivo do exemplo é explicitar as decisões de uma AFC e suas justificativas, preservando

o conteúdo e o formato de resposta do instrumento.

As sínteses da literatura sustentam a estrutura de quatro domínios, embora também indiquem que sua aplicação exige atenção às relações entre determinados itens. Lin & Yao (2022) integraram resultados de 16 estudos de análise fatorial exploratória e corroboram a solução de quatro fatores pela sua interpretabilidade e parcimônia. Nessa solução, Q8, referente à segurança na vida diária, apresentou relação mais forte com o domínio psicológico do que com o ambiental, ao qual pertence teoricamente. Esse resultado mostra que o suporte à organização geral em quatro fatores pode coexistir com relações entre itens e domínios que não correspondem a uma estrutura simples.

A revisão sistemática de Mosqueira Taipe et al. (2026) amplia essa discussão: dos 439 registros identificados, 36 estudos foram incluídos, e a estrutura de quatro fatores também foi identificada em 64% deles. A revisão sustenta a estrutura original, mas documenta modificações relacionadas a contextos culturais e clínicos, além de heterogeneidade nos procedimentos e no relato dos índices de ajuste. Portanto, esse conjunto de evidências justifica tomar os quatro domínios como ponto de partida e explicitar antecipadamente quais relações adicionais serão avaliadas.

Nesse sentido, a partir da leitura de Lin & Yao (2022), formulamos nosso modelo de análise primário, que inclui uma covariância residual entre Q3, sobre dor e desconforto, e Q4, sobre a necessidade de tratamento médico (Figura 2). Ambos pertencem ao domínio físico e são formulados em direção negativa à qualidade de vida. Sua proximidade de conteúdo e a formulação compartilhada tornam plausível uma associação que não seja inteiramente explicada pelo fator físico. Essa especificação também encontra precedente em estudos reunidos por Mosqueira Taipe et al. (2026). No contexto da discussão sobre Common Method Bias (CMB), tratamos essa covariância como uma hipótese de dependência local compatível com conteúdo ou método compartilhado.

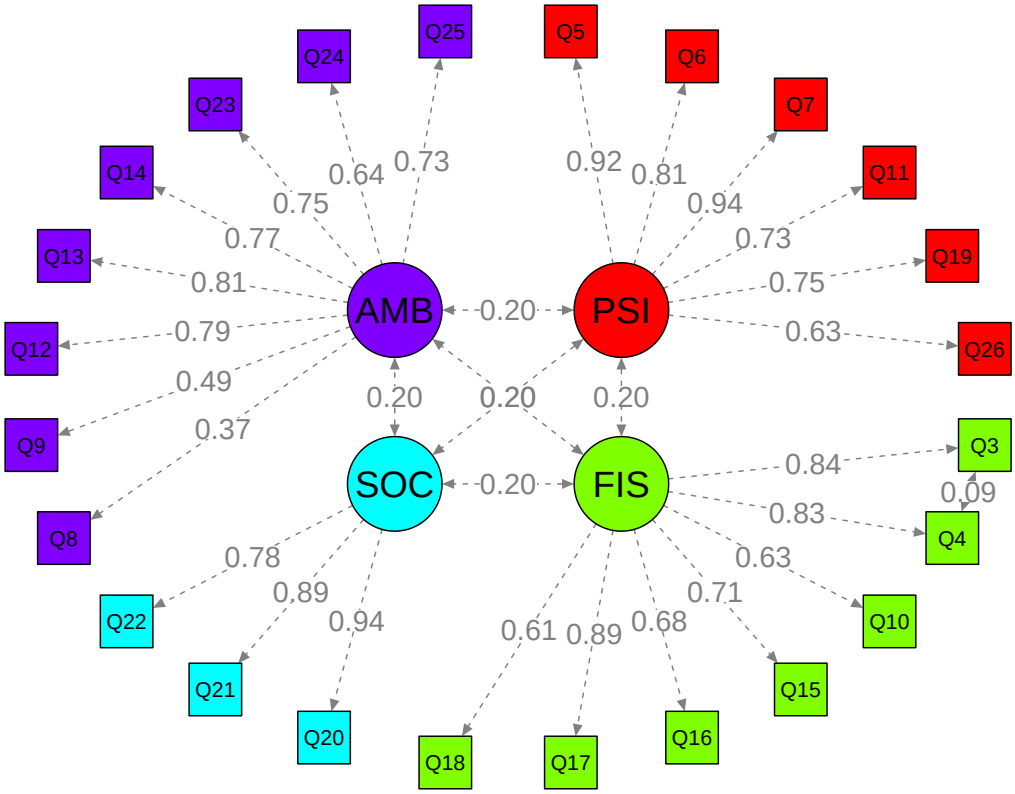


Figura 2: Modelo de quatro fatores correlacionados com covariância residual entre Q3 e Q4. *Nota.* PSI = psicológico; FIS = físico; SOC = relações sociais; AMB = ambiente. A figura representa a especificação (cargas fixas) do modelo populacional. Ao estimarmos com parametros livres, as cargas e a covariância residual são ajustadas para a amostra, e temos nosso modelo de análise (H_0)

O segundo modelo mantém a covariância residual Q3–Q4 e acrescenta três cargas cruzadas: Q8 e Q9 no domínio psicológico e Q15 no domínio ambiental (Figura 3). A seleção dessas relações é informada pela solução exploratória de quatro fatores apresentada na Tabela 3 de Lin & Yao (2022). A segurança percebida em Q8 e a avaliação do ambiente físico em Q9 podem compartilhar aspectos com o bem-estar psicológico, enquanto a mobilidade avaliada por Q15 pode envolver, além da capacidade física, condições ambientais. Essas interpretações constituem justificativas substantivas para testar as relações selecionadas; não são conclusões já estabelecidas para a amostra deste tutorial.

Preservamos as cargas de Q8 e Q9 no domínio ambiental e a de Q15 no domínio físico, acrescentando as relações propostas em vez de transferir os itens de domínio. Também não reproduzimos todas as cargas secundárias da solução exploratória de Lin & Yao (2022). O segundo modelo é uma especificação delimitada para este tutorial, apoiada naquela evidência e na interpretação do conteúdo dos itens, e não uma AFC anteriormente validada pelos autores com essa exata configuração.

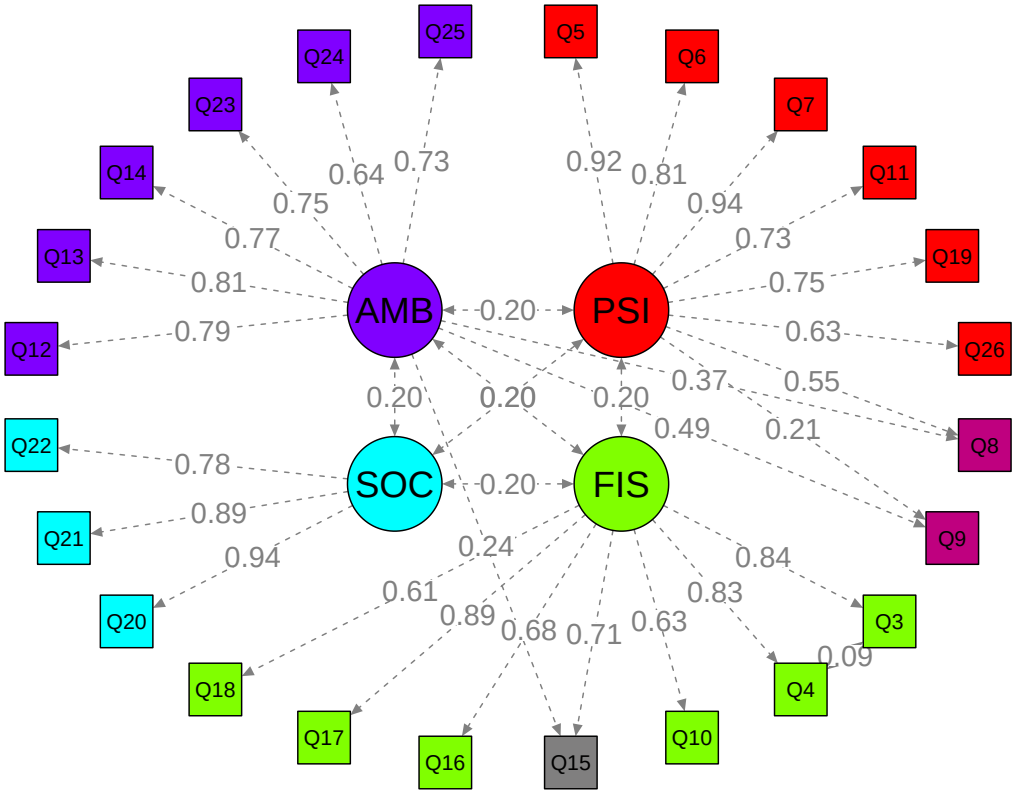


Figura 3: Modelo de quatro fatores correlacionados com covariância residual Q3–Q4 e três cargas cruzadas. *Nota.* PSI = psicológico; FIS = físico; SOC = relações sociais; AMB = ambiente. Mantém-se a estrutura do primeiro modelo e acrescentam-se as cargas do fator psicológico em Q8 e Q9 e do fator ambiental em Q15. A figura representa a especificação (cargas fixas) do modelo populacional alternativo. Ao estimarmos com parametros livres, as cargas e a covariância residual são ajustadas para a amostra, e temos nosso modelo alternativo (H_1)

4 Análise de poder

Em muitas pesquisas empíricas, uma escala não constitui o desfecho final, mas o modelo de medida de construtos posteriormente relacionados em um modelo estrutural. O planejamento amostral deve, portanto, considerar o instrumento e a estrutura que se pretende estimar, em vez de depender de regras gerais sobre o número de itens ou parâmetros (Kline, 2023). Nesta seção, tratamos poder como a probabilidade de detectar uma omissão estrutural definida antes da coleta.

4.1 Pressupostos a priori

A AP foi planejada a partir dos dois modelos de medida fundamentados na Seção 3. Nesta análise, a segunda especificação representa uma condição populacional alternativa na qual o ajuste do modelo mais parcimonioso implica a omissão deliberada das três cargas cruzadas.

As cargas fatoriais principais, as correlações entre os fatores e as variâncias residuais foram definidas com base nas evidências meta-analíticas e nas revisões apresentadas anteriormente (Lin & Yao, 2022; Mosqueira Taipe et al., 2026; Skevington & Epton, 2018). Consequentemente, a AP é conduzida *a priori*: as características da população e a magnitude da misspecificação são estabelecidas antes do acesso aos dados empíricos utilizados nas seções subsequentes.

Além da estrutura fatorial, as simulações incorporam duas condições frequentemente encontradas em aplicações reais da AFC: não normalidade e dados ausentes. A distribuição dos indicadores admite assimetrias entre -1 e $+1$ e valores de curtose entre aproximadamente 1,7 e 2,0, representando desvios moderados da normalidade compatíveis com resultados anteriores obtidos com o WHOQOL-Bref (Yoshitake et al., 2015).

Também se pressupõe que 10% das respostas estejam ausentes segundo um mecanismo completamente ao acaso (*Missing Completely at Random* — MCAR). A adoção desse mecanismo permite representar a perda de informação decorrente dos dados ausentes sem exigir a formulação adicional de um padrão prospectivo de ausência dependente de variáveis observadas. Em todas as condições, os modelos são estimados por MLR, enquanto os dados ausentes são tratados por FIML. A Tabela 1 sintetiza essas decisões.

Tabela 1: Pressupostos da análise de poder a priori.

Componente	Especificação	Base
Modelo de referência	Quatro fatores correlacionados e covariância residual Q3–Q4	Lin e Yao (2022)
Misspecificação	Omissão de três cargas cruzadas	Mosqueira-Taipe et al. (2026)
Não normalidade	Assimetria de -1 a +1; curtose entre 1,7 e 2,0	Yoshitake et al. (2015)
Dados ausentes	10% MCAR	Mosqueira-Taipe et al. (2026)
Estimação	MLR + FIML	Cenário realístico
Erro tipo I	0.05	Definido a priori
Poder-alvo	0.80	Definido a priori

4.2 Abordagem analítica de poder

A primeira estimativa do tamanho amostral é obtida pelo método analítico baseado em modelos. Nessa análise, a estrutura populacional contém as três cargas cruzadas, enquanto o modelo submetido ao teste mantém apenas as cargas principais e a covariância residual entre Q3 e Q4. Assim, a magnitude do efeito não é definida por um valor convencional de RMSEA ou por outra regra geral, mas pela discrepância entre a matriz de covariâncias populacional e as restrições impostas pelo modelo de análise (Moshagen & Bader, 2024).

Como não é especificado um segundo modelo livremente estimado para uma comparação aninhada, o procedimento avalia o ajuste global do modelo de análise em relação ao modelo saturado. Portanto, a hipótese testada não corresponde à comparação direta entre o modelo parcimonioso e o modelo livre com cargas cruzadas. Ela expressa a capacidade de rejeitar globalmente o modelo que omite as relações presentes na população.

Considerando nível de significância de 5% e poder desejado de 80%, o método analítico indicou um tamanho amostral mínimo de 106 participantes. Esse valor é utilizado como ponto de partida para a etapa de simulação, e não como recomendação amostral definitiva.

A Tabela 2 reúne as medidas da análise e o tamanho amostral necessário para alcançar o poder desejado.

Tabela 2: Resultados da análise analítica de poder baseada nos modelos.

Medida	Símbolo	Valor
Discrepância populacional	F_0	0.579
Raiz do erro quadrático médio de aproximação	RMSEA	0.049
Índice de centralidade de McDonald	Mc	0.749
Índice de qualidade do ajuste	GFI	0.954
Índice de qualidade do ajuste ajustado	AGFI	0.944
Raiz do resíduo quadrático médio padronizado	SRMR	0.067
Índice de ajuste comparativo	CFI	0.960
Graus de liberdade	df	245
Tamanho amostral necessário	N	106
Qui-quadrado crítico	χ^2_{crit}	282.511
Parâmetro de não centralidade	λ	60.793
Nível de significância (alfa)	α	0.050
Erro tipo II (beta)	β	0.1968
Poder estatístico	$1 - \beta$	0.8032

A Figura 4 apresenta as distribuições central e não central do qui-quadrado. A distribuição sob a hipótese nula representa o comportamento esperado da estatística quando as restrições do modelo são adequadas, enquanto a distribuição não central representa o comportamento esperado diante da discrepância populacional especificada. A região de rejeição e a sobreposição entre as duas distribuições permitem visualizar conjuntamente o erro tipo I e o poder estatístico.

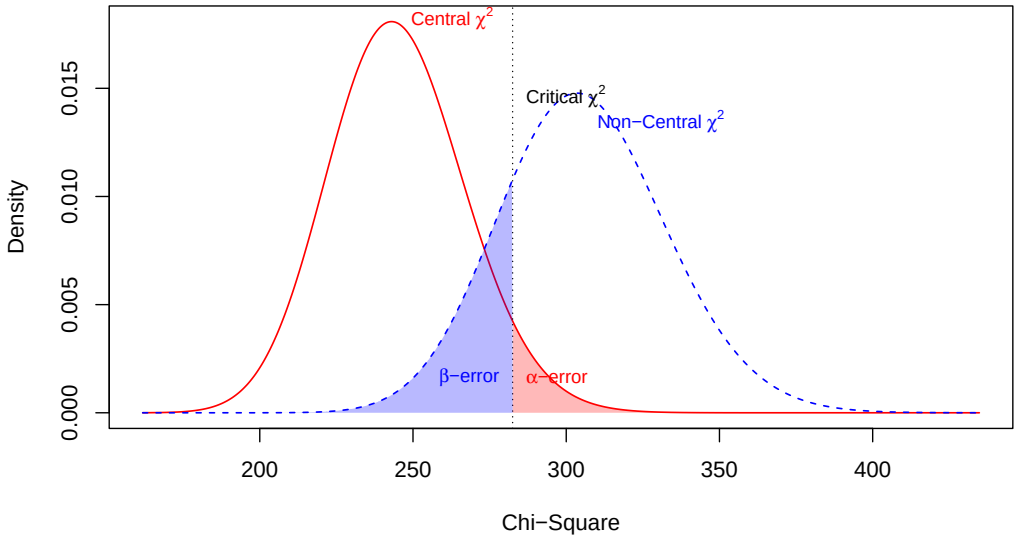


Figura 4: Distribuições central e não central do qui-quadrado na análise analítica de poder baseada nos modelos.

4.3 SMC com tamanho amostral variável

Embora a abordagem analítica forneça um ponto de partida objetivo, ela não representa integralmente as condições realísticas previstas na literatura. Por esse motivo, a etapa seguinte utiliza uma SMC que combina não normalidade moderada e 10% de dados ausentes MCAR, mantendo a estimação por MLR com tratamento dos dados ausentes por FIML.

Os tamanhos amostrais variam de 101 a 400 participantes. Em cada tamanho, são realizadas dez replicações sob duas condições populacionais. Na condição de referência, os dados seguem a estrutura de quatro fatores sem cargas cruzadas. Na condição alternativa, os dados são gerados com as três cargas cruzadas, mas analisados pelo modelo que as omite. A comparação entre essas condições permite estimar a capacidade de RMSEA, SRMR, CFI e TLI para identificar a misspecificação previamente definida.

Duas representações das relações entre tamanho amostral e poder são apresentadas. A primeira utiliza suavização logística para representar a tendência geral de crescimento do poder ao longo da faixa amostral (Figura 5). A segunda mostra diretamente as proporções de rejeição observadas nas replicações realizadas em cada tamanho (Figura 6).

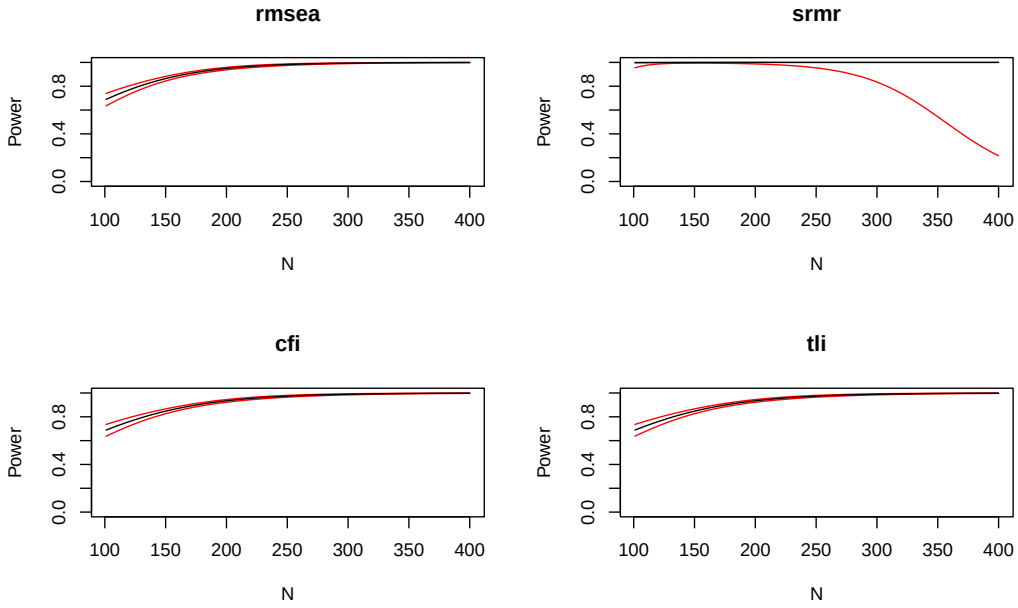


Figura 5: Curvas de poder com suavização logística sob não normalidade leve e 10% de dados ausentes MCAR.

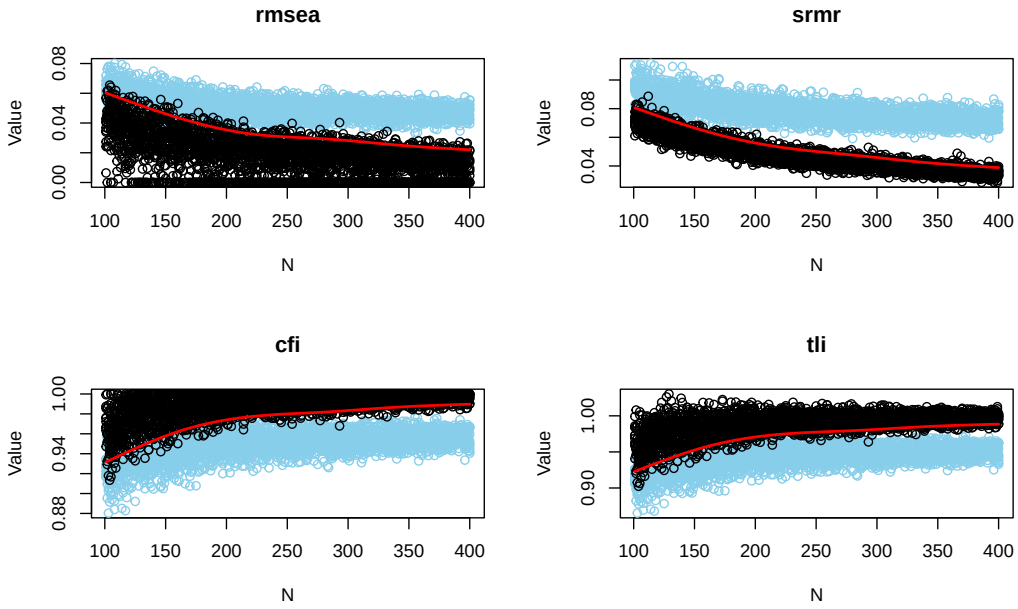


Figura 6: Poder empírico sem suavização logística sob não normalidade leve e 10% de dados ausentes MCAR.

As curvas apresentadas em Figura 5 e Figura 6 sugerem que uma amostra próxima de 150 participantes pode ser suficiente para que os índices globais detectem a omissão das cargas cruzadas. O poder e os pontos de corte empíricos são, então, calculados

especificamente para $N = 150$. Essa avaliação permite verificar se o tamanho indicado visualmente pelas curvas oferece desempenho consistente entre os quatro índices ou se permanece excessivamente próximo do limite adotado.

Tabela 3: Poder e pontos de corte calibrados pelo modelo para N = 150.

	RMSEA	SRMR	CFI	TLI
Poder	0.864	0.999	0.847	0.847
Ponto de corte	0.046	0.068	0.957	0.951

Em $N = 150$, o poder estimado foi de 0.864 para o RMSEA, 0.999 para o SRMR, 0.847 para o CFI e 0.847 para o TLI.

Entretanto, essa primeira simulação examina somente a capacidade dos índices globais de ajuste para detectar a misspecificação. Ela não avalia recuperação das cargas fatoriais, viés absoluto ou relativo dos parâmetros, viés dos erros-padrão, cobertura dos intervalos de confiança ou poder de parâmetros individuais. Assim, uma amostra que pareça suficiente para o teste global não necessariamente garante precisão adequada para todos os parâmetros do modelo (Feng & Hancock, 2023; Pornprasertmanit et al., 2022).

4.4 SMC com tamanho amostral fixo

Diante da possibilidade de que 150 participantes representem uma solução limítrofe, adota-se $N = 200$ como tamanho amostral de planejamento. Essa decisão não constitui uma regra universal para AFC. Trata-se de uma escolha prudencial que considera, simultaneamente, os resultados das curvas de poder, a complexidade do modelo de medida, as condições não ideais de distribuição e missing e a ausência, neste tutorial, de uma avaliação completa da recuperação dos parâmetros.

A análise com tamanho amostral fixo utiliza 1.000 replicações para cada condição populacional. Na primeira, são gerados dados de acordo com o modelo de referência. Na segunda, os dados são gerados sob a estrutura que contém as três cargas cruzadas, mas continuam sendo analisados pelo modelo que as omite. Diferentemente da etapa anterior, na qual dez replicações foram distribuídas em cada um dos diversos tamanhos amostrais, esta etapa concentra todas as 1.000 replicações em $N = 200$. Isso permite obter estimativas mais estáveis do poder e das distribuições empíricas dos índices de ajuste nesse tamanho específico.

Como o tamanho amostral permanece constante, não é necessária uma suavização logística. A Figura 7 mostra diretamente o comportamento empírico dos índices nas duas condições populacionais. A separação entre as distribuições é a representação gráfica da capacidade de identificar a misspecificação.

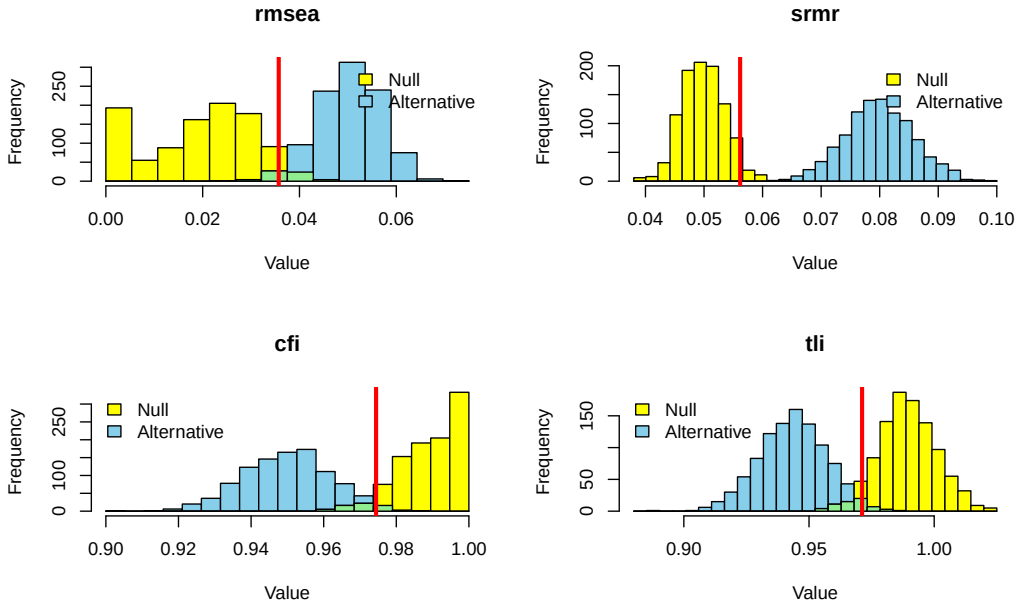


Figura 7: Distribuições empíricas dos índices de ajuste em 1.000 replicações com N = 200.

Em seguida, são calculados o poder de detecção da misspecificação e os pontos de corte correspondentes a RMSEA, SRMR, CFI e TLI. Esses pontos são derivados da distribuição dos índices quando o modelo está corretamente especificado, considerando simultaneamente o tamanho amostral, a não normalidade, o percentual de dados ausentes e o método de estimação. A Tabela 4 apresenta os resultados para $N = 200$.

Tabela 4: Poder e pontos de corte calibrados pelo modelo em 1.000 replicações com N = 200.

	RMSEA	SRMR	CFI	TLI
Poder	0.984	1.000	0.982	0.982
Ponto de corte	0.036	0.056	0.974	0.971

4.5 Comparação com pontos de corte tradicionais

Finalmente, o desempenho dos pontos de corte calibrados é comparado ao desempenho dos limites tradicionalmente utilizados para interpretar o ajuste global. Para RMSEA e SRMR, a rejeição ocorre quando os valores ultrapassam os respectivos limites; para CFI e TLI, ocorre quando os valores ficam abaixo deles.

A mesma simulação com tamanho amostral fixo é reavaliada, mantendo constantes o tamanho amostral, os modelos de geração e análise e todas as características dos dados. Apenas o critério de decisão é alterado. A Figura 8 apresenta a classificação obtida com os pontos de corte tradicionais, e a Tabela 5 apresenta o poder resultante.

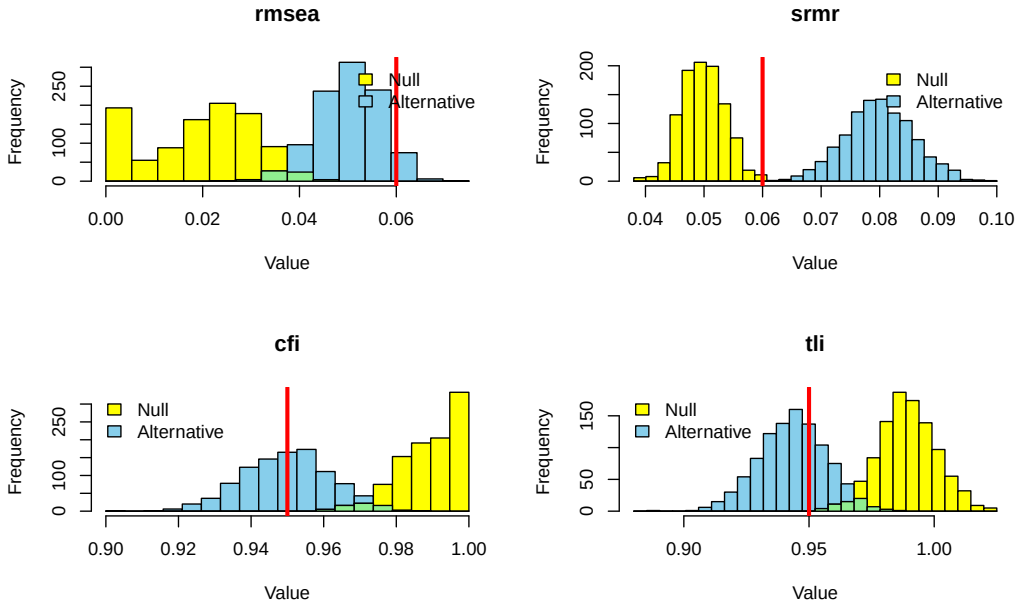


Figura 8: Distribuições dos índices de ajuste avaliadas por pontos de corte tradicionais em 1.000 replicações com N = 200.

Tabela 5: Poder obtido com pontos de corte tradicionais em 1.000 replicações com N = 200.

	CFI	TLI	RMSEA	SRMR
Poder	0.496	0.678	0.062	1

Com os pontos de corte tradicionais, o poder foi de 0.062 para o RMSEA, 1.000 para o SRMR, 0.496 para o CFI e 0.678 para o TLI.

Essa comparação permite verificar que os critérios tradicionais produzem conclusões completamente diferente às obtidas com as distribuições simuladas, com a sensibilidade para a misspecificação considerada considerávelmente distorcida (Groskurth et al., 2024; McNeish & Wolf, 2023).

Em conjunto, as três etapas cumprem funções complementares. A abordagem analítica oferece uma estimativa inicial baseada na discrepância populacional; a simulação com tamanho variável mostra como o poder evolui entre 101 e 400 participantes; e a simulação com 1.000 replicações em $N = 200$ fornece uma avaliação mais estável do planejamento amostral escolhido.

Os limites obtidos em $N = 200$ pertencem às condições desse planejamento: parâmetros populacionais definidos pela literatura, não normalidade moderada e 10% de ausências MCAR. Sua aplicação a uma amostra com outro tamanho, distribuições ou parâmetros requer uma calibração correspondente a essas condições. O resultado central dessa etapa é o desempenho esperado para detectar a omissão estipulada, condicionado ao cenário simulado.

5 Pré-processamento

O pré-processamento em questionários de autorelato tem como finalidade proteger as análises vindouras de vieses introduzidos por C/IER, registros incompletos ou com respostas inconsistentes, e a inspeção preliminar das variáveis para prospecção de problemas. Nas seções anteriores não precisamos dos dados coletados, mas a partir de agora, temos que fazer exercícios com dados brutos, e por isso, vamos utilizar a mesma base de dados empregada por Rogers (2024) e Rogers (2022).

Nesse tutorial, entretanto, o processamento parte dos 1.546 registros brutos e explicita tanto os critérios procedurais (*ex-ante*) quanto os indicadores estatísticos (*ex-post*) de triagem C/IER. Como os trabalhos anteriores (Rogers, 2022, 2024) partiram de uma base pré-processada de 1.047 participantes, eventuais diferenças entre seus resultados e os deste tutorial não devem ser atribuídas exclusivamente ao tratamento ordinal ou contínuo dos itens. Após a verificação da integridade do banco e a remoção de registros sem identificação ou com mais de cinco respostas ausentes na WHOQOL-Bref, a amostra elegível foi submetida a um protocolo sequencial de triagem C/IER. As respostas ausentes nos registros retidos foram preservadas para tratamento por FIML na estimação.

Para o tratamento dos indivíduos com C/IER adotou-se a abordagem de múltiplos obstáculos (*Multiple-hurdle Approach*) indicada por Curran (2016) e DeSimone et al. (2015). Como os índices de desatenção mensuram manifestações comportamentais distintas, como respostas aleatórias, padrões invariantes e preenchimento apressado, e podem apresentar correlações baixas ou nulas entre si (Biemann et al., 2025; Goldammer et al., 2020; Meade & Craig, 2012), a literatura recomenda a aplicação combinada de critérios de triagem (Arthur et al., 2021; Curran, 2016; Ulitzsch et al., 2022). No presente tutorial, cada critério foi tratado como uma barreira obrigatória, de modo que a falha em qualquer obstáculo determinou a exclusão do participante da amostra final (Curran, 2016; Goldammer et al., 2020).

5.1 Exclusões procedurais

No âmbito dos controles *ex-ante*, utilizamos itens de atenção inseridos no questionário e a duração total de preenchimento da pesquisa. (Curran, 2016; Ward & Meade, 2023). A falha em pelo menos dois dos três itens de atenção incluídos foi interpretada como evidência de C/IER (Chauliac et al., 2023; DeSimone et al., 2015). Também foram excluídos os questionários de indivíduos com velocidade inferior a quatro segundos por item, limiar adotado para sinalizar preenchimentos excessivamente rápidos nesta aplicação, dentro das referências de dois a quatro segundos por item discutidas na Seção 2.3.

5.2 Critérios estatísticos

Como critérios *ex-post* empregamos a medida de *Longstring*, o IRV e a Distância de Mahalanobis (Biemann et al., 2025; A. M. Dunn et al., 2018). O primeiro permite identificar padrões mecânicos de marcação uniforme; o segundo detecta tanto variabilidade anormalmente baixas quanto dispersão alta; e o terceiro identifica padrões multivariados distantes do comportamento normativo da amostra, condizentes com aleatoriedade excesiva (Curran, 2016; DeSimone et al., 2015; Hong et al., 2020; Meade & Craig, 2012). Considerou-se problemática uma sequência contínua (*Longstring*) superior a 13 respostas consecutivas, correspondente à metade dos 26 itens da WHOQOL-Bref

considerados na triagem; para o IRV, utilizaram-se os percentis 1% e 99%; e, para a Distância de Mahalanobis, o percentil 99%. As regras de triagem foram definidas com base na extensão da escala e nas caudas extremas das distribuições; os valores numéricos dos percentis foram calculados na amostra submetida aos critérios estatísticos, buscando equilibrar sensibilidade à desatenção e preservação de respondentes sinceros (Arthur et al., 2021; Goldammer et al., 2020; Steedle, 2018).

Tabela 6: Pontos de corte dos indicadores estatísticos.

Indicador	Média	Desvio-padrão	Mediana	1º percentil	99º percentil	Regra de exclusão
Longstring	5.216	2.734	4.000	2.000	15.000	longstring > 13
IRV	1.025	0.207	1.027	0.552	1.491	IRV p1 ou IRV p99
Distância de Mahalanobis	26.000	15.336	22.060	5.844	80.639	Mahalanobis p99

5.2.1 Decisão final e amostra de análise

Após o cálculo dos indicadores de atenção, velocidade, invariância e discrepância multivariada, cada participante foi avaliado simultaneamente nos cinco obstáculos definidos no protocolo. A decisão de exclusão foi aplicada de forma conservadora: a falha em qualquer uma das barreiras foi suficiente para classificar o respondente como incompatível com a amostra de análise. A Tabela 7 resume a frequência de sinalização em cada critério e permite avaliar quais manifestações de resposta descuidada foram mais comuns na amostra elegível. As sinalizações associadas aos itens de atenção e ao IRV foram as mais frequentes, enquanto o tempo de resposta apresentou menor incidência. Essa distribuição reforça a utilidade da estratégia de múltiplos obstáculos, pois os critérios não identificam exatamente os mesmos participantes nem representam uma única forma de comportamento inadequado.

Tabela 7: Frequência de falhas em cada obstáculo de limpeza.

Critério	N sinalizado	Percentual (%)
Itens de atenção	28	2.1
Tempo de resposta	8	0.6
Longstring	21	1.6
IRV	28	2.1
Distância de Mahalanobis	14	1.1

A aplicação conjunta dos cinco obstáculos produziu uma redução amostral de 1.546 para 1.243 participantes. Dos 1.546 registros brutos, 223 foram removidos na etapa preliminar por não apresentarem condições mínimas de utilização da escala. Entre os 1.323 respondentes elegíveis aos obstáculos, 80 falharam em pelo menos um critério e foram excluídos da análise. Essa trajetória mostra que a maior redução ocorreu antes da aplicação dos indicadores de C/IER, enquanto a triagem comportamental posterior

produziu uma exclusão proporcionalmente menor e concentrada em padrões considerados incompatíveis com a resposta cuidadosa. A Tabela 8 apresenta essa trajetória.

Tabela 8: Trajetória da amostra durante o pré-processamento.

Etapa	N
Banco bruto	1546
Dropouts removidos	223
Elegíveis aos obstáculos	1323
Excluídos por pelo menos um obstáculo	80
Amostra analítica final	1243

5.3 Descrição dos itens

Com a amostra de análise definida, a etapa seguinte consistiu em avaliar o comportamento empírico dos itens que serão utilizados na AFC. Essa descrição deve ser utilizada para verificar a quantidade de respostas disponíveis, a tendência central, a dispersão e a forma das distribuições, fornecendo informações para a escolha do procedimento de estimação, por exemplo. Em geral, os itens apresentaram médias acima do ponto médio da escala e dispersão suficiente para preservar diferenças individuais nas respostas. A quantidade de respostas válidas variou entre os itens, porém com baixissima incidência, razão para não eliminar participantes que permanecem elegíveis para a análise. Esses resultados são apresentados na Tabela 9.

Tabela 9: Estatísticas descritivas dos itens utilizados na AFC.

Item	Respostas válidas	Média	Desvio-padrão	Assimetria	Curtose	VIF
Q3	1242	4.136	0.941	-0.910	0.076	1.624
Q4	1241	4.089	1.009	-0.983	0.183	1.473
Q5	1230	3.283	0.818	-0.472	-0.008	2.140
Q6	1238	3.895	0.974	-0.871	0.534	1.752
Q7	1241	3.586	0.858	-0.489	0.059	1.706
Q8	1240	2.933	0.979	-0.098	-0.459	1.317
Q9	1239	3.471	0.884	-0.569	0.216	1.475
Q10	1241	3.587	0.903	-0.164	-0.368	2.226
Q11	1241	3.798	0.996	-0.615	-0.087	1.611
Q12	1242	3.414	1.099	-0.241	-0.530	1.825
Q13	1243	3.896	0.828	-0.570	0.235	1.545
Q14	1240	3.331	0.956	-0.281	-0.245	1.927
Q15	1243	4.398	0.807	-1.513	2.455	1.504
Q16	1232	3.485	1.035	-0.124	-1.165	1.430
Q17	1242	3.711	0.921	-0.504	-0.538	3.689
Q18	1243	3.730	0.955	-0.488	-0.659	3.247
Q19	1240	3.691	0.942	-0.400	-0.706	2.661
Q20	1239	3.608	0.891	-0.237	-0.674	1.893
Q21	1242	3.420	1.009	-0.003	-1.111	1.316
Q22	1241	3.554	0.884	-0.131	-0.703	1.730
Q23	1237	3.973	0.949	-0.686	-0.413	1.392

Tabela 9: Estatísticas descritivas dos itens utilizados na AFC.

Item	Respostas válidas	Média	Desvio-padrão	Assimetria	Curtose	VIF
Q24	1242	3.725	0.963	-0.400	-0.771	1.389
Q25	1241	3.821	0.978	-0.489	-0.737	1.402
Q26	1243	3.891	0.930	-1.160	1.535	1.559

A Tabela 9 também permite avaliar a distribuições dos itens. A assimetria é predominantemente negativa, especialmente nos itens com maior concentração nas categorias superiores, enquanto alguns itens apresentam valores de curtose mais elevados. Esses resultados são compatíveis com o padrão esperado para respostas Likert, nas quais a limitação do número de categorias e a concentração das respostas podem produzir desvios da normalidade multivariada. Por essa razão, a estimação subsequente deve utilizar uma abordagem robusta, capaz de ajustar erros-padrão e estatísticas de teste diante de desvios moderados da normalidade (Li, 2016a, 2016b).

A presença de respostas ausentes em alguns itens também deve ser considerada no processo de estimação. Como os participantes não foram excluídos apenas por apresentarem um ou poucos valores ausentes em itens específicos, a análise deve preservar as informações observadas e utilizar o procedimento FIML (Lai, 2021b; Lei & Shiverdecker, 2020). Dessa forma, os valores disponíveis de cada respondente podem contribuir para a estimação sem recorrer à exclusão *listwise* de todos os casos que apresentem qualquer ausência.

A coluna de VIF complementa a descrição das variáveis ao avaliar possível redundância linear entre os indicadores. Os valores observados permanecem abaixo do limite de referência de 5 (T. Kyriazos & Poga, 2023), indicando que não há evidência de multicolinearidade severa entre os itens empregados na AFC. Esse resultado é importante porque sugere que a matriz de informação não deve ser comprometida por colinearidade elevada.

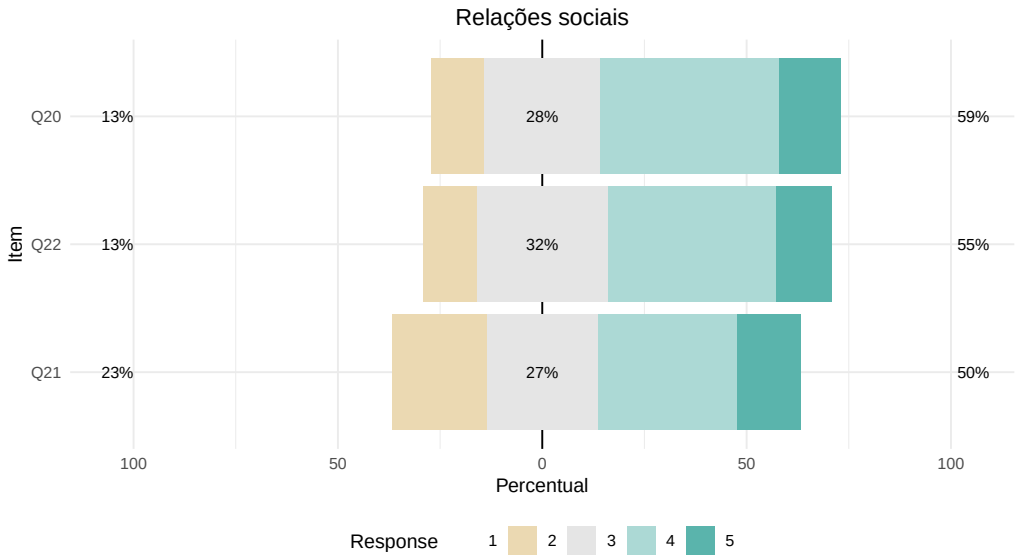


Figura 9: Distribuição das categorias de resposta Likert no construto Relações sociais.

A Figura 9 apresenta, como exemplo, a distribuição das respostas nos itens do construto Relações sociais. O gráfico permite visualizar simultaneamente a concentração das respostas, a presença de categorias menos utilizadas e a assimetria relativa de cada item. Observa-se maior concentração nas categorias superiores da escala, especialmente nas respostas 4 e 5, padrão coerente com as médias positivas observadas na descrição dos itens.

6 Processo de estimação

Depois da seleção dos modelos e do pré-processamento, essa seção estima as duas especificações da AFC na amostra de calibração. A estimação converte as relações previstas nos modelos em parâmetros amostrais e aplica as condições definidas nas etapas anteriores: tratamento contínuo dos itens, MLR, FIML e identificação pela variância dos fatores (Jackson et al., 2009; Nye, 2022).

Os 1.243 participantes da amostra analítica foram divididos aleatoriamente em duas parcelas: 621 para calibração e 622 para validação. A divisão foi estratificada pela presença de respostas ausentes nos 24 indicadores, distribuindo os 60 participantes com alguma ausência igualmente entre as parcelas. A calibração é utilizada para estimar os modelos e examinar seus diagnósticos; a validação é reservada à avaliação da especificação selecionada.

6.1 Fundamentação da estimação

Os itens foram tratados como variáveis contínuas, conforme a justificativa desenvolvida na Seção 2.4. Segundo Rhemtulla et al. (2012), a MLR apresenta desempenho adequado em condições com cinco ou mais categorias, especialmente com limiares aproximadamente simétricos. Robitzsch (2020) e Robitzsch (2022) mostram que as abordagens contínua e ordinal definem alvos paramétricos distintos. Com cinco categorias e uma estrutura fatorial previamente definida, esse estudo adota a formulação contínua como aproximação de mensuração.

O método MLR foi mantido porque combina a máxima verossimilhança com erros-padrão robustos e estatística de teste escalada. Essa combinação é adequada às distribuições observadas na etapa de pré-processamento e segue a recomendação da literatura para situações de não normalidade multivariada (Brown, 2015; Kline, 2023; Rogers, 2024).

As poucas respostas ausentes foram incorporadas por FIML. O procedimento utiliza a informação observada de cada participante e mantém os 621 casos da amostra de calibração. A escolha segue a recomendação de tratar ausências na etapa de estimação quando se trabalha com ML ou suas variantes robustas (Brown, 2023; Kline, 2023).

A escala dos fatores foi definida pela fixação de suas variâncias em 1. Essa identificação permite estimar livremente as cargas fatoriais e estabelece a mesma métrica latente nos dois modelos. As duas especificações foram estimadas na mesma parcela de calibração e sob as mesmas condições. A comparação concentra-se, assim, nas três relações adicionais do modelo H_1 (Jackson et al., 2009; Nye, 2022).

6.2 Parâmetros estimados

Antes da avaliação do ajuste, a Tabela 10 apresenta os parâmetros fatoriais estimados. Para cada relação entre fator e item, a tabela reúne a carga não padronizada, o erro-padrão robusto, a estatística de teste e a carga padronizada, conforme recomendado por Jackson et al. (2009) e Nye (2022).

As cargas não padronizadas preservam a métrica do modelo. As cargas padronizadas permitem comparar a magnitude das relações dentro de cada especificação, e os erros-padrão refletem a inferência robusta do MLR.

A tabela inclui os dois modelos e mostra as três relações adicionais do H_1 junto das cargas primárias. A avaliação dessas relações combina os parâmetros estimados com os índices de ajuste e os critérios de comparação dos modelos.

Tabela 10: Parâmetros fatoriais estimados nos modelos H_0 e H_1.

Modelo	Relação	Estimativa	EP	z	Padronizada
H0	psycho =~ Q5	0.523	0.033	15.774	0.639
H0	psycho =~ Q6	0.591	0.042	13.918	0.597
H0	psycho =~ Q7	0.561	0.031	18.139	0.653
H0	psycho =~ Q11	0.639	0.040	16.047	0.637
H0	psycho =~ Q19	0.764	0.033	23.296	0.798
H0	psycho =~ Q26	0.559	0.041	13.789	0.585
H0	physical =~ Q3	0.435	0.043	10.079	0.459
H0	physical =~ Q4	0.435	0.046	9.528	0.429
H0	physical =~ Q10	0.681	0.033	20.662	0.729
H0	physical =~ Q15	0.437	0.042	10.497	0.511
H0	physical =~ Q16	0.585	0.037	15.689	0.568
H0	physical =~ Q17	0.838	0.027	30.776	0.907
H0	physical =~ Q18	0.830	0.029	28.401	0.851
H0	social =~ Q20	0.711	0.033	21.654	0.806
H0	social =~ Q21	0.485	0.044	10.996	0.481
H0	social =~ Q22	0.637	0.035	18.180	0.727
H0	environment =~ Q8	0.448	0.041	10.919	0.455
H0	environment =~ Q9	0.453	0.037	12.206	0.529
H0	environment =~ Q12	0.751	0.041	18.249	0.688
H0	environment =~ Q13	0.508	0.038	13.259	0.624
H0	environment =~ Q14	0.631	0.039	16.006	0.667
H0	environment =~ Q23	0.525	0.041	12.939	0.535
H0	environment =~ Q24	0.455	0.042	10.814	0.478
H0	environment =~ Q25	0.491	0.043	11.407	0.504
H1	psycho =~ Q5	0.523	0.033	15.708	0.639
H1	psycho =~ Q6	0.593	0.043	13.923	0.600
H1	psycho =~ Q7	0.564	0.031	18.087	0.656
H1	psycho =~ Q11	0.640	0.040	16.068	0.639
H1	psycho =~ Q19	0.764	0.033	23.193	0.798
H1	psycho =~ Q26	0.559	0.041	13.779	0.585
H1	psycho =~ Q8	0.190	0.071	2.693	0.193
H1	psycho =~ Q9	0.126	0.056	2.235	0.147

Tabela 10: Parâmetros fatoriais estimados nos modelos H_0 e H_1.

Modelo	Relação	Estimativa	EP	z	Padronizada
H1	physical =~ Q3	0.427	0.043	9.991	0.451
H1	physical =~ Q4	0.430	0.046	9.432	0.424
H1	physical =~ Q10	0.676	0.033	20.293	0.722
H1	physical =~ Q15	0.253	0.049	5.206	0.296
H1	physical =~ Q16	0.584	0.037	15.638	0.568
H1	physical =~ Q17	0.846	0.027	31.669	0.915
H1	physical =~ Q18	0.834	0.029	29.055	0.855
H1	social =~ Q20	0.712	0.033	21.677	0.806
H1	social =~ Q21	0.485	0.044	10.998	0.480
H1	social =~ Q22	0.636	0.035	18.134	0.726
H1	environment =~ Q8	0.282	0.070	4.027	0.286
H1	environment =~ Q9	0.346	0.060	5.810	0.404
H1	environment =~ Q12	0.762	0.040	18.882	0.698
H1	environment =~ Q13	0.518	0.038	13.527	0.637
H1	environment =~ Q14	0.639	0.039	16.324	0.676
H1	environment =~ Q23	0.522	0.041	12.807	0.532
H1	environment =~ Q24	0.457	0.042	10.795	0.481
H1	environment =~ Q25	0.494	0.044	11.329	0.508
H1	environment =~ Q15	0.301	0.051	5.865	0.352

6.3 Convergência e admissibilidade

Convergência e admissibilidade encerram a etapa de estimação. A convergência indica que o algoritmo encontrou uma solução para o modelo especificado. A admissibilidade é examinada pelas variâncias negativas e pelas cargas padronizadas superiores a 1, diagnósticos associados a soluções Heywood (Brown, 2015; Nye, 2022). A Tabela 11 reúne essas verificações para H_0 e H_1 e registra o tamanho amostral e o número de parâmetros livres.

Na amostra de calibração, os dois modelos convergiram, não apresentaram variâncias negativas e não produziram cargas padronizadas superiores a 1. As soluções estão prontas para a avaliação do ajuste global e local.

Tabela 11: Verificações de convergência e admissibilidade das soluções estimadas.

Modelo	N observado	Parâmetros livres	Convergência	Variâncias negativas	Cargas padronizadas > 1
H0	621	79	Sim	0	0
H1	621	82	Sim	0	0

7 Ajuste do modelo

7.1 Ajuste global dos modelos originais

O ajuste global avalia em que medida as relações especificadas reproduzem a estrutura de covariâncias dos indicadores. Conforme a Seção 2.5, sua avaliação combina o teste de ajuste exato e índices que descrevem a magnitude do desajuste.

A Tabela 12 apresenta os resultados de H_0 e H_1 para os mesmos 621 participantes da amostra de calibração. O ^{2} e seu valor de p correspondem ao teste ajustado; CFI, TLI e RMSEA são apresentados nas versões robustas, incluindo os limites robustos do intervalo do RMSEA. O SRMR acompanha essas medidas como resumo adicional. A leitura conjunta dos indicadores orienta a avaliação das especificações originais (Mai et al., 2021; Niemand & Mai, 2018).

Tabela 12: Ajuste global dos modelos originais H_0 e H_1, estimados por MLR/FIML.

Medida	H0	H1
N	621	621
χ^2 ajust.	764.651	712.025
df	245	242
p-valor	< 0.001	< 0.001
CFI (robusto)	0.895	0.905
TLI (robusto)	0.882	0.892
RMSEA (robusto)	0.063	0.060
RMSEA IC90% inf.	0.058	0.055
RMSEA IC90% sup.	0.068	0.066
p (RMSEA $\leq$ 0,05)	< 0.001	< 0.001
SRMR	0.054	0.050

Os resultados da Tabela 12 mostram limitações de ajuste nas duas especificações. O teste de ajuste exato foi significativo em H_0, $^2(245) = 764{,}651$ (p <0,001), e em H_1, $^2(242) = 712{,}025$ (p <0,001). O teste ^{2} é sensível ao tamanho amostral e pode detectar discrepâncias de pequena magnitude. Sua interpretação é complementada pelos demais índices (Nye, 2022; West et al., 2023).

Os índices incrementais constituem o principal sinal de fragilidade nesta avaliação inicial. Em H_0, CFI e TLI robustos foram, respectivamente, 0,895 e 0,882; em H_1, foram 0,905 e 0,892. Esses valores mostram ganho limitado de ajuste em relação ao modelo de referência. O RMSEA robusto foi 0,063 (IC de 90%: 0,058–0,068) em H_0 e 0,060 (IC de 90%: 0,055–0,066) em H_1, com magnitudes próximas à referência convencional de 0,06.

O SRMR apresentou um resultado mais favorável, com 0,054 em H_0 e 0,050 em H_1. A menor magnitude média dos resíduos padronizados pode coexistir com dificuldades em relações específicas, que serão examinadas no diagnóstico local. Essa diferença entre os sinais dos índices reforça a necessidade de interpretá-los conjuntamente (Mai et al., 2021; Niemand & Mai, 2018).

H_1 apresenta índices descritivamente mais favoráveis, com melhora pequena em relação a H_0. As limitações dos índices incrementais permanecem nas duas especificações, apesar dos resultados mais favoráveis de RMSEA e SRMR. A avaliação por simulação

complementa essa leitura com referências para as condições da amostra de calibração, conforme a estratégia discutida na Seção 2.5. O diagnóstico local examina as relações em que se concentram as discrepâncias e orienta sua interpretação substantiva.

7.2 Confiabilidade dos escores

A confiabilidade expressa a precisão de um escore sob determinadas condições de mensuração. O ômega é a medida principal, calculada a partir dos parâmetros fatoriais e da variância observada do escore. Essa avaliação complementa o ajuste global e depende da adequação da especificação utilizada (Cho, 2022; Flora, 2020).

A Tabela 13 apresenta o ômega e o GLB para os quatro domínios em H_0 e H_1. Em H_1, o escore psicológico inclui também Q8 e Q9, e o ambiental inclui Q15, passando a oito e nove itens, respectivamente. Os demais escores mantêm sua composição. O GLB é calculado separadamente a partir da matriz observada recuperada de cada ajuste, permitindo verificar a correspondência dos resultados. Sua formulação algébrica pressupõe erros não correlacionados e pode apresentar viés amostral para cima; portanto, sua interpretação difere da confiabilidade baseada no modelo que inclui a covariância residual Q3–Q4 (Trizano-Hermosilla & Alvarado, 2016).

Tabela 13: Confiabilidade dos escores de domínio conforme a composição em H_0 e H_1

Modelo	Fator	Itens	Ômega	GLB
H0	psycho	6	0.807	0.844
H0	physical	7	0.800	0.883
H0	social	3	0.707	0.700
H0	environment	8	0.781	0.836
H1	psycho	8	0.643	0.858
H1	physical	7	0.729	0.883
H1	social	3	0.707	0.700
H1	environment	9	0.673	0.851

No modelo de interesse H_0, os coeficientes dos quatro domínios ficaram próximos ou acima da referência convencional de 0,70, com os menores valores no domínio social. Em H_1, o ômega dos escores psicológico e ambiental ficou abaixo dessa referência. A interpretação dessas diferenças deve considerar a ampliação dos dois escores, além da mudança na especificação fatorial. A confiabilidade dos escores complementa a avaliação do modelo e não resolve as limitações de ajuste global identificadas anteriormente.

7.3 Distribuições dos índices sob os modelos empíricos

A AP utilizou parâmetros populacionais definidos a partir da literatura e de pressupostos de planejamento. Após a estimação, as cargas e as correlações observadas diferiram dessas condições. A avaliação por simulação foi, portanto, parametrizada pelos ajustes empíricos, preservando a estrutura dos modelos e incorporando o tamanho amostral e as características distributivas consideradas na análise atual (Leite et al., 2023; Moshagen & Bader, 2024). Os limites do planejamento em $N = 200$ são, portanto, recalculados para os 621 participantes da calibração, com parâmetros estimados, distribuições marginais

e padrão de ausências dessa parcela. Essa mudança desloca a pergunta do tamanho amostral necessário para o comportamento esperado dos índices nas condições empíricas.

Os parâmetros estimados definem populações geradoras hipotéticas. Sob a primeira condição, os dados são gerados e analisados segundo H_0, fornecendo a distribuição de referência dos índices quando suas restrições são satisfeitas. Sob a segunda, os dados são gerados segundo H_1 e analisados por H_0, permitindo avaliar a sensibilidade dos índices à omissão das três cargas cruzadas previamente consideradas. A forma desse contraste mantém continuidade com o planejamento, enquanto suas magnitudes são atualizadas pelas estimativas empíricas.

A avaliação reúne o posicionamento dos índices observados de H_0 diante de sua referência e a sensibilidade dessa referência à alternativa especificada. Os cortes derivados dos quantis sob H_0 correspondem à referência de ajuste exato; a condição alternativa permite examinar sua capacidade de detectar a omissão escolhida. Esse procedimento utiliza uma alternativa estrutural específica, com as três cargas cruzadas, enquanto o 3DFI apresentado na Seção 2.5 gera perturbações aleatórias na matriz de correlações, com magnitude estipulada por MAD (McNeish & Wolf, 2024). As conclusões são condicionadas aos parâmetros e às condições simuladas. As estimativas utilizadas nos geradores permanecem fixas entre replicações; a simulação reproduz a variabilidade amostral sob essas estimativas. Trata-se de uma avaliação condicional baseada na mesma parcela de calibração utilizada para estimar os parâmetros. O diagnóstico local complementa a avaliação, examinando discrepâncias que o contraste escolhido pode não representar.

São consideradas 1.000 replicações de 621 participantes em cada condição. A geração incorpora as assimetrias e curtoses marginais observadas e repete o padrão de células ausentes da calibração. A estimação mantém MLR/FIML. A Figura 10 apresenta as distribuições de RMSEA, CFI e TLI robustos, acompanhados do SRMR, preservando as medidas utilizadas na Tabela 12. A concentração de CFI e TLI próximos de 1 é esperada sob a condição em que o modelo ajustado corresponde à estrutura geradora; essa referência permite avaliar o afastamento dos valores observados.

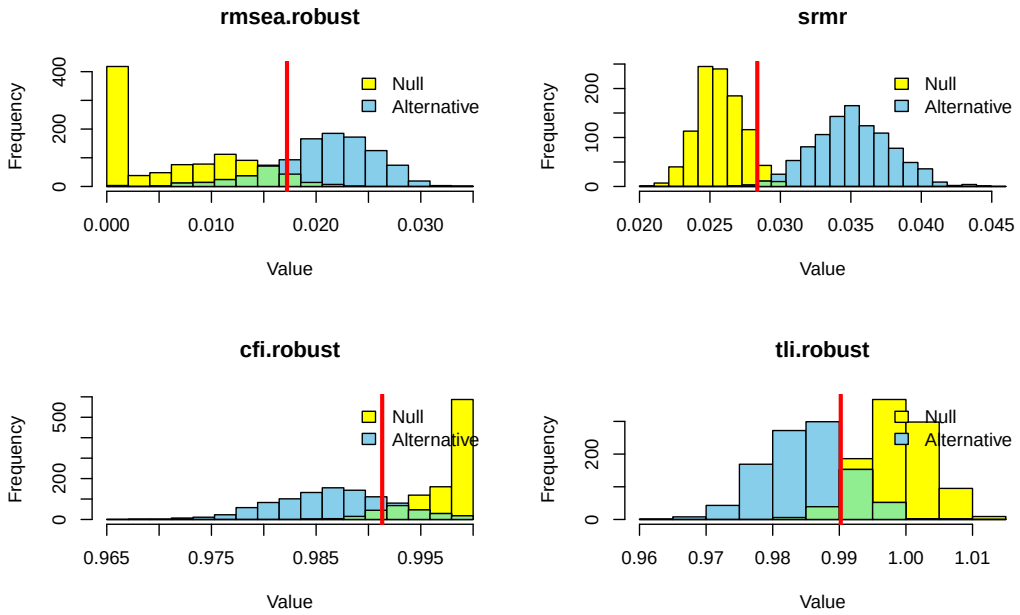


Figura 10: Distribuições de RMSEA, CFI e TLI robustos e SRMR em 1.000 replicações na amostra de calibração: geração sob H ou H e ajuste de H nas duas condições. H inclui as três cargas cruzadas omitidas pelo modelo de análise. As linhas vermelhas indicam os cortes sob H com = 0,05: percentil 95 para RMSEA/SRMR e percentil 5 para CFI/TLI.

A Figura 10 permite comparar as distribuições sob H_0 e sob a condição em que as três cargas cruzadas estão presentes na população, mas são omitidas pelo modelo de análise. Com referência nominal de erro Tipo I de 5%, os limites superiores são 0,017 para RMSEA e 0,028 para SRMR; os limites inferiores são 0,991 para CFI e 0,990 para TLI. Aplicados à condição alternativa, esses cortes fornecem estimativas de poder de 80,7%, 99,6%, 80,1% e 80,1%, respectivamente. Esses valores expressam a capacidade de detectar a omissão das cargas cruzadas nas condições simuladas.

Nos dados observados, H_0 apresentou RMSEA de 0,063 e SRMR de 0,054, enquanto CFI e TLI foram 0,895 e 0,882. O posicionamento desses valores diante dos limites simulados permite avaliar o afastamento da referência de ajuste exato. A capacidade de detectar a alternativa simulada não identifica a origem do desajuste observado nem demonstra que ele decorra especificamente das três cargas cruzadas. Esses resultados fundamentam a investigação local das discrepâncias e sua interpretação à luz da teoria, da magnitude dos problemas e dos precedentes bibliográficos.

7.4 Diagnóstico local

O diagnóstico local identifica relações que contribuem para as discrepâncias globais. A leitura combina os parâmetros fatoriais apresentados na Tabela 10, os MI, os EPC e os resíduos de correlação, conforme a Seção 2.5. A avaliação local concentra-se em H_0, o modelo de análise que orientará os encaminhamentos.

7.4.1 Índices de modificação e mudanças esperadas

O MI estima a redução da estatística de ajuste ao liberar individualmente um parâmetro fixado. O EPC expressa a mudança esperada nesse parâmetro, e sua versão padronizada auxilia a avaliação da magnitude. Essas aproximações devem ser consideradas junto das cargas, dos resíduos e do significado substantivo da relação (Nye, 2022). A Tabela 14 reúne os vinte maiores MI de H_0 e seus EPC correspondentes.

Tabela 14: Vinte maiores índices de modificação de H_0, com EPC bruto e padronizado.

Relação	MI	EPC	EPC padronizado
Q17 ~~ Q18	82.261	0.158	0.794
Q5 ~~ Q14	62.470	0.159	0.358
environment =~ Q5	48.605	0.362	0.442
environment =~ Q15	48.113	0.313	0.366
psycho =~ Q10	41.600	0.552	0.591
Q24 ~~ Q25	34.822	0.179	0.256
Q3 ~~ Q15	30.427	0.125	0.202
psycho =~ Q17	26.402	-0.408	-0.442
Q10 ~~ Q18	26.359	-0.088	-0.269
Q5 ~~ Q6	25.744	0.111	0.223
psycho =~ Q24	25.655	-0.324	-0.341
Q15 ~~ Q17	23.512	-0.076	-0.267
Q23 ~~ Q25	23.341	0.148	0.213
Q11 ~~ Q10	21.303	0.100	0.202
environment =~ Q17	20.282	-0.155	-0.167
physical =~ Q5	20.123	-0.377	-0.460
Q19 ~~ Q18	20.050	0.068	0.230
Q12 ~~ Q23	19.257	-0.139	-0.211
social =~ Q23	18.360	0.225	0.229
environment =~ Q10	18.223	0.177	0.189

7.4.2 Resíduos de correlação

Os resíduos de correlação mostram quanto cada associação entre indicadores é subestimada ou superestimada pelo modelo. Sua magnitude permite localizar discrepâncias que podem ficar diluídas nos índices globais (Crede & Harms, 2019; Nye, 2022).

A Figura 11 apresenta os resíduos de H_0, com os itens na ordem do modelo de análise. A intensidade da cor representa o valor absoluto do resíduo; os números preservam o sinal. Cada par aparece uma única vez. A referência de magnitude absoluta de 0,10 discutida na Seção 2.5 orienta a inspeção conjunta com MI, EPC e conteúdo dos itens.

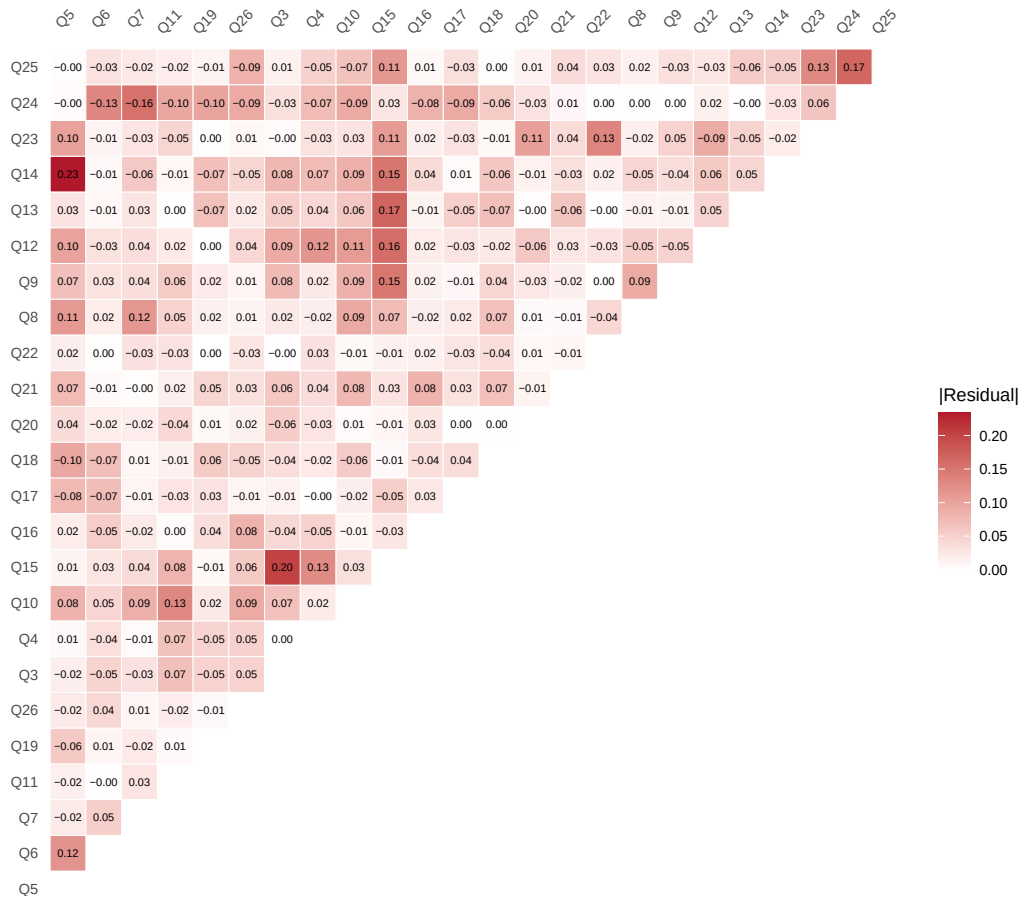


Figura 11: Resíduos de correlação de H . As cores representam magnitudes absolutas; os rótulos preservam o sinal e apresentam duas casas decimais.

O diagnóstico local de H_0 examina inicialmente os três itens cujas cargas cruzadas foram previamente consideradas em H_1. Para Q15, a carga adicional no domínio Ambiente aparece diretamente entre os maiores MI (MI = 48,113; EPC padronizado = 0,366). O item também apresenta resíduos de correlação positivos com Q3 e Q4, de aproximadamente 0,20 e 0,13, respectivamente, indicando associações subestimadas pela especificação atual. Para Q8 e Q9, destaca-se a covariância residual entre os itens (MI = 10,847; EPC padronizado = 0,143), acompanhada de um resíduo de correlação de aproximadamente 0,09. Esses resultados retomam dificuldades de representação envolvendo os itens contemplados na formulação de H_1, embora a dependência residual entre Q8 e Q9 não constitua, isoladamente, evidência de suas cargas adicionais no domínio Psicológico.

O diagnóstico também evidencia dificuldades além das relações previstas em H_1. Q5 participa de indicações de cargas adicionais nos domínios físico e ambiental e de dependências com Q6 e Q14. O resíduo de correlação Q5–Q14, de 0,235, constitui a maior discrepância absoluta da matriz. Q24 combina carga padronizada baixa, indicação de carga adicional no domínio psicológico e dependência com Q25, cujo resíduo de correlação é 0,166. Em conjunto com os problemas de Q15, esses resultados destacam Q5, Q15 e

Q24 como candidatos à investigação de uma especificação modificada na amostra de calibração. Q8 permanece como candidato adicional, considerando sua carga baixa e a relação residual com Q9. As cargas reduzidas de Q3/Q4 e a dependência indicada entre Q17/Q18 também integram o diagnóstico, embora representem dificuldades distintas de mensuração.

A avaliação global apontou limitações nas especificações originais. A simulação oferece uma referência condicional às características da calibração para interpretar os índices observados. A leitura conjunta das cargas, dos resíduos e dos MI/EPC localizou relações que merecem investigação adicional. Esses achados motivam examinar modificações, cuja seleção exige avaliar o conteúdo dos itens e a cobertura dos domínios. Na Seção 8, os candidatos serão confrontados com os precedentes bibliográficos para fundamentar a nova especificação e suas condições de uso. As modificações foram desenvolvidas na calibração, e a especificação selecionada será avaliada na amostra de validação, reservada para essa finalidade.

8 Comparações e modificações dos modelos

8.1 Fundamentação das modificações

O diagnóstico da Seção 7, realizado na amostra de calibração, destacou dificuldades de representação que orientam modificações em H_0. A seleção das alterações considera a magnitude das cargas, as cargas cruzadas, as correlações residuais e o conteúdo dos indicadores, em diálogo com os precedentes bibliográficos. A Tabela 15 sintetiza variações de representação fatorial descritas por Lin & Yao (2022) e por Mosqueira Taipe et al. (2026). O levantamento abrange também indicadores que serão preservados, oferecendo um panorama das dificuldades documentadas para o instrumento.

Tabela 15: Síntese das evidências na literatura sobre a representação dos indicadores do WHOQOL-Bref.

Prioridade de atenção na literatura	Item ou relação	Síntese das evidências na literatura
Alta	Q8 — segurança na vida diária	Apresenta ambiguidade entre os domínios ambiental e psicológico, com registros de cargas cruzadas, realocações e exclusões. É uma das divergências de alocação mais claras nas fontes consultadas.
Alta	Q10 — energia e fadiga	Há evidências de sobreposição entre os domínios físico e psicológico, expressas por cargas cruzadas e alocações alternativas.
Alta	Q14 — lazer	Apresenta registros de carga cruzada, realocação, exclusão e dependência residual com Q5, embora também tenha boa representação ambiental na síntese exploratória.

Tabela 15: Síntese das evidências na literatura sobre a representação dos indicadores do WHOQOL-Bref.

Prioridade de atenção na literatura	Item ou relação	Síntese das evidências na literatura
Alta	Q15 — mobilidade	Há registros de exclusão, inclusive em amostras de língua portuguesa, e de alocação em agrupamentos ambientais. Os achados indicam variação na representação da mobilidade entre contextos.
Moderada	Q3–Q4 — dor e necessidade de tratamento	Apresentam correlação residual recorrente e, em algumas soluções, formam uma dimensão própria. Sua retenção ou exclusão varia com o contexto clínico da amostra.
Moderada	Q5 — prazer de viver	Há registros de correlação residual com Q6 e Q14, alocação alternativa e exclusão em contextos específicos. A síntese exploratória também mostra forte representação do domínio psicológico.
Moderada	Q9 — ambiente físico	Apresenta registros de carga cruzada, correlação residual com Q8 e exclusão em contexto específico, indicando dificuldades na delimitação entre ambiente e percepção psicológica.
Moderada	Q19 — autoestima	Apresenta registros de correlação residual e alocações alternativas, ao lado de forte representação do domínio psicológico na síntese exploratória.
Moderada	Q26 — sentimentos negativos	Há registros de exclusão em diferentes contextos, embora a síntese exploratória também sustente sua representação no domínio psicológico.
Moderada	Q17–Q18 — atividades diárias e capacidade de trabalho	Há precedentes de covariância residual, cargas cruzadas e agrupamento em outra dimensão. A proximidade funcional e a dependência local constituem o argumento mais direto para a relação entre os itens.
Moderada	Q24–Q25 — acesso aos serviços e transporte	Há precedentes de correlação residual e de exclusão em uma solução reduzida, além de evidências de representação de ambos no domínio ambiental.
Moderada	Q12–Q13 — recursos financeiros e acesso à informação	Há precedentes de covariância residual entre os itens e de exclusão de ambos em uma solução reduzida. Os achados indicam variação na representação desses conteúdos ambientais.
Pontual	Q16 — sono e repouso	Há registro de exclusão em contexto específico. A evidência reunida oferece menor convergência para caracterizar uma dificuldade geral de representação.
Pontual	Q22 — apoio social	Há registros de exclusão em contextos específicos, mas a evidência reunida é menos consistente para caracterizar uma dificuldade geral de representação.

Fontes: Lin & Yao (2022) e Mosqueira Taipe et al. (2026). Os estudos individuais são conhecidos por intermédio dessas sínteses.

Nota: A prioridade de atenção na literatura considera a recorrência dos registros e suas implicações para a interpretação do modelo, atribuindo maior peso às cargas cruzadas, seguido da exclusão de itens (cargas baixas) e das covariâncias residuais. A classificação avalia o conjunto das evidências de cada foco. A seleção reúne achados destacados pelas revisões e precedentes recorrentes ou considerados relevantes.

A especificação modificada para as análises adiante exclui Q5, Q15 e Q24. Em Q5, a concentração de correlações com Q6 e Q14 e as indicações de cargas cruzadas apontam dificuldades de delimitação entre conteúdos. A literatura registra essas dependências e alterações de alocação, ao mesmo tempo que a síntese de Lin & Yao (2022) mostra forte representação psicológica. Sua exclusão responde às dificuldades locais observadas na calibração. Para Q15, a carga reduzida e a indicação de relação com o domínio ambiental convergem com precedentes de exclusão em amostras de língua portuguesa e de alocação alternativa. Q24 combina carga reduzida e dependência com Q25, relação também documentada na literatura (Lin & Yao, 2022; Mosqueira Taipe et al., 2026).

Q3, Q4 e Q8 permanecem apesar das cargas baixas. Dor e necessidade de tratamento representam aspectos da condição física cuja relevância varia com o contexto clínico. A revisão documenta a retenção de Q3/Q4 em pacientes e sua exclusão em grupos de estudantes. Mantemos esses conteúdos e a covariância residual Q3–Q4 já prevista na especificação original. Q8 preserva a percepção de segurança no domínio ambiental. Sua proximidade com o domínio psicológico, destacada nas duas sínteses, será considerada na interpretação do ajuste remanescente (Lin & Yao, 2022; Mosqueira Taipe et al., 2026).

Acrescentamos a covariância residual Q17–Q18. A capacidade para realizar atividades cotidianas e a capacidade para o trabalho compartilham um conteúdo funcional específico, além da condição física geral. A revisão registra essa covariância em estudos com participantes com cefaleia crônica e trabalhadores da saúde brasileiros; o agrupamento dos itens em outra dimensão oferece evidência complementar dessa proximidade. A relação residual representa essa associação específica e preserva ambos os indicadores no fator físico (Lin & Yao, 2022; Mosqueira Taipe et al., 2026).

O modelo mantém quatro fatores e os três indicadores sociais, com 21 itens: 5 psicológicos, 6 físicos, 3 sociais e 7 ambientais. As exclusões reduzem a cobertura explícita de prazer de viver, mobilidade e acesso aos serviços de saúde, devendo acompanhar a interpretação dos escores modificados. A seleção foi informada pelo diagnóstico da calibração e constitui uma revisão exploratória. A especificação delimitada é avaliada na amostra de validação, incluindo as dificuldades remanescentes, e a confiabilidade é calculada para os conjuntos de itens retidos. A Figura 12 apresenta a especificação resultante, com as duas covariâncias residuais e os indicadores preservados.

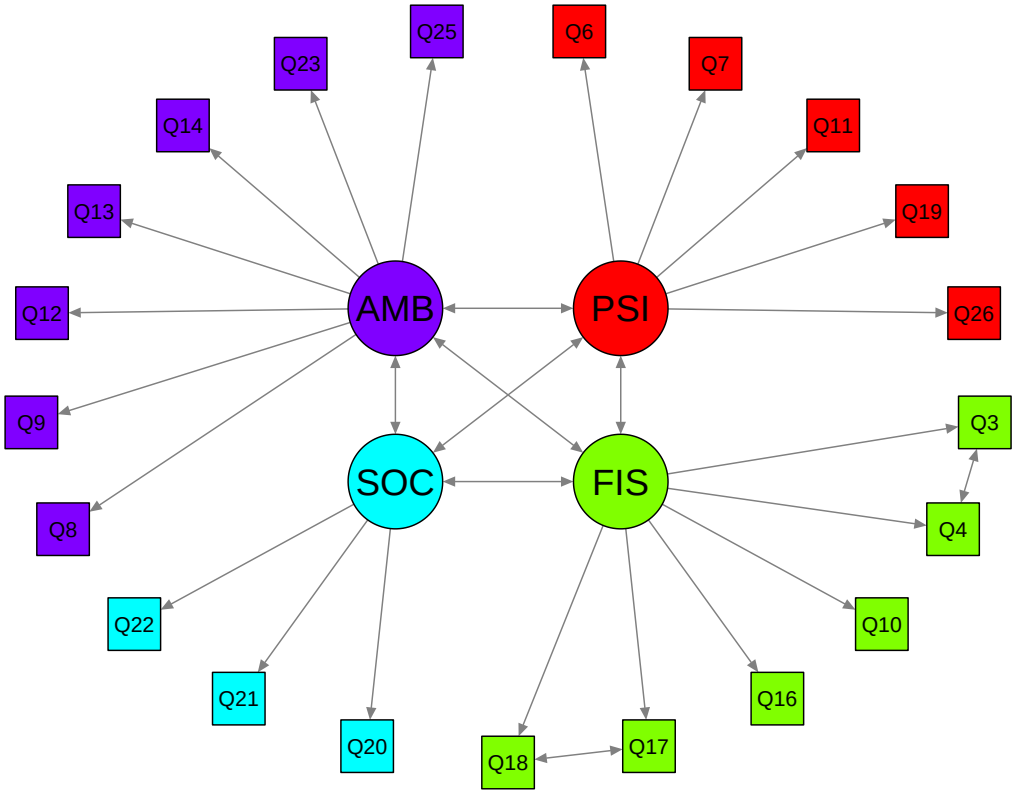


Figura 12: Modelo modificado de quatro fatores correlacionados e 21 indicadores, com covariâncias residuais Q3–Q4 e Q17–Q18. *Nota.* PSI = psicológico; FIS = físico; SOC = relações sociais; AMB = ambiente. Q5, Q15 e Q24 foram excluídos.

8.2 Parâmetros estimados

O modelo modificado é estimado nos 622 participantes da amostra de validação, mantendo as condições de estimação da Seção 6. A avaliação apresenta os parâmetros, verifica a solução e examina o ajuste global e as discrepâncias locais da especificação selecionada na calibração. A Tabela 16 apresenta os parâmetros do modelo modificado.

Tabela 16: Parâmetros fatoriais estimados no modelo modificado.

Relação	Estimativa	EP	z	Padronizada
psycho =~ Q6	0.628	0.037	17.171	0.656
psycho =~ Q7	0.556	0.034	16.532	0.649
psycho =~ Q11	0.594	0.039	15.167	0.601
psycho =~ Q19	0.777	0.027	28.306	0.843
psycho =~ Q26	0.533	0.039	13.489	0.590
physical =~ Q3	0.350	0.040	8.734	0.375
physical =~ Q4	0.348	0.045	7.719	0.347
physical =~ Q10	0.670	0.030	22.676	0.772
physical =~ Q16	0.551	0.041	13.437	0.530

Tabela 16: Parâmetros fatoriais estimados no modelo modificado.

Relação	Estimativa	EP	z	Padronizada
physical =~ Q17	0.711	0.033	21.532	0.775
physical =~ Q18	0.669	0.038	17.689	0.716
social =~ Q20	0.707	0.033	21.174	0.787
social =~ Q21	0.539	0.041	13.059	0.535
social =~ Q22	0.637	0.036	17.779	0.716
environment =~ Q8	0.490	0.043	11.264	0.504
environment =~ Q9	0.563	0.040	14.045	0.619
environment =~ Q12	0.755	0.043	17.630	0.683
environment =~ Q13	0.512	0.040	12.913	0.609
environment =~ Q14	0.667	0.039	17.259	0.692
environment =~ Q23	0.433	0.041	10.515	0.477
environment =~ Q25	0.463	0.044	10.557	0.472

As cargas de Q3, Q4 e Q8 permanecem modestas: 0,375, 0,347 e 0,504, respectivamente. A retenção desses indicadores, definida na fundamentação das modificações, preserva os conteúdos de dor, necessidade de tratamento e segurança. As cargas observadas na validação mostram que esses aspectos continuam parcialmente representados pelos fatores. A avaliação mantém a especificação selecionada na calibração, incluindo a covariância Q3–Q4, e caracteriza suas limitações remanescentes.

O modelo convergiu e não apresentou variâncias negativas nem cargas padronizadas com magnitude superior a 1. Essas verificações sustentam a admissibilidade da solução para a avaliação do ajuste global e local (Brown, 2015; Nye, 2022).

8.3 Ajuste global do modelo modificado

A Tabela 17 apresenta os índices de ajuste do modelo modificado: ^{2} ajustado, CFI, TLI e RMSEA robustos, intervalo de confiança de 90% do RMSEA e SRMR. Os valores descrevem o modelo de 21 indicadores.

Tabela 17: Ajuste global do modelo modificado, estimado por MLR/FIML.

Medida	Valor
N	622
χ^2 ajust.	437.311
df	181
p-valor	< 0.001
CFI (robusto)	0.938
TLI (robusto)	0.928
RMSEA (robusto)	0.052
RMSEA IC90% inf.	0.046
RMSEA IC90% sup.	0.058
p (RMSEA $\leq$ 0,05)	0.294
SRMR	0.041

O modelo apresentou CFI robusto de 0,938, TLI robusto de 0,928, RMSEA robusto de 0,052 e SRMR de 0,041. Os índices são descritivamente mais favoráveis que os das especificações originais apresentadas na Seção 7. Esse contraste envolve conjuntos de indicadores e parcelas amostrais diferentes; portanto, não constitui um teste de superioridade do modelo reduzido. A avaliação concentra-se na adequação da especificação selecionada aos dados de validação. Para o ajuste próximo, o teste da hipótese RMSEA robusto 0,05 apresenta p = 0,294, superior a 0,05. Assim, a hipótese de ajuste próximo não é rejeitada na amostra de validação.

8.4 Confiabilidade dos escores

A Tabela 18 apresenta o ômega e o GLB dos quatro escores, recalculados com os itens retidos. O ômega incorpora a especificação modificada, incluindo suas covariâncias residuais; o GLB mantém o pressuposto de erros não correlacionados e requer a mesma cautela de interpretação já discutida (Cho, 2022; Flora, 2020; Trizano-Hermosilla & Alvarado, 2016).

Tabela 18: Confiabilidade dos escores no modelo modificado.

Fator	Itens	Ômega	GLB
psycho	5	0.798	0.823
physical	6	0.694	0.854
social	3	0.717	0.712
environment	7	0.780	0.838

As exclusões alteram a composição dos escores psicológico, físico e ambiental; o escore social preserva seus três indicadores. Na validação, o ômega dos escores psicológico, social e ambiental supera a referência convencional de 0,70. No físico, o coeficiente é 0,694, ligeiramente abaixo dessa referência. Os GLB superam 0,70 nos quatro domínios, sob os pressupostos já discutidos (Cho, 2022; Trizano-Hermosilla & Alvarado, 2016).

Os ômegas variam de 0,694 a 0,798; os GLB, de 0,712 a 0,854. A interpretação conjunta com H_0 considera tanto a composição dos escores quanto as amostras em que foram estimados. A redução da cobertura dos domínios e o ômega físico próximo de 0,70 integram a avaliação dos usos possíveis da versão modificada. As diferenças entre coeficientes não podem ser atribuídas exclusivamente às exclusões de itens.

8.5 Avaliação por 3DFI

A avaliação da especificação modificada na amostra de validação utiliza o 3DFI fundamentado na Seção 2.5. A calibração dos limites caracteriza o ajuste aproximado por magnitudes de discrepância nas correlações, sem escolher novos caminhos omitidos para definir a má especificação. A simulação da Seção 7 examinou a referência de ajuste exato e a sensibilidade a uma alternativa estrutural específica; aqui, o objetivo é qualificar a magnitude do desajuste remanescente (McNeish & Wolf, 2024). A aplicação do 3DFI concentra-se nessas condições para demonstrar a avaliação graduada de uma solução após as modificações. As duas calibrações respondem a perguntas distintas: o afastamento da referência exata nos modelos originais e o grau de ajuste aproximado do

modelo modificado. Seus resultados devem ser interpretados segundo essas perguntas, considerando também a mudança de 24 para 21 indicadores e as amostras utilizadas.

A calibração considera os 21 indicadores, a não normalidade e a estimação robusta. São utilizadas 1.000 replicações e três magnitudes médias absolutas de discrepância: 0,038, 0,050 e 0,060, correspondentes às referências de ajuste próximo, razoável e medíocre. Esses valores seguem as referências heurísticas de McNeish & Wolf (2024); o MAD define a magnitude de entrada, e os pontos de corte dos índices são obtidos para esta especificação. A Tabela 19 apresenta os limites de CFI, RMSEA e limite superior do intervalo de confiança de 90% do RMSEA. A avaliação deve comparar cada índice observado com sua referência correspondente (McNeish & Wolf, 2024).

Tabela 19: Limites 3DFI calibrados para o modelo modificado.

Referência	MAD	MAD simulado	CFI	RMSEA	RMSEA IC90% sup.
Próximo	0.038	0.036	0.975	0.032	0.040
Razoável	0.050	0.048	0.924	0.058	0.064
Medíocre	0.060	0.058	0.875	0.076	0.082

A Figura 13 detalha a referência razoável, contrastando as distribuições simuladas de CFI e RMSEA na condição de referência e sob a discrepância estipulada. Os limites dinâmicos e convencionais permitem visualizar a diferença entre as duas referências de interpretação.

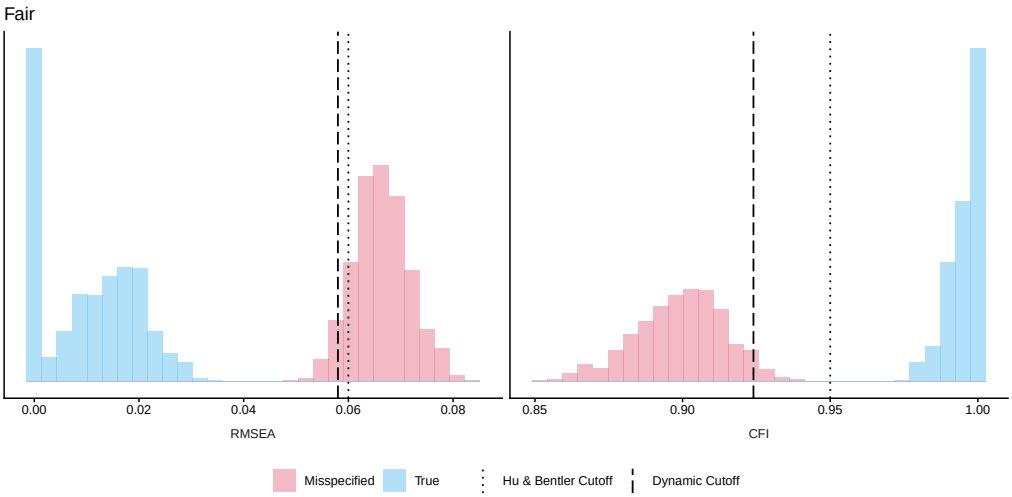


Figura 13: Distribuições simuladas de CFI e RMSEA e limites dinâmicos da referência razoável (fair), com limites convencionais para comparação.

Os índices observados atendem aos limites da referência razoável (*fair*): CFI de pelo menos 0,924, RMSEA de até 0,058 e limite superior do intervalo do RMSEA de até 0,064. A referência próxima (*close*) é mais exigente e não foi alcançada. A classificação 3DFI caracteriza, portanto, o ajuste como razoável sob as condições de simulação utilizadas.

8.6 Diagnóstico local

O diagnóstico local caracteriza as dificuldades que permanecem no modelo modificado na validação. A Tabela 20 apresenta os vinte maiores MI, com EPC bruto e padronizado. Esses resultados são aproximações da liberação individual de parâmetros e devem ser interpretados junto das cargas e dos resíduos, preservando a especificação delimitada na fundamentação (Crede & Harms, 2019; Nye, 2022).

Tabela 20: Vinte maiores índices de modificação do modelo modificado, com EPC bruto e padronizado.

Relação	MI	EPC	EPC padronizado
Q8 ~~ Q9	38.123	0.169	0.282
Q9 ~~ Q23	19.371	0.114	0.200
Q17 ~~ Q22	18.096	-0.062	-0.171
physical =~ Q6	17.080	-1.197	-1.251
Q12 ~~ Q14	17.060	0.126	0.225
Q20 ~~ Q12	14.926	-0.093	-0.208
Q19 ~~ Q10	14.908	-0.062	-0.225
social =~ Q6	13.327	0.234	0.245
environment =~ Q10	12.885	0.184	0.212
psycho =~ Q18	12.786	0.825	0.884
Q9 ~~ Q12	12.119	-0.102	-0.176
Q18 ~~ Q22	12.003	0.055	0.135
Q19 ~~ Q3	11.631	-0.063	-0.147
Q23 ~~ Q25	11.594	0.102	0.147
Q8 ~~ Q13	11.534	-0.086	-0.154
Q6 ~~ Q3	11.394	-0.081	-0.130
social =~ Q26	11.212	-0.211	-0.233
Q12 ~~ Q13	10.791	0.089	0.165
social =~ Q7	9.959	-0.182	-0.212
Q13 ~~ Q14	9.786	0.074	0.159

A Figura 14 apresenta as diferenças entre as correlações observadas e reproduzidas pelo modelo. Cada par aparece uma única vez, com cor proporcional à magnitude absoluta e rótulo que preserva o sinal. A referência de magnitude absoluta de 0,10 orienta a localização das discrepâncias remanescentes, em conjunto com os parâmetros e MI/EPC.

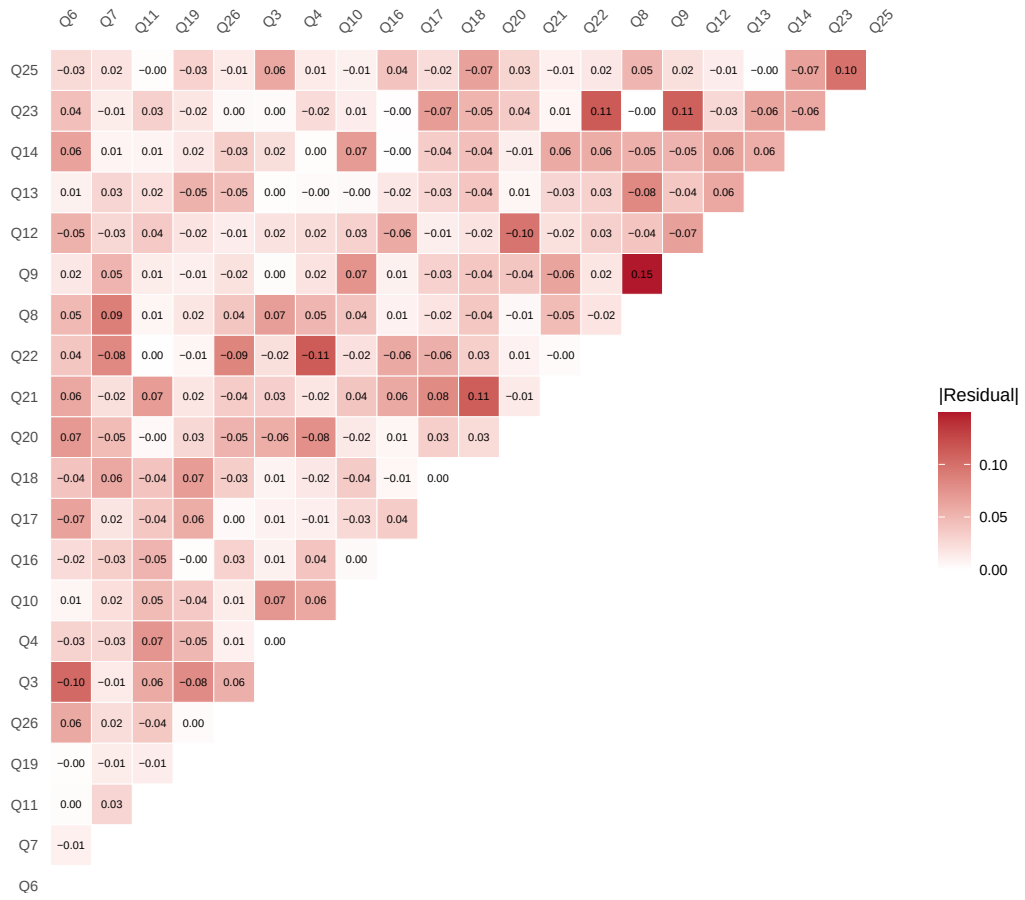


Figura 14: Resíduos de correlação do modelo modificado. As cores representam magnitudes absolutas; os rótulos preservam o sinal.

O maior resíduo absoluto é 0,149; 6 dos 210 pares apresentam magnitude de pelo menos 0,10. A leitura conjunta desse mapa, das cargas e dos MI/EPC documenta as limitações locais da especificação selecionada, em conjunto com a avaliação por 3DFI apresentada anteriormente. Q8–Q9 apresenta o maior MI e o maior resíduo absoluto; Q9–Q23 também se destaca nos dois diagnósticos. A indicação de carga cruzada de Q6 no fator físico apresenta EPC padronizado de -1,251 e integra as limitações locais registradas. Esses EPC são aproximações da liberação individual de parâmetros, não estimativas de um novo modelo ajustado. O contraste com H_0 considera a retirada dos pares que envolviam os indicadores excluídos e o uso de outra parcela amostral.

A revisão resultou em um modelo de quatro fatores com 21 indicadores, preservando os três itens sociais, mantendo a covariância residual Q3–Q4 e acrescentando Q17–Q18. Na validação, a solução apresentou ajuste compatível com a referência razoável do 3DFI, e a hipótese de ajuste próximo pelo RMSEA não foi rejeitada. A confiabilidade permaneceu próxima ou acima de 0,70, com ômega físico ligeiramente abaixo dessa referência. Cargas modestas e discrepâncias locais delimitam a interpretação da solução. Retemos essa especificação, desenvolvida na calibração e avaliada na validação, com os mesmos critérios de pré-processamento e estimação das seções anteriores. Seus usos devem considerar a

cobertura reduzida dos domínios; a generalização para outros contextos requer novas avaliações.

8.7 Invariância de medida

A avaliação prossegue com a estabilidade do modelo de 21 indicadores entre calibração e validação. A AFC multigrupo mantém a identificação das duas amostras e permite examinar se a estrutura e os parâmetros de mensuração são compatíveis entre elas. O ajuste configural preserva o mesmo padrão de fatores e cargas livres nos grupos; a etapa métrica acrescenta igualdade das cargas não padronizadas (Fischer & Karl, 2019; Putnick & Bornstein, 2016). Esse contraste atende ao objetivo central de avaliar a estabilidade das relações entre indicadores e fatores, conforme discutido na Seção 2.6.

Apesar de não necessário, para nossos fins, os níveis escalar e estrito ampliam a avaliação, acrescentando, sucessivamente, igualdade dos interceptos e das variâncias residuais (Putnick & Bornstein, 2016). Todos os ajustes mantêm MLR/FIML e as covariâncias residuais Q3–Q4 e Q17–Q18, estimadas livremente em cada grupo.

A Tabela 21 apresenta os testes dos modelos e as diferenças robustas entre níveis hierárquicos. A avaliação considera o desajuste decorrente das restrições acrescentadas, distinguindo o teste de diferença da hipótese de ajuste exato de cada modelo. A correção robusta é aplicada ao teste de diferença (Brown, 2015).

Tabela 21: Testes dos modelos de invariância e diferenças robustas entre níveis hierárquicos.

Modelo	χ^2 ajust.	gl	$\Delta\chi^2$ ajust.	Δgl	p da diferença
Configural	834.452	362	–	–	–
Métrico	847.998	379	12.521	17	0.768
Escalar	869.482	396	18.625	17	0.350
Estrito	895.285	417	26.812	21	0.177

A igualdade das cargas não foi rejeitada: o contraste métrico/configural apresentou $\Delta\chi^2$ ajustado de 12,521, com 17 graus de liberdade e $p = 0{,}768$. As restrições adicionais também foram compatíveis com os dados: os testes escalar/métrico e estrito/escalar retornaram $p = 0{,}350$ e $p = 0{,}177$, respectivamente. Esses resultados sustentam a manutenção das restrições avaliadas (Putnick & Bornstein, 2016) e indicam a estabilidade do modelo modificado da WHOQOL-Bref proposto.

A Tabela 22 reúne os índices dos quatro modelos e suas diferenças em relação ao nível anterior. As mudanças são calculadas como modelo mais restrito menos o anterior: queda do CFI e aumento do RMSEA ou do SRMR indicam piora. As referências de aproximadamente 0,010 para queda do CFI e 0,015 para aumento do RMSEA orientam a leitura conjunta, considerando as condições em que foram propostas por Cheung & Rensvold (2002) e Chen (2007).

Tabela 22: Índices de ajuste e suas mudanças entre níveis hierárquicos de invariância: CFI e RMSEA robustos e SRMR.

Modelo	CFI	ΔCFI	RM-SEA	ΔRMSEA	SRMR	ΔSRMR
Configural	0.943	–	0.050	–	0.040	–
Métrico	0.944	+0.0005	0.048	-0.0013	0.042	+0.0028
Escalar	0.943	-0.0002	0.047	-0.0010	0.043	+0.0005
Estrito	0.943	-0.0007	0.047	-0.0009	0.043	+0.0004

O modelo configural apresentou CFI robusto de 0,943, RMSEA robusto de 0,050 e SRMR de 0,040. Com a igualdade das cargas, o CFI aumentou 0,0005 e o RMSEA diminuiu 0,0013, enquanto o SRMR aumentou 0,0028. A imposição de invariância métrica, portanto, não produziu desajuste relevante nesses índices.

Nas etapas escalar e estrita, as quedas de CFI foram de 0,0002 e 0,0007, acompanhadas de redução do RMSEA e de aumentos pequenos do SRMR. A concordância entre os testes robustos e a magnitude dessas mudanças favorece a estabilidade das cargas, dos interceptos e das variâncias residuais entre as amostras (Putnick & Bornstein, 2016).

A invariância métrica também pode ser examinada por uma referência empírica das mudanças de CFI robusto, RMSEA robusto e SRMR (Jorgensen et al., 2018). Assim, os rótulos de calibração e validação foram redistribuídos dentro dos estratos originais de participantes completos e incompletos, preservando a alocação de cada estrato entre as amostras, e reestimamos os modelos configural e métrico numa permutação que permitiu avaliar se a mudança observada poderia ser extrema na direção de pior ajuste.

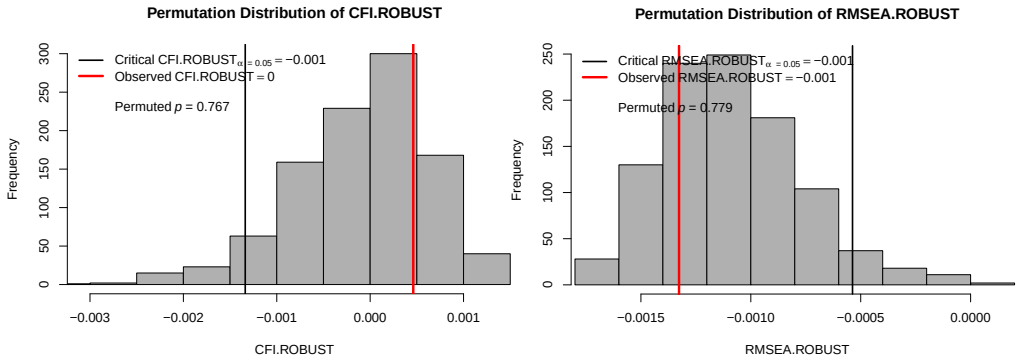
A Tabela 23 apresenta as diferenças observadas e os valores-p empíricos. A referência foi construída com 1000 permutações, das quais 1000 produziram ajustes convergentes.

Tabela 23: Diferenças observadas e valores-p da permutação para a invariância métrica.

Índice	Δ observado	p da permutação
CFI (robusto)	+0.0005	0.767
RMSEA (robusto)	-0.0013	0.779
SRMR	+0.0028	0.559

Os valores-p de permutação foram 0,767 para CFI robusto, 0,779 para RMSEA robusto e 0,559 para SRMR. As diferenças observadas não foram extremas nas respectivas caudas de deterioração, em concordância com o teste robusto de diferença. Essa convergência de evidências sustenta a compatibilidade das restrições métricas com os dados (Jorgensen et al., 2018).

A Figura 15 apresenta as distribuições empíricas de ΔCFI e ΔRMSEA. As linhas vermelhas localizam as diferenças observadas e as pretas indicam os limites críticos: na cauda inferior para o CFI e na superior para o RMSEA. Em ambos os painéis, as mudanças observadas permanecem fora da região de rejeição.



(a) CFI robusto (b) RMSEA robusto

Figura 15: Distribuições de permutação das mudanças de CFI e RMSEA robustos na avaliação da invariância métrica.

A análise multigrupos procedida sob a amostra de calibração (grupo 1) e validação (grupo 2) sustenta a estabilidade métrica do modelo de 21 indicadores, acompanhada de resultados favoráveis às restrições escalares e estritas. Essa evidência complementa o ajuste global, a confiabilidade e o diagnóstico local da solução. Seu alcance é a estabilidade interna entre amostras da mesma população de origem (Fischer & Karl, 2019; Putnick & Bornstein, 2016).

9 Conclusões

Referências

AERA, APA, & NCME. (1999). *Standards for Educational and Psychological Testing*. American Educational Research Association, American Psychological Association, & National Council on Measurement in Education.

AERA, APA, & NCME. (2014). *Standards for Educational and Pshychological Testing*. American Educational Research Association, American Psychological Association & National Council on Measurement in Education.

Arthur, W., Hagen, E., & George, F. (2021). The Lazy or Dishonest Respondent: Detection and Prevention. *Annu. Rev. Organ. Psychol. Organ. Behav.*, *8*, 105–137. https://doi.org/10.1146/annurev-orgpsych-012420-055324

Bandalos, D. L. (2014). Relative Performance of Categorical Diagonally Weighted Least Squares and Robust Maximum Likelihood Estimation. *Structural Equation Modeling*, *21*(1), 102–116. https://doi.org/10.1080/10705511.2014.859510

Bandalos, D. L. (2018). *Measurement Theory and Applications for the Social Sciences*. Guilford Press.

Bell, S. M., Chalmers, R. P., & Flora, D. B. (2023). The Impact of Measurement Model Misspecification on Coefficient Omega Estimates of Composite Reliability. *Educational and Psychological Measurement*, 1–36. https://doi.org/10.1177/00131644231155804

Biemann, T., Koch-Bayram, I. F., Meier-Barthold, M., & Aguinis, H. (2025). Using Markov Chains to Detect Careless Responding in Survey Research. *Organ. Res. Methods*, *28*(4), 543–568. https://doi.org/10.1177/10944281251334778

Brown, T. A. (2015). *Confirmatory Factor Analysis for Applied Research*. The Guilford Press.

Brown, T. A. (2023). Confirmatory Factor Analysis. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.

Byrne, B. M. (2016). *Structural Equation Modeling with AMOS: Basic Concepts, Application, and Programming*. Routledge Taylor & Francis Group.

Chauliac, M., Willems, J., Gijbels, D., & Donche, V. (2023). The Prevalence of Careless Response Behaviour and Its Consequences on Data Quality in Self-Report Questionnaires on Student Learning. *Front. Educ.*, *8*. https://doi.org/10.3389/feduc.2023.1197324

Chen, F. F. (2007). Sensitivity of Goodness of Fit Indexes to Lack of Measurement Invariance. *Structural Equation Modeling: A Multidisciplinary Journal*, *14*(3), 464–504. https://doi.org/10.1080/10705510701301834

Cheung, G. W., & Rensvold, R. B. (2002). Evaluating Goodness-of-Fit Indexes for Testing Measurement Invariance. *Structural Equation Modeling: A Multidisciplinary Journal*, *9*(2), 233–255. https://doi.org/10.1207/S15328007SEM0902_5

Cho, E. (2022). Reliability and Omega Hierarchical in Multidimensional Data: A Comparison of Various Estimators. *Psychological Methods*. https://doi.org/10.1037/met0000525

Cohen, R. J., Schneider, J. W., & Tobin, R. M. (2022). *Psychological Testing and Assessment: An Introduction to Test and Measurement*. McGraw Hill LLC.

Collier, J. E. (2020). *Applied Structural Equation Modeling Using AMOS: Basic to Advanced Techniques*. Routledge.

Crede, M., & Harms, P. (2019). Questionable Research Practices When Using Confirmatory Factor Analysis. *Journal of Managerial Psychology*, *34*(1), 18–30. https://doi.org/10.1108/JMP-06-2018-0272

Curran, P. G. (2016). Methods for the Detection of Carelessly Invalid Responses in Survey Data. *J. Exp. Soc. Psychol.*, *66*, 4–19. https://doi.org/10.1016/j.jesp.2015.07.006

Davvetas, V., Diamantopoulos, A., Zaefarian, G., & Sichtmann, C. (2020). Ten Basic Questions about Structural Equations Modeling You Should Know the Answers to – But Perhaps You Don't. *Industrial Marketing Management*, *90*, 252–263. https://doi.org/10.1016/j.indmarman.2020.07.016

DeSimone, J. A., Harms, P. D., & DeSimone, A. J. (2015). Best Practice Recommendations for Data Screening. *J. Organ. Behav.*, *36*(2), 171–181. https://doi.org/10.1002/job.1962

Dunn, A. M., Heggestad, E. D., Shanock, L. R., & Theilgard, N. (2018). Intra-Individual Response Variability as an Indicator of Insufficient Effort Responding: Comparison to Other Indicators and Relationships with Individual Differences. *J. Bus. Psychol.*, *33*(1), 105–121. https://doi.org/10.1007/s10869-016-9479-0

Dunn, T. J., Baguley, T., & Brunsden, V. (2014). From Alpha to Omega: A Practical Solution to the Pervasive Problem of Internal Consistency Estimation. *British Journal of Psychology*, *105*(3), 399–412. https://doi.org/10.1111/bjop.12046

Enders, C. (2023). Fitting Structural Equation Models with Missing Data. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.

Feng, Y., & Hancock, G. R. (2023). Power Analysis within a Structural Equation Modeling Framework. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.

Fischer, R., & Karl, J. A. (2019). A Primer to (Cross-Cultural) Multi-Group Invariance Testing Possibilities in R. *Frontiers in Psychology*, *10*, 1507. https://doi.org/10.338

9/fpsyg.2019.01507
Flake, J. K., Davidson, I. J., Wong, O., & Pek, J. (2022). Construct Validity and the Validity of Replication Studies: A Systematic Review. *American Psychologist*, *77*(4), 576–588. https://doi.org/10.1037/amp0001006
Flake, J. K., & Fried, E. I. (2020). Measurement Schmeasurement: Questionable Measurement Practices and How to Avoid Them. *Advances in Methods and Practices in Psychological Science*, *3*(4), 456–465. https://doi.org/10.1177/2515245920952393
Flake, J. K., Pek, J., & Hehman, E. (2017). Construct Validation in Social and Personality Research: Current Practices and Recommendations. *Social Psychological and Personality Science*, *8*(4), 370–378. https://doi.org/10.1177/1948550617693063
Flora, D. B. (2020). Your Coefficient Alpha Is Probably Wrong, but Which Coefficient Omega Is Right? A Tutorial on Using R to Obtain Better Reliability Estimates. *Advances in Methods and Practices in Psychological Science*, *3*(4), 484–501. https://doi.org/10.1177/2515245920951747
Flora, D. B., & Flake, J. K. (2017). The Purpose and Practice of Exploratory and Confirmatory Factor Analysis in Psychological Research: Decisions for Scale Development and Validation. *Canadian Journal of Behavioural Science*, *49*(2), 78–88. https://doi.org/10.1037/cbs0000069
Flora, D. B., LaBrish, C., & Chalmers, R. P. (2012). Old and New Ideas for Data Screening and Assumption Testing for Exploratory and Confirmatory Factor Analysis. *Frontiers in Psychology*, *3*(MAR), 55. https://doi.org/10.3389/fpsyg.2012.00055
Furr, M. R. (2021). *Psychometrics: An Introduction*. SAGE Publications.
Gilroy, S. P., & Kaplan, B. A. (2019). Furthering Open Science in Behavior Analysis: An Introduction and Tutorial for Using GitHub in Research. *Perspectives on Behavior Science*, *42*(3), 565–581. https://doi.org/10.1007/s40614-019-00202-5
Goldammer, P., Annen, H., Stöckli, P. L., & Jonas, K. (2020). Careless Responding in Questionnaire Measures: Detection, Impact, and Remedies. *Leadersh. Q.*, *31*(4), 101384. https://doi.org/10.1016/j.leaqua.2020.101384
Goodboy, A. K., & Martin, M. M. (2020). Omega over Alpha for Reliability Estimation of Unidimensional Communication Measures. *Annals of the International Communication Association*, *44*(4), 422–439. https://doi.org/10.1080/23808985.2020.1846135
Green, S. B., & Yang, Y. (2015). Evaluation of Dimensionality in the Assessment of Internal Consistency Reliability: Coefficient Alpha and Omega Coefficients. *Educational Measurement: Issues and Practice*, *34*(4), 14–20. https://doi.org/10.1111/emip.12100
Grewal, R., Cote, J. A., & Baumgartner, H. (2004). Multicollinearity and Measurement Error in Structural Equation Models: Implications for Theory Testing. *Marketing Science*, *23*(4), 519–529. https://doi.org/10.1287/mksc.1040.0070
Groskurth, K., Bluemke, M., & Lechner, C. M. (2024). Why We Need to Abandon Fixed Cutoffs for Goodness-of-Fit Indices: An Extensive Simulation and Possible Solutions. *Behav. Res. Methods*, *56*(4), 3891–3914. https://doi.org/10.3758/s13428-023-02193-3
Hair, J. F., Hult, T. M. G., Ringle, C. M., & Sarstedt, M. (2022). *A Primer on Partial Least Squares Structural Equation Modeling (PLS-SEM)*. Sage Publications.
Hair, J. F., Sarstedt, M., Ringle, C., & Gudergan, S. P. (2017). *Advanced Issues in Partial Least Squares Structural Equation Modeling*. SAGE Publications, Inc.
Hair, J., Black, W., Babin, B., & Anderson, R. (2019). *Multivariate Data Analysis*. Cengage Learning.
Harpe, S. E. (2015). How to Analyze Likert and Other Rating Scale Data. *Curr. Pharm. Teach. Learn.*, *7*(6), 836–850. https://doi.org/10.1016/j.cptl.2015.08.001
Harrington, D. (2009). *Confirmatory Factor Analysis*. Oxford University Press.

Hayes, A. F., & Coutts, J. J. (2020). Use Omega Rather than Cronbach's Alpha for Estimating Reliability. But…. *Communication Methods and Measures*, *14*(1), 1–24. https://doi.org/10.1080/19312458.2020.1718629

Henseler, J. (2021). *Composite-Based Structural Equation Modeling: Analyzing Latent and Emergent Variables*. The Guilford Press.

Holgado-Tello, F., Morata-Ramirez, M., & García, M. (2016). Robust Estimation Methods in Confirmatory Factor Analysis of Likert Scales: A Simulation Study. *International Review of Social Sciences and Humanities*, *11*(2), 80–96.

Hong, M., Steedle, J. T., & Cheng, Y. (2020). Methods of Detecting Insufficient Effort Responding: Comparisons and Practical Recommendations. *Educ. Psychol. Meas.*, *80*(2), 312–345. https://doi.org/10.1177/0013164419865316

Hoyle, R. H. (2023). Structural Equation Modeling: An Overview. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. Guilford Press.

Huang, J. L., Liu, M., & Bowling, N. A. (2015). Insufficient Effort Responding: Examining an Insidious Confound in Survey Data. *J. Appl. Psychol.*, *100*(3), 828–845. https://doi.org/http://dx.doi.org/10.1037/a0038510

Huang, J. L., Wang, Z., Huang, R., Wu, D., & Shi, H. (2026). *Insufficient Effort Responding in Management Research: A Critical Review and Future Directions*. *52*(1). https://doi.org/10.1177/01492063251330268

Huang, P.-H. (2017). Asymptotics of AIC, BIC, and RMSEA for Model Selection in Structural Equation Modeling. *Psychometrika*, *82*(2), 407–426. https://doi.org/10.1007/s11336-017-9572-y

Hughes, D. J. (2018). Psychometric Validity: Establishing the Accuracy and Appropriateness of Psychometric Measures. Em P. Irwing, T. Booth, & D. J. Hughes (Org.), *The Wiley Handbook of Psychometric Testing: A Multidisciplinary Reference on Survey, Scale and Test Development*. John Wiley & Sons Ltd.

Jackson, D. L., Gillaspy, J. A., & Purc-Stephenson, R. (2009). Reporting Practices in Confirmatory Factor Analysis: An Overview and Some Recommendations. *Psychological Methods*, *14*(1). https://doi.org/10.1037/a0014694

Jak, S., Jorgensen, T. D., Verdam, M. G. E., Oort, F. J., & Elffers, L. (2021). Analytical Power Calculations for Structural Equation Modeling: A Tutorial and Shiny App. *Behavior Research Mehods*, *53*, 1385–1406. https://doi.org/10.3758/s13428-020-01479-0/Published

Jobst, L. J., Bader, M., & Moshagen, M. (2023). A Tutorial on Assessing Statistical Power and Determining Sample Size for Structural Equation Models. *Psychological Methods*, *28*(1), 207–221. https://doi.org/10.1037/met0000423

Jones, E. A., Wind, S. A., Tsai, C.-L., & Ge, Y. (2023). Comparing Person-Fit and Traditional Indices Across Careless Response Patterns in Surveys. *Appl. Psychol. Meas.*, *47*(5-6), 365–385. https://doi.org/10.1177/01466216231194358

Jorgensen, T. D., Kite, B. A., Chen, P.-Y., & Short, S. D. (2018). Permutation randomization methods for testing measurement equivalence and detecting differential item functioning in multiple-group confirmatory factor analysis. *Psychological Methods*, *23*(4), 708–728. https://doi.org/10.1037/met0000152

Kalkbrenner, M. T. (2023). Alpha, Omega, and H Internal Consistency Reliability Estimates: Reviewing These Options and When to Use Them. *Counseling Outcome Research and Evaluation*, *14*(1), 77–88. https://doi.org/10.1080/21501378.2021.1940118

Kathawalla, U.-K., Silverstein, P., & Syed, M. (2021). Easing Into Open Science: A Guide for Graduate Students and Their Advisors. *Collabra: Psychology*, *7*(1), 18684.

https://doi.org/10.1525/collabra.18684
Klein, O., Hardwicke, T. E., Aust, F., Breuer, J., Danielsson, H., Mohr, A. H., IJzerman, H., Nilsonne, G., Vanpaemel, W., & Frank, M. C. (2018). A Practical Guide for Transparency in Psychological Science. *Collabra: Psychology*, *4*(1), 20. https://doi.org/10.1525/collabra.158
Kline, R. B. (2016). *Principles and Pratice of Structural Equation Modeling*. The Guilford Press.
Kline, R. B. (2023). *Principles and Pratice of Structural Equation Modeling* (Fifth Edition). The Guilford Press.
Kyriazos, T. A. (2018). Applied Psychometrics: Sample Size and Sample Power Considerations in Factor Analysis (EFA, CFA) and SEM in General. *Psychology*, *09*(08), 2207–2230. https://doi.org/10.4236/psych.2018.98126
Kyriazos, T., & Poga, M. (2023). Dealing with Multicollinearity in Factor Analysis: The Problem, Detections, and Solutions. *Open Journal of Statistics*, *13*(3), 404–424. https://doi.org/10.4236/ojs.2023.133020
Lai, K. (2020). Confidence Interval for RMSEA or CFI Difference Between Nonnested Models. *Structural Equation Modeling: A Multidisciplinary Journal*, *27*(1), 16–32. https://doi.org/10.1080/10705511.2019.1631704
Lai, K. (2021a). Fit Difference Between Nonnested Models Given Categorical Data: Measures and Estimation. *Structural Equation Modeling: A Multidisciplinary Journal*, *28*(1), 99–120. https://doi.org/10.1080/10705511.2020.1763802
Lai, K. (2021b). Using Information Criteria Under Missing Data: Full Information Maximum Likelihood Versus Two-Stage Estimation. *Structural Equation Modeling: A Multidisciplinary Journal*, *28*(2), 278–291. https://doi.org/10.1080/10705511.2020.1780925
Lei, P.-W., & Shiverdecker, L. K. (2020). Performance of Estimators for Confirmatory Factor Analysis of Ordinal Variables with Missing Data. *Structural Equation Modeling: A Multidisciplinary Journal*, *27*(4), 584–601. https://doi.org/10.1080/10705511.2019.1680292
Leite, W. L., Bandalos, D. L., & Shen, Z. (2023). Simulation Methods in Structural Equation Modeling. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.
Li, C. H. (2016a). Confirmatory Factor Analysis with Ordinal Data: Comparing Robust Maximum Likelihood and Diagonally Weighted Least Squares. *Behavior Research Methods*, *48*(3), 936–949. https://doi.org/10.3758/s13428-015-0619-7
Li, C. H. (2016b). The Performance of ML, DWLS, and ULS Estimation with Robust Corrections in Structural Equation Models with Ordinal Variables. *Psychological Methods*, *21*(3), 369–387. https://doi.org/10.1037/met0000093
Limongi, R., & Rogers, P. (2025a). Open Science in Three Acts: Foundations, Practice, and Implementation - First Act. *BAR - Brazilian Administration Review*, *22*(1), e250079. https://doi.org/10.1590/1807-7692bar2025250079
Limongi, R., & Rogers, P. (2025b). Open Science in Three Acts: Foundations, Practice, and Implementation - Second Act. *BAR - Brazilian Administration Review*, *22*(2), e250116. https://doi.org/10.1590/1807-7692bar2025250116
Lin, L.-C., & Yao, G. (2022). Validation of the Factor Structure of the WHOQOL-BREF Using Meta-Analysis of Exploratory Factor Analysis and Social Network Analysis. *Psychological Assessment*, *34*(7), 660–670. https://doi.org/10.1037/pas0001122
Mai, R., Niemand, T., & Kraus, S. (2021). A Tailored-Fit Model Evaluation Strategy for Better Decisions about Structural Equation Models. *Technological Forecasting*

and Social Change, *173*, 121142. https://doi.org/10.1016/j.techfore.2021.121142
Marcoulides, K. M., & Yuan, K. H. (2017). New Ways to Evaluate Goodness of Fit: A Note on Using Equivalence Testing to Assess Structural Equation Models. *Structural Equation Modeling*, *24*(1), 148–153. https://doi.org/10.1080/10705511.2016.1225260
Marsh, H. W., Dowson, M., Pietsch, J., & Walker, R. (2004). Why Multicollinearity Matters: A Reexamination of Relations Between Self-Efficacy, Self-Concept, and Achievement. *Journal of Educational Psychology*, *96*(3), 518–522. https://doi.org/10.1037/0022-0663.96.3.518
Martins, H. C. (2021). Tutorial-Articles: The Importance of Data and Code Sharing. *Revista de Administração Contemporânea*, *25*(1), e200212. https://doi.org/10.1590/1982-7849rac2021200212
Maydeu-Olivares, A., Fairchild, A. J., & Hall, A. G. (2017). Goodness of Fit in Item Factor Analysis: Effect of the Number of Response Alternatives. *Structural Equation Modeling: A Multidisciplinary Journal*, *24*(4), 495–505. https://doi.org/10.1080/10705511.2017.1289816
McNeish, D. (2018). Thanks Coefficient Alpha, We'll Take It from Here. *Psychological Methods*, *23*(3), 412–433. https://doi.org/10.1037/met0000144
McNeish, D. (2023a). Dynamic Fit Index Cutoffs for Factor Analysis with Likert, Ordinal, or Binary Responses. *PsyArXiv Preprints*. https://doi.org/10.31234/osf.io/tp35s
McNeish, D. (2023b). Generalizability of Dynamic Fit Index, Equivalence Testing, and Hu & Bentler Cutoffs for Evaluating Fit in Factor Analysis. *Multivariate Behavioral Research*, *58*(1), 195–219. https://doi.org/10.1080/00273171.2022.2163477
McNeish, D., & Wolf, M. G. (2023). Dynamic Fit Index Cutoffs for Confirmatory Factor Analysis Models. *Psychological Methods*, *28*(1), 61–88. https://doi.org/10.1037/met0000425
McNeish, D., & Wolf, M. G. (2024). Direct Discrepancy Dynamic Fit Index Cutoffs for Arbitrary Covariance Structure Models. *Structural Equation Modeling: A Multidisciplinary Journal*, *31*(5), 835–862. https://doi.org/10.1080/10705511.2024.2308005
Meade, A. W., & Craig, S. B. (2012). Identifying Careless Responses in Survey Data. *Psychol. Methods*, *17*(3), 437–455. https://doi.org/10.1037/a0028085
Mendes-Da-Silva, W. (2023). What Lectures and Research in Business Management Need to Know About Open Science. *Revista de Administração de Empresas*, *63*(4), e0000–0033. https://doi.org/10.1590/s0034-759020230408x
Moshagen, M., & Bader, M. (2024). semPower: General Power Analysis for Structural Equation Models. *Behav. Res. Methods*, *56*(4), 2901–2922. https://doi.org/10.3758/s13428-023-02254-7
Mosqueira Taipe, C. M., Amador Campos, J. A., Krieger, V., Miasso, A. I., Molina, N. P. F. M., & dos Santos, P. L. (2026). Systematic Review of the Factor Structure of WHOQOL-bref in Adult Population. *Quality of Life Research*, *35*(17), 1–18. https://doi.org/10.1007/s11136-025-04115-6
Nalbantoğlu-Yılmaz, F. (2019). Comparison of Different Estimation Methods Used in Confirmatory Factor Analyses in Non-Normal Data: A Monte Carlo Study. *International Online Journal of Educational Sciences*, *11*(4). https://doi.org/10.15345/iojes.2019.04.010
Niemand, T., & Mai, R. (2018). Flexible Cutoff Values for Fit Indices in the Evaluation of Structural Equation Models. *Journal of the Academy of Marketing Science*, *46*(6), 1148–1172. https://doi.org/10.1007/s11747-018-0602-9
Norman, G. (2010). Likert Scales, Levels of Measurement and the "Laws" of Statistics. *Adv. Health Sci. Educ.*, *15*(5), 625–632. https://doi.org/10.1007/s10459-010-9222-y

Nye, C. D. (2022). Reviewer Resources: Confirmatory Factor Analysis. *Organizational Research Methods*, 109442812211205. https://doi.org/10.1177/10944281221120541

Pilcher, N., & Cortazzi, M. (2023). 'Qualitative' and 'quantitative' Methods and Approaches across Subject Fields: Implications for Research Values, Assumptions, and Practices. *Quality & Quantity*. https://doi.org/10.1007/s11135-023-01734-4

Podsakoff, P. M., MacKenzie, S. B., & Podsakoff, N. P. (2012). Sources of Method Bias in Social Science Research and Recommendations on How to Control It. *Annual Review of Psychology*, *63*(1), 539–569. https://doi.org/10.1146/annurev-psych-120710-100452

Pornprasertmanit, S., Miller, P., Jorgensen, T. D., & Corbin, Q. (2022). *Simsem: SIMulated Structural Equation Modeling*. R package. www.simsem.org

Preacher, K. J., & Yaremych, H. E. (2023). Model Selection in Structural Equation Modeling. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.

Putnick, D. L., & Bornstein, M. H. (2016). Measurement invariance conventions and reporting: The state of the art and future directions for psychological research. *Developmental Review*, *41*, 71–90. https://doi.org/10.1016/j.dr.2016.06.004

Reeves, T. D., & Marbach-Ad, G. (2016). Contemporary Test Validity in Theory and Practice: A Primer for Discipline-Based Education Researchers. *CBE Life Sciences Education*, *15*(1). https://doi.org/10.1187/cbe.15-08-0183

Rhemtulla, M., Brosseau-Liard, P. É., & Savalei, V. (2012). When Can Categorical Variables Be Treated as Continuous? A Comparison of Robust Continuous and Categorical SEM Estimation Methods under Suboptimal Conditions. *Psychological Methods*, *17*(3), 354–373. https://doi.org/10.1037/a0029315

Rios, J., & Wells, C. (2014). Validity Evidence Based on Internal Structure. *Psicothema*, *26*(1), 108–116. https://doi.org/10.7334/psicothema2013.260

Robitzsch, A. (2020). Why Ordinal Variables Can (Almost) Always Be Treated as Continuous Variables: Clarifying Assumptions of Robust Continuous and Ordinal Factor Analysis Estimation Methods. *Frontiers in Education*, *5*. https://doi.org/10.3389/feduc.2020.589965

Robitzsch, A. (2022). On the Bias in Confirmatory Factor Analysis When Treating Discrete Variables as Ordinal Instead of Continuous. *Axioms*, *11*(4). https://doi.org/10.3390/axioms11040162

Rogers, P. (2022). Best Practices for Your Exploratory Factor Analysis: A Factor Tutorial. *Revista de Administração Contemporânea*, *26*(6). https://doi.org/10.1590/1982-7849rac2022210085.en

Rogers, P. (2024). Best Practices for Your Confirmatory Factor Analysis: A JASP and Lavaan Tutorial. *Behavior Research Methods*. https://doi.org/10.3758/s13428-024-02375-7

Rogers, P., & Limongi, R. (2025). Open Science in Three Acts: Foundations, Practice, and Implementation - Third Act. *BAR - Brazilian Administration Review*, *22*(3), e250162. https://doi.org/10.1590/1807-7692bar2025250162

Rosseel, Y. (2012). Lavaan: An R Package for Structural Equation Modeling. *Journal of Statistical Software*, *48*(2), 1–36. https://doi.org/10.18637/jss.v048.i02

Rosseel, Y. (2023). *The Lavaan Tutorial*. Department of Data Analysis, Ghent University.

Schumacker, R. E., Wind, S. A., & Holmes, L. F. (2021). Resources for Identifying Measurement Instruments for Social Science Research. *Measurement: Interdisciplinary Research and Perspectives*, *19*(4), 250–257. https://doi.org/10.1080/15366367.2021.1950486

Shek, D. T. L., & Yu, L. (2014). Use of Structural Equation Modeling in Human

Development Research. *International Journal on Disability and Human Development*, *13*(2), 157–167. https://doi.org/10.1515/ijdhd-2014-0302

Shi, D., & Maydeu-Olivares, A. (2020). The Effect of Estimation Methods on SEM Fit Indices. *Educational and Psychological Measurement*, *80*(3), 421–445. https://doi.org/10.1177/0013164419885164

Shi, D., Maydeu-Olivares, A., & Rosseel, Y. (2020). Assessing Fit in Ordinal Factor Analysis Models: SRMR vs. RMSEA. *Structural Equation Modeling: A Multidisciplinary Journal*, *27*(1), 1–15. https://doi.org/10.1080/10705511.2019.1611434

Sireci, S. G., & Sukin, T. (2013). Test Validity. Em *APA Handbook of Testing and Assessment in Psychology, Vol. 1: Test Theory and Testing and Assessment in Industrial and Organizational Psychology.* (p. 61–84). American Psychological Association. https://doi.org/10.1037/14047-004

Skevington, S. M., & Epton, T. (2018). How Will the Sustainable Development Goals Deliver Changes in Well-Being? A Systematic Review and Meta-Analysis to Investigate Whether WHOQOL-BREF Scores Respond to Change. *BMJ Glob. Health*, *3*. https://doi.org/10.1136/bmjgh-2017-000609

Steedle, J. (2018). *Detecting Inattentive Responding on a Psychosocial Measure of College Readiness*. ACT.org.

Trizano-Hermosilla, I., & Alvarado, J. M. (2016). Best Alternatives to Cronbach's Alpha Reliability in Realistic Conditions: Congeneric and Asymmetrical Measurements. *Frontiers in Psychology*, *7*(MAY). https://doi.org/10.3389/fpsyg.2016.00769

Ulitzsch, E., Pohl, S., Khorramdel, L., Kroehne, U., & Davier, M. von. (2022). A Response-Time-Based Latent Response Mixture Model for Identifying and Modeling Careless and Insufficient Effort Responding in Survey Data. *Psychometrika*, *87*(2), 593–619. https://doi.org/10.1007/s11336-021-09817-7

Urbina, S. (2014). *Essentials of Psychological Testing*. John Wiley & Sons.

Wang, Y. A. (2023). *How to Conduct Power Analysis for Structural Equation Models: A Practical Primer* [Preprint]. PsyArXiv. https://doi.org/10.31234/osf.io/4n3uk

Wang, Y. A., & Rhemtulla, M. (2021). Power Analysis for Parameter Estimation in Structural Equation Modeling: A Discussion and Tutorial. *Advances in Methods and Practices in Psychological Science*, *4*(1), 1–17. https://doi.org/10.1177/2515245920918253

Ward, M. K., & Meade, A. W. (2023). Dealing with Careless Responding in Survey Data: Prevention, Identification, and Recommended Best Practices. *Annu. Rev. Psychol.*, *74*(Volume 74, 2023), 577–596. https://doi.org/10.1146/annurev-psych-040422-045007

West, S. G., Wu, W., McNeish, D., & Savord, A. (2023). Model Fit in Structural Equation Modeling. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.

Westland, C. J. (2010). Lower Bounds on Sample Size in Structural Equation Modeling. *Electronic Commerce Research and Applications*, *9*(6). https://doi.org/10.1016/j.elerap.2010.07.003

Whittaker, T. A., & Schumacker, R. E. (2022). *A Beginner's Guide to Structural Equation Modeling* (Fifth Edition). Routledge Taylor & Francis Group.

Widodo, E. (2018). Some Notes on the Contemporary Views of Validity in Psychological and Educational Assessment. *Advances in Social Science, Education and Humanities Research*, *231*, 732–734. https://doi.org/10.3968/8877

Wilkinson, M. D., Dumontier, M., Aalbersberg, Ij. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., Da Silva Santos, L. B., Bourne, P. E.,

Bouwman, J., Brookes, A. J., Clark, T., Crosas, M., Dillo, I., Dumon, O., Edmunds, S., Evelo, C. T., Finkers, R., … Mons, B. (2016). The FAIR Guiding Principles for Scientific Data Management and Stewardship. *Scientific Data*, *3*(1), 160018. https://doi.org/10.1038/sdata.2016.18

Xia, Y., & Yang, Y. (2019). RMSEA, CFI, and TLI in Structural Equation Modeling with Ordered Categorical Data: The Story They Tell Depends on the Estimation Methods. *Behavior Research Methods*, *51*(1), 409–428. https://doi.org/10.3758/s13428-018-1055-2

Yang, Y., & Liang, X. (2013). Confirmatory Factor Analysis under Violations of Distributional and Structural Assumptions. *Int. J. Quantitative Research in Education*, *1*(1), 61–84.

Yang-Wallentin, F., Jöreskog, K. G., & Luo, H. (2010). Confirmatory Factor Analysis of Ordinal Variables with Misspecified Models. *Structural Equation Modeling*, *17*(3), 392–423. https://doi.org/10.1080/10705511.2010.489003

Yoshitake, N., Sun, Y., Sugawara, M., Matsumoto, S., Sakai, A., Takaoka, J., & Goto, N. (2015). The Psychometric Properties of the WHOQOL-BREF in Japanese Couples. *Health Psychology Open*, *2*(2), 1–9. https://doi.org/10.1177/2055102915598089

Yuan, K. H., Chan, W., Marcoulides, G. A., & Bentler, P. M. (2016). Assessing Structural Equation Models by Equivalence Testing With Adjusted Fit Indexes. *Structural Equation Modeling*, *23*(3), 319–330. https://doi.org/10.1080/10705511.2015.1065414

Zhang, Z., & Yuan, K.-H. (2018). *Practical Statistical Power Analysis Using Webpower and R*. ISDSA Press. https://doi.org/10.35566/power