

Escolhas inteligentes para modelos de medida

Tutorial em manuscrito executável para análise fatorial confirmatória no ambiente R

Pablo Rogers and Sérgio Murilo Georgeto

15 de setembro de 2026

Resumo

O presente artigo busca cumprir três objetivos: i) compilar orientações, alinhadas com a literatura recente, sobre a aplicação de uma das técnicas mais utilizadas nas ciências sociais aplicadas, Análise Fatorial Confirmatória (AFC); ii) evidenciar como essas orientações podem ser implementadas na prática, tendo em vista um exemplo real; e iii) estruturar esse enredo de modo reproduzível. Nesse sentido, apresentamos uma solução na forma de um artigo-tutorial, em que as principais decisões tomadas numa AFC são justificadas do ponto de vista da literatura, e apresentadas num documento dinâmico para que o leitor acesse os códigos-fonte do artigo, dados utilizados e códigos de execução das análises. Através da presente metodologia didática, desenvolvida completamente em ambiente aberto (Git/Github/Positron/Quarto/pacotes R + lavaan/Docker), espera-se incentivar pesquisadores que dominam determinada técnica estatística, relevante para sua área de atuação, imitar essa proposta e ajudarem seus pares.

Palavras-chave: Análise Fatorial Confirmatória, Modelagem de Equações Estruturais, Validade da Estrutura Interna, Ciência Aberta, Reprodutibilidade, Quarto, *lavaan*.

1 Introdução

A Análise Fatorial Confirmatória (AFC) é uma das principais ferramentas para se coletar evidências de validade de um instrumento de medida baseada na estrutura interna (Bandalos, 2018; Hughes, 2018; Sireci & Sukin, 2013). A validade é sem dúvida a qualidade mais importante de um modelo de medida (Furr, 2021), pois está relacionada com a questão de medição fundamental: o que os instrumentos de medida estão realmente medindo (Bandalos, 2018). Inclusive, esse aspecto se entrelaça com o próprio conceito clássico de validade: grau em que um teste mede o que ele pretende medir (Bandalos, 2018; Furr, 2021; Sireci & Sukin, 2013; Urbina, 2014); condizente com o modelo tripartite e ainda utilizado por muitos pesquisadores (Widodo, 2018).

A visão tripartite de validade é uma forma de conceber a validade de um teste ou instrumento de medida baseada em três tipos de evidência: conteúdo, critério e construto (Bandalos, 2018). A validade de conteúdo se refere à adequação e representatividade dos itens do teste em relação ao domínio ou objetivo que se pretende medir (Cohen et al., 2022). A validade de critério se refere à relação entre os escores do teste e algum

critério externo relevante, como o desempenho em outra medida ou em alguma situação futura (Cohen et al., 2022). A validade de construto se refere à capacidade do teste de mensurar o construto teórico que se propõe a medir, considerando as hipóteses e evidências empíricas sobre esse construto (Cohen et al., 2022).

A visão tripartite de validade foi proposta no “*Standards for Educational and Psychological Testing*” da *American Psychological Association* (APA) em 1966, considerada a maior autoridade sobre padrões de medição nas ciências sociais (Bandalos, 2018), e foi amplamente aceita por décadas. No entanto, essa visão veio recebendo severas críticas por ser limitada, fragmentada e confusa (Sireci & Sukin, 2013) e já não mais prevalece: vários tipos de validade dessa visão tradicional foram substituídos por uma nova visão (Widodo, 2018).

O lançamento dos *standards* de 1999 (AERA et al., 1999), seguidos pelos *standards* de 2014 (AERA et al., 2014), marcou uma mudança substancial no conceito de validade dos testes, que passou a ser associado à interpretação e uso dos escores dos testes (Furr, 2021). Com a nova estrutura, a validação passou a exigir várias evidências teóricas e empíricas. Atualmente, a visão prevalecente é da validade como um conceito unitário (validade de construto) e a existência de várias fontes de evidência que podem ser usadas para avaliar possíveis interpretações de escores de testes para fins específicos (Furr, 2021; Urbina, 2014).

Assim, de acordo com as principais autoridades em avaliação psicológica, validade refere-se ao grau que as evidências e a teoria apoiam a interpretação das pontuações dos testes para o propósito que foi concebido (AERA et al., 2014). Validade é um julgamento avaliativo integrado do grau em que as evidências empíricas e os fundamentos teóricos apoiam a adequação e apropriação das inferências e ações baseadas em pontuações de testes ou outros modos de avaliação (Bandalos, 2018; Furr, 2021; Urbina, 2014).

De acordo com os *standards* da APA (AERA et al., 2014), existem cinco fontes de evidências de validade para testes e medidas: baseadas no conteúdo, no processo de resposta, na relação com variáveis externas, nas consequências do uso do teste e na estrutura interna. A primeira tem a ver com o grau em que o conteúdo incluído em um teste fornece uma representação adequada do domínio a ser medido e somente o domínio mensurado (Furr, 2021). A segunda se refere ao ajuste entre o construto e a natureza detalhada do desempenho ou resposta dos examinados (Sireci & Sukin, 2013). A validade baseada na relação com variáveis externas se refere à correlação do teste com outros testes ou construtos que se espera que estejam relacionados ou não com o construto medido (Furr, 2021). A validade baseada nas consequências do uso do teste se refere aos efeitos positivos ou negativos que o uso do teste pode ter para os indivíduos ou grupos avaliados (Bandalos, 2018).

As evidências com base na estrutura interna estão relacionadas com o grau em que as relações entre os itens do teste e seus componentes estão em conformidade com o construto no qual as interpretações dos escores do instrumento de medida são baseadas (AERA et al., 2014; Rios & Wells, 2014). A evidência de validade baseada na estrutura interna pode vir de muitas fontes diferentes (Rios & Wells, 2014), incluindo a análise da (a) confiabilidade, (b) dimensionalidade e (c) invariância de medida.

A confiabilidade pode ser mensurada através da consistência interna, sendo representada pela i) a reprodutibilidade dos escores dos testes em administrações repetidas, realizadas nas mesmas condições e ii) também definida como a proporção da variância do escore

verdadeiro em relação à variância do escore total observado (Rios & Wells, 2014). Na avaliação da dimensionalidade se está interessado, principalmente, em determinar se as inter-relações entre os itens suportam as inferências que serão produzidas pelo escore do modelo de medida proposto (Rios & Wells, 2014), que deve ser, essencialmente, unidimensional. Para análise da invariância torna-se útil fornecer evidências de que as características do item são comparáveis entre grupos conhecidos, como sexo ou raça.

Através da AFC podemos atacar essas três diferentes fontes para obter evidências da validade da estrutura interna (Bandalos, 2018; Flora & Flake, 2017; Hughes, 2018; Reeves & Marbach-Ad, 2016; Rios & Wells, 2014). Na maioria das situações em ciências sociais aplicadas o pesquisador tem uma estrutura dimensional teórica em mente (Sireci & Sukin, 2013), e o emprego da AFC torna-se recomendado para comparar a estrutura do modelo de medida hipotético ao observado (Rios & Wells, 2014).

A AFC é uma das principais ferramentas dentro do arcabouço da Modelagem de Equações Estruturais (SEM) baseada em covariâncias (CB-SEM) (Brown, 2023; Harrington, 2009; Jackson et al., 2009; Kline, 2023; Nye, 2022). A SEM é uma das ferramentas estatísticas mais utilizadas nas ciências sociais aplicadas (Hoyle, 2023; Kline, 2023). Ela é uma generalização da regressão múltipla e análise fatorial (Hoyle, 2023) e permite que os componentes dessas técnicas sejam integrados analiticamente. A SEM busca resolver problemas de pesquisa que envolvam mais de uma relação entre variáveis e que podem conter erros de mensuração (Hoyle, 2023), condizente com a necessidade para validações de modelos de medida.

As aplicações da AFC envolvem escolhas metodológicas que dependem da estrutura dos dados, do formato de resposta dos itens e dos objetivos do estudo (Crede & Harms, 2019; Flake et al., 2017; Flake & Fried, 2020; Jackson et al., 2009; Nye, 2022; Rogers, 2024). Essas escolhas também afetam a viabilidade da análise: a complexidade do modelo, a quantidade e a distribuição das categorias de resposta e o tamanho amostral podem influenciar a precisão das estimativas e o desempenho dos procedimentos de estimação (Rhemtulla et al., 2012). Por isso, considerar as implicações analíticas dos instrumentos ainda no planejamento da pesquisa pode evitar dificuldades nas etapas subsequentes.

Nesse sentido, surge o seguinte questionamento: **existem escolhas numa aplicação AFC que podem “facilitar a vida” do cientista social para acessar evidências de validade da estrutura interna de um modelo de medida?** Com esse questionamento não estamos de forma alguma sugerindo que se pautem os objetivos da pesquisa a partir dos métodos quantitativos empregados. Objetivos da pesquisa são o norte da investigação científica, pois definem o que se quer descobrir e o que se considera relevante. O método quantitativo é um meio para atingir esses objetivos, mas não é o fim em si mesmo. O método quantitativo é apenas uma das muitas ferramentas disponíveis para os cientistas, e o objetivo da pesquisa é o que deve orientar a escolha do método (Pilcher & Cortazzi, 2023).

Na Psicometria, diversas questões metodológicas admitem mais de uma abordagem defensável. Nesses casos, a escolha deve considerar os objetivos da pesquisa e as consequências da modelagem para a interpretação dos resultados. Nesse artigo, adotamos uma recomendação prática: entre instrumentos adequados ao construto e à população de interesse, privilegiar aqueles cujos itens possam ser tratados como contínuos. Essa decisão deve ser planejada e justificada, pois oferece acesso às possibilidades analíticas da máxima verossimilhança (ML) sem exigir que o formato ordinal das respostas seja considerado, por si só, um impedimento (Rhemtulla et al., 2012; Robitzsch, 2020, 2022).

Para esse propósito, recomendamos instrumentos com itens de cinco ou mais categorias de resposta, preferencialmente sete, quando houver alternativas apropriadas e com evidências de validade para o uso pretendido. Estudos de simulação em AFC sustentam o emprego de ML robusta com cinco a sete categorias em diversas condições, com resultados particularmente favoráveis quando os limiares das categorias são aproximadamente simétricos (Rhemtulla et al., 2012).

O tratamento contínuo permite utilizar a ML e suas correções robustas, além de articular a estimação a procedimentos de avaliação e comparação de modelos e ao tratamento de dados ausentes (Rhemtulla et al., 2012; Robitzsch, 2020). A modelagem ordinal, por sua vez, também envolve pressupostos: a abordagem usual baseada em correlações policóricas pressupõe respostas contínuas subjacentes com distribuição normal. Portanto, não se trata de escolher entre uma abordagem com pressupostos e outra livre deles, mas de justificar qual representação é adequada aos objetivos da pesquisa (Robitzsch, 2020, 2022).

Essas vantagens tornam o tratamento contínuo uma escolha prática para o artigo. Na presença de dados ausentes, por exemplo, a ML com informação completa (FIML) permite incorporá-los à estimação, observadas as condições relativas ao modelo e ao mecanismo de ausência. A literatura também identifica cenários em que ML robusto apresenta desempenho favorável em amostras menores (Rhemtulla et al., 2012).

O presente artigo tem como proposta guiar os cientistas sociais aplicados sobre escolhas que eles podem tomar, desde a seleção do modelo de medida até a comparação e modificação dos modelos, e que pode aumentar a flexibilidade de sua AFC. O artigo ainda discorre sobre análise de poder, pré-processamento dos dados, processo de estimação e ajuste dos modelos de medidas. Esses assuntos são abordados sob a perspectiva do que fazer (Flake et al., 2017; Nye, 2022; Rogers, 2024), o que não fazer (Crede & Harms, 2019; Rogers, 2024), e o que reportar (Flake & Fried, 2020; Jackson et al., 2009; Rogers, 2024).

Essas sugestões têm a intenção de orientar aqueles que necessitam acessar a estrutura interna de modelos de medida através de uma AFC, para não caírem em armadilhas em nenhuma das etapas do processo de análise dos dados. Boas escolhas nas etapas iniciais podem evitar restrições em etapas subsequentes. Más escolhas em etapas iniciais podem lhe direcionar para um estudo exploratório, e/ou exigir maiores esforços nas etapas subsequentes.

Do ponto de vista prático, pretendemos apresentar um exemplo na forma de tutorial no R/Quarto, principalmente pelo uso do ecossistema baseado no pacote lavaan (Rosseel, 2023), seguindo todas as diretrizes para reprodutibilidade, replicabilidade e transparência preconizadas pelo movimento Ciência Aberta (CA) (Gilroy & Kaplan, 2019; Kathawalla et al., 2021; Klein et al., 2018).

Para além das práticas recomendadas de fluxo de trabalho de projetos de pesquisa, *preprints*, código reproduzível, compartilhamento de dados, redação transparente e relatórios registrados (Kathawalla et al., 2021), que foram delineadas e estão presentes nesse artigo, cremos que artigos-tutoriais como esse podem cumprir um papel importante para o ensino de métodos quantitativos em ciências sociais aplicadas (Martins, 2021; Mendes-Da-Silva, 2023).

Um artigo-tutorial tem como objetivo descrever uma técnica importante ou uma área de aplicação para leitores que não são especialistas no campo (Martins, 2021; Mendes-Da-

Silva, 2023). Na medida que os leitores espelham as melhores práticas de pesquisadores experientes, a partir de protocolos claros, códigos e dados abertos e reutilizáveis, a comunidade científica passará ser menos afetada pelo viés positivo de publicação (P-hacking e HARKing).

Artigos-tutoriais que praticam os princípios FAIR (Findable, Accessible, Interoperable, and Reusable) (Wilkinson et al., 2016) e explicam de uma maneira didática (direta e simples), porém sem perder a profundidade e qualidade da execução, podem ajudar sobremaneira pesquisadores a aplicar uma técnica relevante para o campo (Martins, 2021; Mendes-Da-Silva, 2023). Acreditamos que esse seja o caso da presente proposta, que além de aplicar as práticas de CA (Gilroy & Kaplan, 2019; Kathawalla et al., 2021; Klein et al., 2018), discute uma técnica vastamente utilizada nas ciências sociais aplicadas (Crede & Harms, 2019).

Nessa perspectiva, a adoção da CA envolve incorporar seus princípios à rotina de pesquisa, mediante práticas de documentação, compartilhamento e formação de pesquisadores (Limongi & Rogers, 2025a). A articulação dessas práticas em um fluxo de trabalho requer organizar os materiais, registrar as alterações e conectar as análises à redação dos resultados (Limongi & Rogers, 2025b). Para operacionalizar essa articulação, adotamos como referência o ARTE (Article Reproducibility Template & Environment), um template que integra a organização do projeto, o controle de versões, a gestão de dependências computacionais e a elaboração de documentos dinâmicos (Rogers & Limongi, 2025).

O ARTE propõe uma adoção gradual dessas práticas, desde a organização e o compartilhamento dos materiais até o controle do ambiente computacional por meio de contêineres, conforme as necessidades do projeto e a familiaridade do pesquisador com as ferramentas (Rogers & Limongi, 2025). No presente tutorial, essa proposta orienta a organização dos dados e scripts e sua articulação com a narrativa em Quarto, permitindo vincular as decisões analíticas aos procedimentos que produzem as tabelas, figuras e estatísticas apresentadas. Essa organização também atende à finalidade didática do artigo: oferecer ao leitor uma estrutura que possa examinar, executar e adaptar às suas próprias aplicações de AFC.

O presente artigo-tutorial está organizado em uma seção de fundamentação, seis etapas aplicadas e uma conclusão, além desta introdução. Seguindo a proposta de Martins (2021) para artigos-tutoriais, a próxima seção apresenta uma revisão sólida da AFC, baseada em destacadas compilações de boas práticas (Crede & Harms, 2019; Flake et al., 2017; Flake & Fried, 2020; Jackson et al., 2009; Nye, 2022; Rogers, 2024), e os capítulos seguintes desenvolvem um exemplo de aplicação de pesquisa real (Rogers, 2022, 2024) no ecossistema do R e Quarto (<https://quarto.org/>), fornecendo os protocolos para estimar o método ou usar a técnica. Esses capítulos buscam seguir de perto a proposta do ARTE (Limongi & Rogers, 2025a, 2025b; Rogers & Limongi, 2025) e geram diversos materiais suplementares (<https://phdpablo.github.io/smart-cfa/>). Por último, apresentamos as considerações finais a título de conclusão.

2 Escolhas inteligentes

O presente tutorial retoma o contexto de aplicações discutido por Rogers (2024): modelos de fator comum, com estrutura multifatorial definida e propriedades psicométricas previamente investigadas, frequentemente empregados como etapa de uma pesquisa mais ampla. A diferença está no caminho analítico aqui recomendado: planejar a escolha de

instrumentos cujos itens permitam o tratamento contínuo, utilizando ML robusto como estratégia de estimação. A fundamentação dessa escolha exige distinguir o formato de resposta, o objeto da análise e os pressupostos do modelo.

Itens individuais e escores agregados de uma escala não são intercambiáveis nessa discussão. A possibilidade de analisar uma soma ou média de itens como contínua não basta para justificar o mesmo tratamento de cada indicador em uma AFC. Harpe (2015) faz essa distinção e recomenda que itens individuais com formatos numéricos de pelo menos cinco categorias podem, em geral, ser tratados como contínuos. Norman (2010) complementa essa perspectiva ao mostrar que a avaliação de procedimentos paramétricos deve considerar sua robustez, em vez de rejeitá-los automaticamente pela classificação ordinal dos dados. Essas contribuições apoiam a discussão geral; a justificativa específica para a AFC vem dos estudos sobre seus modelos e estimadores.

Nessa direção, Rhemtulla et al. (2012) encontrou desempenho aceitável de ML robusto com cinco a sete categorias em diversas condições, embora a assimetria dos limiares e a magnitude das cargas fatoriais influenciassem os resultados. Com sete categorias e limiares aproximadamente simétricos, a abordagem contínua frequentemente apresentou desempenho tão bom quanto ou melhor que a alternativa categórica estudada. Esses resultados oferecem suporte à nossa preferência prática, sem estabelecer cinco categorias como um limiar que garanta bom desempenho em qualquer aplicação.

Por outra perspectiva, Robitzsch (2020) e Robitzsch (2022) argumentam que a escolha entre modelar as relações entre os escores observados e modelar respostas contínuas subjacentes envolve diferentes definições dos parâmetros de interesse. A modelagem ordinal não é universalmente superior apenas porque os itens apresentam categorias ordenadas. Assim, nossa recomendação combina a possibilidade de defender o modelo contínuo com evidências de desempenho e vantagens operacionais. Recomendamos esse caminho desde o planejamento, mantendo a adequação do instrumento ao objetivo da pesquisa como critério prioritário.

As seções seguintes verbalizam analiticamente alguns tópicos percorridos na literatura (Crede & Harms, 2019; Flake et al., 2017; Flake & Fried, 2020; Jackson et al., 2009; Nye, 2022; Rogers, 2024), que foram apenas sintetizado por Rogers (2024) no contexto de uma AFC com itens ordinais. Os mesmos assuntos são abordados sob a perspectiva do que fazer (Flake et al., 2017; Nye, 2022; Rogers, 2024), o que não fazer (Crede & Harms, 2019; Rogers, 2024), e o que reportar (Flake & Fried, 2020; Jackson et al., 2009; Rogers, 2024), para escolhas de modelos de medidas cujos dados possam ser tratados como contínuos.

Partimos da hipótese que o leitor possui algum conhecimento introdutório sobre o assunto, e por isso, deixamos certas nuances para alguns bons manuais (Brown, 2015; Kline, 2023) ou artigos científicos que oferecem uma boa introdução à CB-SEM (Davvetas et al., 2020; Shek & Yu, 2014). O contexto é da AFC dentro do arcabouço da CB-SEM (Brown, 2015; Jackson et al., 2009; Kline, 2023; Nye, 2022). Não abordaremos ajustes de modelos de medidas na SEM baseada em variâncias (VB-SEM), que podem ser encontradas, principalmente, na literatura sobre *Partial Least Squares* SEM (PLS-SEM) (J. F. Hair et al., 2017, 2022; Henseler, 2021).

2.1 Seleção do Modelo de Medida

Na seleção do modelo de medida, recomendamos privilegiar instrumentos cujos itens tenham cinco ou mais categorias de resposta, preferencialmente sete, entre as alternativas com evidências de validade para o construto, a língua e a população de interesse. A preferência por sete categorias decorre do desempenho favorável observado em condições estudadas de AFC e da possibilidade de maior diferenciação das respostas; não representa uma garantia de maior poder ou de melhor mensuração em qualquer contexto (Harpe, 2015; Rhemtulla et al., 2012). Essa orientação se aplica à escolha entre instrumentos apropriados e não autoriza alterar arbitrariamente o formato de resposta de uma escala validada, pois modificações podem exigir nova avaliação de suas propriedades psicométricas (Harpe, 2015).

O número de categorias oferecidas também deve ser confrontado com a forma como elas são utilizadas. Um item com cinco ou sete opções pode apresentar respostas concentradas em apenas duas ou três categorias, como destaca Harpe (2015). Por isso, recomendamos examinar, no planejamento, evidências de aplicações anteriores na população-alvo e, após a coleta, as frequências das categorias e a distribuição de cada item. A descrição dos indicadores no pré-processamento permitirá documentar essas características e informar a avaliação da estratégia de estimação. As correções robustas não dispensam essa análise nem corrigem automaticamente uma especificação inadequada do modelo de medida (Rhemtulla et al., 2012).

Ao selecionar um modelo de medida, é importante dar prioridade para escalas que já foram validadas na língua de aplicação e utilizadas na população-alvo da pesquisa (Flake et al., 2017). Além disso, é crucial confirmar se essas escalas não são proprietárias ou privativas de uma profissão. Uma varredura inicial no Sistema de Avaliação de Testes Psicológicos do seu país pode ser útil, e se não encontrar o que procura, busque por escalas financiadas por entidades públicas ou não governamentais, grupos/centros de pesquisas ou universidades que, geralmente, empreendem maior esforço (recursos humanos, tempo e dinheiro) para validar modelos de medidas para fins de políticas públicas.

Esgote seu esforço de pesquisa para a seleção do modelo de medida, consultando periódicos especializados, livros, relatórios técnicos e dissertações ou teses. Schumacker et al. (2021) fornecem uma lista extensa para busca de testes e medidas como ponto de partida. Existem diversas revisões sistemáticas (ou meta-análise) da literatura de modelos de medida sobre um tema, área ou construto. Nunca deixe de conferir os artigos originais da escala e relevantes aplicações subsequentes. Kline (2016, p. 29) apresenta um interessante checklist para avaliar modelos de medidas potenciais.

Evite se aventurar em modelos de medida construídos para propósitos específicos e sem rigor psicométrico (Flake & Fried, 2020; Kline, 2016). A simples existência de uma escala não indica que ela é válida (Flake et al., 2017). Além disso, não confie indiscriminadamente em escalas utilizadas pouquíssimas vezes ou construídas há muito tempo, pois isso pode ser um indicativo de fracas propriedades psicométricas. Evite também pegar uma escala aplicada em outra língua e fazer um processo de tradução/retradução “rápido”, aplicando-a em uma única amostra. Não oculte estruturas fatoriais alternativas (modelos de ordem superior ou bifactor) para um mesmo modelo de medida, pois se o pesquisador acha que terá mais “trabalho”, essas estruturas alternativas, com alguma relevância e justificativa teórica, pode ser a salvação da pesquisa (Crede & Harms, 2019).

Justifique as boas propriedades psicométricas da escala selecionada, indicando as evidências empíricas anteriores de emprego na população almejada, medidas de confiabilidade e validade (Flake & Fried, 2020; Jackson et al., 2009; Kline, 2016). Se para uma mesma escala existir diferentes estruturas fatoriais esperadas (modelos de ordem superior ou bifactor), justifique as comparações que serão empreendidas para não utilizar a AFC para fins exploratórios (Jackson et al., 2009).

Especifique seu modelo preferido e apoie sua escolha discutindo os méritos de seu modelo preferido em relação a modelos teóricos equivalentes e concorrentes (Jackson et al., 2009). Represente graficamente os modelos testados (Jackson et al., 2009). Defina e descreva, a priori, a partir das evidências empíricas anteriores, as suspeitas de cross-loadings (Brown, 2023; Nye, 2022).

Considerando que a escala selecionada poderá estar no contexto de um questionário de pesquisa mais amplo, em linha com as propostas de triagem procedimental da literatura de Careless/ Insufficient Effort Responding (C/IER) (Curran, 2016; Huang et al., 2026; Ward & Meade, 2023), como detalharemos adiante, recomenda-se planejar desde o desenho do instrumento a inclusão de itens de atenção explícita (por exemplo, instructed response items e, quando apropriado, bogus/infrequency items) e o registro do tempo de resposta do questionário, se possível em nível de página, de modo a permitir, em um nível mínimo de triagem, a identificação de respondentes que não leram os itens ou que completaram o questionário em velocidade incompatível com um processamento cuidadoso das perguntas (Ward & Meade, 2023).

2.2 Análise de Poder

Primeiramente, uma das questões mais importantes a se ressaltar sobre a Análise de Poder (AP) é o que não fazer: não justifique a decisão de tamanho amostral com base em regras de bolso. Existem regras de bolso que vão ao encontro das mais diversas demandas: i) alguns estudos indicam tamanho mínimo (n) de 50, 100, 200, 300, 400, 500 e 1.000; outros estudos indicam ii) critérios número de observações/quantidade de parâmetros (n/p): 20/1, 10/1, 5/1 (Kline, 2023; Kyriazos, 2018). Essas sugestões são baseadas em situações específicas, estudos de simulação com design particular, e podem não estar de acordo com o cenário da sua pesquisa.

É importante ressaltar que não se deve confiar em tamanhos amostrais de limite inferior para substituir a AP para detectar efeitos-alvo (Westland, 2010). Esse tamanho de amostra representa o n mínimo necessário para qualquer modelo, e praticamente garantirá poder inadequado para detectar efeitos-alvo de tamanho equivalente no modelo em estudo (Wang, 2023). Nesse sentido, deveria ser evitada a calculadora de Soper (2026), disponível em: <https://www.danielsoper.com/statcalc>; e muito utilizada nos estudos empíricos (em 14/09/2026, com cerca de quatro anos de existência, acumulava mais de 2.000 citações no Google Scholar).

Regras gerais para requerimentos de tamanho amostral no contexto da SEM, devido ser uma técnica complexa, são impraticáveis (Kyriazos, 2018), e uma estratégia mais produtiva e moderna tem sido adaptar o poder amostral para cada estudo, acomodando o contexto específico da pesquisa e considerando suas questões focais (Feng & Hancock, 2023; Moshagen & Bader, 2024). Não existe “regra-de-ouro” sobre tamanho amostral ou tamanho mínimo de amostra para todos os estudos (Kline, 2023).

Apesar da opção de se executar a AP *a posteriori*, sugere-se que o planejamento amostral

seja realizado antes de coletar os dados (*a priori*) (Feng & Hancock, 2023). Procedendo dessa forma, naturalmente, o pesquisador adquirirá maior entendimento sobre sua pesquisa (Leite et al., 2023). Isso porque, como veremos, algumas decisões devem levar em conta algum conhecimento sobre a literatura subjacente e parâmetros populacionais conhecidos sobre o modelo de medida em avaliação (Feng & Hancock, 2023). Se o pesquisador levou a primeira etapa a sério, a AP *a priori* torna-se um trabalho menos árduo.

A AP *a priori* garante que o pesquisador tenha uma amostra suficientemente grande para detectar os efeitos que se está interessado em estudar (minimização de erros do tipo II). Isso aumenta a confiabilidade de obter resultados válidos, replicáveis e comparáveis com outras pesquisas na área, facilitando as metas-análises, por exemplo. Também evita o desperdício de tempo e recursos, coletando dados de uma amostra maior do que o necessário, e ajuda a definir o orçamento para a coleta de dados, otimizando o planejamento da pesquisa (Feng & Hancock, 2023).

Dentro da SEM a AP pode ser realizada analiticamente, com base na teoria assintótica, ou por meio de simulação. A abordagem analítica requer a definição do efeito de interesse em termos de uma medida que mostre uma relação direta com o parâmetro de não centralidade. A AP simulada obtém uma estimativa empírica do poder através de um modelo populacional ou considerado verdadeiro (Moshagen & Bader, 2024). Existem duas avaliações principais para as quais o poder é relevante: o ajuste global do modelo e os parâmetros do modelo. Em qualquer uma dessas avaliações podemos utilizar tanto métodos analíticos quanto de simulação (Feng & Hancock, 2023).

Geralmente, numa AFC, estamos procedendo a validação de um modelo de medida para um passo posterior e nesse sentido recomenda-se, no mínimo, que se avalie o poder relevante de um ajuste global do modelo de medida (Nye, 2022; Wang, 2023). Apesar das limitações das soluções analíticas (Feng & Hancock, 2023), podemos utilizá-las como ponto de partida e complementar aos métodos de simulação (Moshagen & Bader, 2024).

Existem formas acessíveis de se proceder as soluções analíticas para a AP do ajuste global (Wang, 2023): 1) baseada no teste qui-quadrado não central (solução Saris-Satorra); ou 2) baseada na estatística RMSEA de um modelo corretamente/incorrectamente especificado (solução de MacCallum e outros). Como exemplos dessas opções temos os ShinyApps: i) <https://sjak.shinyapps.io/power4SEM/> de Jak et al. (2021); ii) <https://sempower.shinyapps.io/sempower/> de Moshagen & Bader (2024); iii) <https://yilinandrewa.ng.shinyapps.io/pwrSEM/> de Wang & Rhemtulla (2021); e o aplicativo WebPower (<https://webpower.psychstat.org/>) de Zhang & Yuan (2018).

Esse último é o mais completo e apresenta soluções baseadas na Simulação de Monte Carlo (SMC), nos permite contemplar valores *missing* e dados não-normais, e principalmente, podemos fazer tudo através de diagramas, sem necessidade de *script*. A solução de Wang & Rhemtulla (2021) também tem a opção de utilizar simulação, e todas elas também incorporam a AP de um efeito específico (parâmetro do modelo). Para uma visão geral sobre essas soluções e revisão dos métodos analíticos veja Feng & Hancock (2023), Jak et al. (2021), Nye (2022) e Wang (2023).

No entanto, uma escolha inteligente é executar uma SMC para a AP de seu modelo AFC a partir de soluções que sejam condizentes com a reprodutibilidade e replicabilidade dos resultados. Nesse sentido, até mesmo as soluções analíticas, que o pesquisador pode tomar como ponto de partida, sugere-se o ambiente *R* através dos pacotes semTools (Jak

et al., 2021) e semPower 2 (Jobst et al., 2023; Moshagen & Bader, 2024).

Para a SMC no contexto da SEM a escolha inteligente seria utilizar o pacote *simsem* (Pornprasertmanit et al., 2022). Na sequência se pontua um misto de razões pragmáticas e teóricas para essa sugestão:

- A abordagem analítica depende fortemente das distribuições de amostragem conhecidas e propriedades assintóticas da estatística de teste. Entretanto, muitas dessas suposições podem ser facilmente relaxadas ao usar a SMC, que se mostra cada vez mais popular devido à sua flexibilidade para se adaptar a vários cenários de pesquisa (dados categóricos, valores ausentes, estudos longitudinais, ajuste local e global, etc.) (Feng & Hancock, 2023), inclusive, com a possibilidade de se utilizar as versões robustas do estimador ML, como veremos adiante;
- A SMC exige que o pesquisador forme a base de conhecimento do seu modelo de medida populacional, no qual os verdadeiros valores dos parâmetros são conhecidos, e ajuda apoiar a validade das inferências obtidas de suas análises (Leite et al., 2023). Por exemplo, os resultados obtidos com a SMC podem indicar os pontos de cortes dos índices de ajustes globais utilizados nas etapas posteriores;
- A desvantagem que a SMC exige substancial poder de computação e tempo, para modelos complicados (Nye, 2022), se sustenta parcialmente na prática (Byrne, 2016). Primeiro, porque na maioria das aplicações empíricas os modelos AFC não são tão complexos. Segundo, porque o poder computacional atual e a computação em nuvem oferecem soluções escaláveis e acessíveis para pesquisas que demandam alto poder computacional. Diversos caminhos podem ser utilizados para otimizar a SMC, tal como a seleção de parâmetros eficientes, algoritmos de estimação avançados e dividir o estudo em etapas (Leite et al., 2023). E por último, somente a SMC produz uma solução realista para modelos complexos (Moshagen & Bader, 2024);
- Por mais que possa ressoar contraintuitivo e/ou alguns cientistas sociais encarar com ceticismo: a SMC é fácil de aprender (Nye, 2022; Wang, 2023; Wang & Rhemtulla, 2021) ou tão difícil quanto a abordagem analítica Saris-Satorra para analisar o efeito de um parâmetro específico. A lógica por trás da SMC é relativamente simples (Leite et al., 2023), e o conhecimento básico de estatística é suficiente para compreender os princípios da técnica. Tutoriais e documentações completas facilitam o aprendizado e a utilização da SMC no contexto da SEM, como é o caso do pacote *simsem* (<https://simsem.org/>), cujos exemplos são variados e didáticos. Esse pacote faz uso da syntax do lavaan, e caso o cientista social já o utilize ou pretenda seguir os passos desse manuscrito executável, estará bem adiante na curva de aprendizado. Nesse sentido, se considerar as habilidades necessárias para o entendimento das soluções analíticas, e o conforto de funções predefinidas para calcular o poder estatístico para diferentes tipos de modelos e designs de pesquisa, a partir de uma syntax conhecida, a flexibilidade da SMC mais do que compensa qualquer esforço marginal que possa existir (Feng & Hancock, 2023).

Cremos que a prática de reportar o planejamento amostral para o(s) modelo(s) de medida auxilia na replicabilidade e reprodutibilidade da ciência (Flake et al., 2017; Flake et al., 2022), contribuindo para acumular evidências de validade da estrutura interna (Flake & Fried, 2020) e externa (Leite et al., 2023). No contexto da AFC, um baixo poder porventura que deixamos passar, pode acender um sinal de alerta para as inferências

procedidas a partir do modelo completo (modelo de medida + estrutural). A SMC é uma escolha inteligente para avaliar o poder do modelo de medida, pois a validade externa muitas vezes supera a precisão: informações precisas sobre um resultado irrelevante são muitas vezes menos úteis do que informações imprecisas sobre um resultado relevante (Leite et al., 2023).

2.3 Pré-processamento

A qualidade dos dados é condição necessária, embora não suficiente, para que os parâmetros estimados numa AFC sejam válidos e interpretáveis. Além das inconsistências técnicas (e.g., vide Whittaker & Schumacker (2022)) e do Common Method Bias (CMB, vide Podsakoff et al. (2012)), a etapa de pré-processamento deve considerar sistematicamente as Respostas com Insuficiência de Esforço (C/IER). C/IER designa as respostas fornecidas sem atenção ou esforço suficiente ao conteúdo dos itens, abrangendo padrões aleatórios e não aleatórios, como *straightlining*, respostas concentradas no meio da escala e padrões repetitivos (Curran, 2016; Huang et al., 2015).

É importante distinguir C/IER de outros fenômenos de resposta: a Desejabilidade Social e a Aquiescência, por exemplo, constituem ameaças à validade baseada nos processos de resposta, conforme discutido na introdução deste artigo. O C/IER opera em nível distinto: quando respostas desatentas contaminam múltiplas medidas autorrelatadas na mesma direção, elas introduzem variância compartilhada não substantiva que funciona como uma fonte de *Common Method Variance* (CMV) e pode gerar CMB, distorcendo correlações, cargas fatoriais e inferências (Huang et al., 2015). Assim, C/IER pode ser entendido como um caso particular e contingente de CMV/CMB, distinguindo-se da simples noção de erro aleatório de medição. A revisão de Huang et al. (2026) evidencia que a triagem de C/IER ainda carece de padronização, reforçando a necessidade de incorporá-la formalmente ao workflow de pré-processamento.

Uma vez os dados originais tabulados, de preferência em arquivos não binários (.csv, .txt, .json, etc.), a primeira ação a se tomar é excluir as respostas dos entrevistados que, efetivamente, abandonaram a pesquisa. Às vezes acontece desse indivíduo ficar na base de dados e somente ao final do pré-processamento nos darmos conta. Enquanto isso, ele serviu de informação para o tratamento dos *missings*, *outliers* e a multicolinearidade.

Se o pesquisador colocou questões de controle no questionário e consegue mensurar o tempo de resposta, nesse momento também deve excluir observações de respondentes que escolheram as questões de controle incorretamente e terminaram o questionário em tempo consideravelmente menor do que o esperado (Collier, 2020). Na terminologia C/IER, esses correspondem aos métodos procedurais de detecção: os itens de controle (*instructed response items* ou *infrequency items*) e o tempo de resposta do questionário ou por página (*page time*) são os procedimentos a priori mais recomendados pela literatura (Curran, 2016; Huang et al., 2026) e devem ser planejados prospectivamente, desde a concepção do instrumento.

No âmbito dos métodos *post hoc* de detecção de C/IER, calcule o índice *Intraindividual Response Variability* (IRV) de cada indivíduo para avaliar a variabilidade das respostas aos itens. O IRV representa o desvio-padrão das respostas do indivíduo, e valores iguais a zero ou muito perto de zero correspondem, na literatura C/IER, a *straightlining*, uma forma sistemática de C/IER que pode inflar artificialmente a consistência interna da escala. Complementarmente, o *Long String* (LS) quantifica a maior sequência de respostas idênticas consecutivas, sendo especialmente sensível a respondentes que

selecionam repetidamente a mesma opção (Curran, 2016; Hong et al., 2020). Em casos que o IRV é alto há indícios de padrões de resposta aleatórios, inconsistente com respostas esperadas de itens dentro de um mesmo constructo (Curran, 2016; Hong et al., 2020).

A detecção de *outliers* deve ser integrada ao protocolo de triagem C/IER e tratada como etapa do pré-processamento. Padrões de resposta aberrantes comprometem a estrutura de covariância dos dados e podem distorcer a solução fatorial antes mesmo de qualquer ajuste de modelo. A Distância de Mahalanobis (MD) é o indicador multivariado mais utilizado: estima a distância entre o vetor de respostas de cada indivíduo e o vetor médio da amostra, sendo sensível a padrões de resposta aleatórios (Curran, 2016; Hong et al., 2020).

A recomendação consolidada é empregar um subconjunto complementar de índices, tal como, por exemplo: algum método procedural, IRV e MD (*best subset approach*); pois cada indicador captura manifestações distintas de C/IER; a combinação de todos os índices disponíveis (*kitchen sink approach*) tende a reduzir a especificidade sem ganho equivalente de sensibilidade (Hong et al., 2020).

O pesquisador pode optar por ser mais leniente em cada um dos critérios *post hoc*, examinando os casos suspeitos (perfil de resposta) antes de proceder à exclusão: a presença concomitante de IRV baixo, LS elevado e MD atípica oferece evidência mais robusta de C/IER do que qualquer indicador isolado (Curran, 2016; Hong et al., 2020; Huang et al., 2026). No entanto, pode optar por não desistir de excluir os indivíduos que gastaram menos de 2 segundos por item (Huang et al., 2026) ou não passaram em todos *instructed items*.

Sobre a multicolinearidade, calcule o fator de inflação de variância (VIF) de cada um dos itens e considere a exclusão daqueles com alta multicolinearidade ($VIF > 10$) (Whittaker & Schumacker, 2022). Na AFC, cujo foco reside em constructos reflexivos, a correlação entre os itens é desejável (Grewal et al., 2004), mas nem tanto ao ponto de causar problemas de convergência dos modelos (Flora et al., 2012; Kline, 2023; Whittaker & Schumacker, 2022). A alta colinearidade ou multicolinearidade entre as variáveis observadas é uma das principais causas de uma matriz não-positiva definida (Flora et al., 2012; Kline, 2023), e mesmo se o modelo convergir com sua presença, pode acarretar em interpretações equivocadas (Marsh et al., 2004) e/ou indicar falta de validade discriminante (Grewal et al., 2004).

O tratamento dos *missings*, não necessariamente, precisa ser considerado na etapa inicial de *data screening*. No caso, evite a imputação única (*listwise*, *pairwise*, *mean-substitution*, *regression substitution* e *pattern matching*). Todos os métodos de imputação única tendem a subestimar a variância do erro, especialmente se a proporção de observações ausentes for relativamente alta, e algumas dessas técnicas podem causar problemas de identificação (Enders, 2023). Poucos valores faltantes, como 5% no conjunto total de dados, podem ser pouco preocupantes (Kline, 2023), mas devem ser tratados por imputação múltipla (MI) ou Full Information ML (FIML).

A escolha inteligente em grande parte das aplicações empíricas de AFC reside em optar por FIML, na etapa de estimação: na maioria dos casos representa a melhor e mais fácil maneira de tratar os *missings* (Brown, 2023). Na MI os resultados podem ser alterados sempre que o método é aplicado ao mesmo modelo e dados, dificultando a replicabilidade; em contraste, há uma única solução para o FIML. Há mais decisões potenciais a serem tomadas na abordagem MI do que na FIML (Kline, 2023). Quando os estimadores são

direcionados para ML ou suas variações robustas MLR ou MLM, a escolha pragmática reside em optar por FIML (Brown, 2023).

A transformação dos dados para linearização ou normalização não se mostra uma estratégia inteligente, tendo em vista a disponibilidade e facilidade de procedimentos de estimativa robustos (Brown, 2023). Outra recomendação é não parcelar os itens, pois (i) existem muitas estratégias de fazer isso e (ii) pode mascarar a multidimensionalidade (Brown, 2023; Crede & Harms, 2019).

Inspecções visuais e descritivas dos itens do modelo de medida estão implícitas, recomendadas e salutares em qualquer análise estatística. Existem várias formas para isso, mas debruçar sobre esses procedimentos, assim como outras questões do pré-processamento abordadas na literatura (Brown, 2023; Collier, 2020; Flora et al., 2012; J. Hair et al., 2019; Kline, 2023; Whittaker & Schumacker, 2022), considera-se desnecessário para os fins desse manuscrito.

Em suma, reporte todos os procedimentos para limpar os dados. Seja transparente em relação aos *missings*. Todo pesquisador enfrenta esse problema, e em doses pequenas, é possível de tratamento e não invalida o estudo (Crede & Harms, 2019). Execute e reporte estratégias para avaliar o engajamento dos respondentes e a triagem de C/IER, incluindo os índices utilizados, os pontos de corte adotados e a proporção de casos removidos (Huang et al., 2026). Reporte indícios de multicolinearidade mesmo antes de começar a AFC. Reporte o software e/ou pacotes utilizados com suas devidas versões (Flake & Fried, 2020; Jackson et al., 2009). Disponibilize os dados brutos ou a matriz de covariância/correlação dos itens (Crede & Harms, 2019; Flake et al., 2022; Flake & Fried, 2020).

2.4 Processo de Estimação

Numa AFC cujos itens são ordinais, ou seja, com opções de resposta do tipo Likert de até cinco pontos, Rogers (2024) argumenta, através de uma extensa literatura, que devemos utilizar os estimadores da família OLS (Ordinary Least Squared), preferencialmente ULS (Unweighted LS) na sua versão robusta (RULS), para amostras menores, ou DWLS (Diagonally Weighted LS) na sua versão robusta (RDWLS), para amostras maiores.

No entanto, conforme argumentado da introdução, algumas evidências empíricas (Rhemtulla et al., 2012; Robitzsch, 2022) e argumentos teóricos (Robitzsch, 2020) sugerem que metodologia contínua na presença de dados ordinais produzirá resultados aceitáveis quando o número de categorias for cinco ou mais. Com 6-7 categorias, os estudos (Rhemtulla et al., 2012) encontram semelhanças entre os métodos para muitas condições e recomendam o uso de um grande número de alternativas de resposta (5) para aumentar o poder de detectar modelos incorretos (Maydeu-Olivares et al., 2017).

Apesar do estimador ML ser robusto a pequenos desvios de normalidade (Brown, 2015), nessas condições: presença de assimetria e excesso de curtose, ou seja, onde a falta de normalidade (moderada ou severa) é a regra e não exceção; alguns argumentos (Robitzsch, 2020) são direcionados para se utilizar as versões robustas do estimador ML, particularmente o MLR (Huber-White standard errors and Yuan-Bentler scaled 2).

Existem vários métodos para gerar erros-padrão robustos e estatísticas de teste ajustadas com propriedades semelhantes (Kline, 2023), mas o MLR tem aplicações mais amplas, como a estimativa de modelos com dados faltantes (RFIML) ou modelos onde os dados violam a suposição de independência de observações (Brown, 2015; Rosseel,

2012). Adicionalmente, acumulam algumas evidências empíricas favoráveis, ou que não desabonam o MLR, comparativamente às outras opções de estimadores (Bandalos, 2014; Holgado-Tello et al., 2016; Li, 2016; Nalbantoğlu-Yılmaz, 2019; Yang & Liang, 2013; Yang-Wallentin et al., 2010).

De qualquer forma, reporte e justifique o método de estimação utilizado a partir das características dos dados disponíveis e modelo a ser ajustado (Crede & Harms, 2019). Reporte todos os problemas ocorridos com a estimação, tal como não convergência dos algoritmos e modelos não identificados (Nye, 2022). Caso haja problemas nesse sentido, um plano B seria optar pelos estimadores MLM (robust standard errors and Satorra-Bentler scaled χ^2) ou ML default com bootstrapping não paramétrico modificado por Bollen-Stine (Brown, 2015; Kline, 2023). Essa última solução pode englobar dados missings (Kline, 2023). Além disso, indique se fixou a variância ou uma variável marcadora ($=1$) para definir a escala da variável latente (Jackson et al., 2009) e reporte os parâmetros padronizados e não padronizados (Nye, 2022).

2.5 Ajuste do Modelo

Nessa seção também nos parece sensato começar com a indicação do que não fazer: não utilize os cutoffs tradicionais, seja aqueles mais conservadores (SRMR .06, RMSEA .06 e CFI .95) ou menos conservadores (RMSEA .08, CFI .90 e SRMR .08). Ultrapassar um conjunto de valores de corte não deve ser a principal justificativa para aceitar um modelo (Xia & Yang, 2019). Os cutoffs tradicionais foram concebidos a partir de estudos de simulação que levaram em conta no máximo uma estrutura com 3 fatores, 15 itens e cargas fatoriais entre 0.7 e 0.8 (West et al., 2023). Os cutoffs tradicionais são sensíveis ao número de itens e fatores, graus de liberdade do modelo, magnitude das cargas fatoriais, tipo de desajuste e missing data (Groskurth et al., 2024; Niemand & Mai, 2018; West et al., 2023).

Todos os índices globais têm suas limitações e vantagens (West et al., 2023). Analise os principais índices globais (SRMR, RMSEA e CFI) em conjunto e não tome um em particular (Mai et al., 2021; Niemand & Mai, 2018). Se algum índice global indicar um desajuste, mesmo que pequenos desvios dos cutoffs tradicionais (SRMR .06, RMSEA .06 e CFI .95), pode ser necessária uma investigação mais aprofundada para demonstrar que o desajuste se deve às características dos dados ou a uma limitação do índice em vez de uma especificação incorreta do modelo (Nye, 2022).

Nesse sentido, trate os índices convencionais de ajuste global mais como um tamanho de efeito, como originalmente foram concebidos (McNeish & Wolf, 2023b), do que um teste de hipótese *ad hoc* em que se toma uma decisão de rejeitar/não rejeitar o modelo (McNeish, 2023b). O SRMR parece ser mais robusto sob a uma variedade maior de situações (Mai et al., 2021), como a falta de normalidade e/ou nível de mensuração dos itens (Maydeu-Olivares et al., 2017; Shi et al., 2020; Shi & Maydeu-Olivares, 2020). No mais, utilizar o par SRMR/CFI parece ser suficiente para balancear os erros Tipo I/Tipo II, e empregar diversos índices poder inflar o erro do Tipo I (Mai et al., 2021; Niemand & Mai, 2018).

O Dynamic Fit Index (DFI) parece ser um bom método para avaliar o índice de ajuste global (McNeish, 2023a). Trata de uma proposta baseada em simulação em que temos pontos de corte específico para o modelo em questão. A lógica dessa estratégia é que ela imite a estratégia usada para derivar os cutoffs tradicionais, mas adapta o design da simulação ao subespaço do modelo que corresponde ao modelo empírico em avaliação

(McNeish, 2023a, 2023b; McNeish & Wolf, 2023a; McNeish & Wolf, 2023b). Visto dessa forma, essa sugestão também pode ser abordada na etapa 2 (Seção 2.2), tendo como base de conhecimento o modelo de medida populacional (ou não, dependendo da abordagem), pois trata de incorporar as ideias da AP nas avaliações de índices de ajuste (McNeish & Wolf, 2023a).

Outra sugestão de simulação customizada é a proposta Flexible Cutoffs (FCO) (Mai et al., 2021; Niemand & Mai, 2018). Apesar do FCO não exigir que os pesquisadores identifiquem um modelo mal especificado, assim como o DFI, essa abordagem define um modelo mau especificado de forma conservadora, e altera o foco de ajuste aproximado para ajuste exato (McNeish & Wolf, 2023a).

De qualquer forma, mesmo sem informações aproximadas do tamanho do efeito, Mai et al. (2021) e Niemand & Mai (2018) apresentam evidências favoráveis que a proposta FCO permite o equilíbrio entre erros do Tipo I e Tipo II, além de que essa abordagem ‘*sui generis*’, desenvolve valores de corte que atendem de forma flexível às características dos dados e do modelo, é particularmente eficaz na área cinza (crítica) de especificação incorreta (erro Tipo I), melhora a detecção de erro tanto no modelo estrutural quanto no modelo de medição, e leva em conta a não normalidade dos dados (Niemand & Mai, 2018). Particularmente, nas situações enfatizadas no presente manuscrito, modelo de medida (AFC) estabelecido na literatura, o equilíbrio entre erros do Tipo I/Tipo II é mais importante do que o erro Tipo II num modelo de medida novo (Mai et al., 2021).

Caso seja uma barreira (McNeish & Wolf, 2023a) e o pesquisador não pretenda aventurar no “mundo” da simulação, uma outra opção seria o Equivalence Testing (EQT). A ideia por trás do EQT é a mesma das soluções analíticas da AP (Seção 2.2), e incorpora a lógica do DFI, quando adota a visão de que a o método convencional de teste de hipóteses (NHT) não é interessante, pois uma estatística de teste não significativa não implica, necessariamente, que o modelo está corretamente especificado, ou que o tamanho da especificação incorreta seja adequadamente controlada (Yuan et al., 2016).

Em vez de usar os cutoffs tradicionais para orientar uma avaliação aproximada do ajuste, o EQT pode ser uma alternativa (McNeish, 2023b), pois refere-se a limites como tamanho de tolerância (ou valor T-Size), que inclui a variabilidade amostral no índice de ajuste em vez de usar a estimativa pontual estimada. O valor T-Size é, portanto, o valor que é comparado com os diferentes valores de referência ajustados [por exemplo, os pontos de corte tanto para o RMSEA (0,01; 0,05; 0,08 e 0,10) quanto para o CFI (0,99; 0,95; 0,92 e 0,90) têm sido comumente utilizados para distinguir entre modelos excelentes, bons, regulares e medíocres/ruins, respectivamente] para determinar qual grau de ajuste pode ser endossado (Marcoulides & Yuan, 2017).

O EQT é uma maneira inteligente de trazer raciocínio inferencial para a avaliação aproximada do ajuste, incorporar a variabilidade amostral na avaliação do ajuste, permitir aos pesquisadores a capacidade de endossar um determinado nível de ajuste, e de implementar porque não depende da simulação de benchmarks (McNeish, 2023b). Apesar de melhor do que os cutoffs tradicionais, o EQT ainda retém algumas de suas propriedades indesejáveis, como não se aplicar em uma ampla gama de características de modelos (McNeish, 2023b).

Complementando o que não fazer: não utilize o Alfa de Cronbach como medida de confiabilidade (Bell et al., 2023; Cho, 2022; T. J. Dunn et al., 2014; Flora, 2020; Goodboy & Martin, 2020; Green & Yang, 2015; Hayes & Coutts, 2020; Kalkbrenner,

2023; McNeish, 2018; Trizano-Hermosilla & Alvarado, 2016). Não utilize o χ^2 sem o devido ajuste (Yuan-Bentler scaled χ^2 , por exemplo) (Crede & Harms, 2019).

Dito isso, inicialmente, inspecione se existem casos Heywood: cargas fatoriais padronizadas > 1 ou variâncias negativas (Nye, 2022). Avalie os índices de ajuste local: baixa carga fatorial, cross-loadings, correlação residual ($> 0,10$), índices de modificação ($> 3,84$) e estimated parameter change (EPC) (Nye, 2022). Use como medida de confiabilidade o Ω de McDonald e/ou o GLB (greatest lower bound) no contexto do modelo AFC ajustado (Bell et al., 2023; Cho, 2022; T. J. Dunn et al., 2014; Flora, 2020; Goodboy & Martin, 2020; Green & Yang, 2015; Hayes & Coutts, 2020; Kalkbrenner, 2023; McNeish, 2018; Trizano-Hermosilla & Alvarado, 2016).

Calcule e reporte antes de iniciar o ajuste do modelo (Jackson et al., 2009) os cutoffs que serão utilizados como ancoras. Se utilizar a metodologia DFI (McNeish & Wolf, 2023b), para modelos mais simples de AFC, como unifatorial e multifatorial sob a hipótese de normalidade, o pesquisador pode acessar os valores DFI's via ShinyApp: <https://www.dynamicfit.app/connect/> (acesso em 21/02/2024). Para situações mais complexas: como abordar não normalidade, modelos bifactor e de segunda-ordem; e se ensaja a replicabilidade e reprodutibilidade, faz-se necessário o pacote *dynamic* (Wolf & McNeish, 2023) do R, cujas funções fazem uso de objetos lavaan (Rosseel, 2012). Nesse pacote também podemos calcular o EQT, apesar da existência de outras soluções (Yuan et al., 2016), até mesmo incorporadas nativamente em softwares *point-and-click*, como o JASP (Rogers, 2024). Para implementar o FCO podemos utilizar o pacote *FCO* do R (Mai et al., 2021; Niemand & Mai, 2018).

Reporte o χ^2 ajustado e os graus de liberdade (df) (Crede & Harms, 2019). Reporte no mínimo os seguintes índices de ajuste global: RMSEA, CFI e SRMR. Note que, como utilizará o scaled χ^2 , essas medidas também devem ser ajustadas tendo em vista o método empregado (Nye, 2022). Reporte, no mínimo, o Ω de McDonald, mas preferencialmente, acompanhado do GLB ou outra medida de confiabilidade composta (Trizano-Hermosilla & Alvarado, 2016). Reporte todas as decisões de ajuste do modelo (Flake & Fried, 2020), condizentes com a avaliação das medidas de ajuste local (baixa carga fatorial, cross-loadings, correlação residual, índices de modificação e EPC). Reporte o tamanho das correlações residuais e índices de modificação (Crede & Harms, 2019).

2.6 Comparações e Modificações dos Modelos

Já na primeira etapa sugerimos aos pesquisadores não ocultar estruturas fatoriais alternativas para um mesmo modelo de medida. Uma boa prática seria considerá-las na pesquisa desde o início (planejamento da pesquisa) e compará-las. O pesquisador pode ter um modelo preferido, mas selecione-o discutindo seus méritos em relação a modelos teóricos equivalentes e concorrentes (Jackson et al., 2009). Nenhum modelo pode refletir perfeitamente a verdade, então consideramos os modelos como aproximações da realidade (Preacher & Yaremych, 2023).

Para que o conhecimento nas ciências sociais se acumule de forma genuína, é crucial que as diferentes teorias sejam comparadas e testadas ao longo do tempo, construindo um histórico de acertos e erros. Diversas características definem um bom modelo, como interpretabilidade, simplicidade e capacidade de generalização. No entanto, o mais importante é que ele apresente desempenho superior a seus rivais em aspectos relevantes. Dessa forma, a teoria escolhida se torna uma "melhor hipótese de trabalho" até que uma alternativa mais eficiente surja (Preacher & Yaremych, 2023).

Os índices de ajuste são mais úteis para avaliar a qualidade de um único modelo isoladamente. Um bom ajuste transmite que o modelo é apenas uma representação plausível da estrutura real subjacente. Assumindo que os modelos concorrentes foram selecionados *a priori*, baseados em teorias reais, a comparação de vários modelos é uma abordagem preferível à avaliação de modelos individuais (Preacher & Yaremych, 2023).

Na seleção de modelos, o pesquisador ajusta um conjunto de modelos ao mesmo conjunto de dados, utilizando o mesmo software e tamanho de amostra. Isso garante que os graus de liberdade do pesquisador sejam mantidos relativamente constantes, mitigando o risco de manipulação dos resultados. Essa padronização promove uma abordagem mais honesta e científica para a investigação (Preacher & Yaremych, 2023).

Ao comparar o desempenho de diferentes modelos em aspectos relevantes, a seleção de modelos identifica a melhor opção para explicar o fenômeno em estudo. Essa abordagem não se limita à escolha de um único modelo, permitindo descartar aqueles com desempenho ruim e manter um conjunto de modelos de bom desempenho para análises posteriores. Essa flexibilidade garante uma investigação mais profunda e completa do problema em questão (Preacher & Yaremych, 2023).

Em suma, a seleção de modelos é uma ferramenta valiosa para o avanço do conhecimento nas ciências sociais. Ela promove a honestidade científica, incentiva práticas rigorosas e oferece flexibilidade na análise de dados, contribuindo para a construção de um conhecimento científico mais sólido e confiável (Preacher & Yaremych, 2023).

De qualquer forma, se um modelo individual não apresentar boas medidas de ajuste, modificações podem ser necessárias: certifique que elas são teoricamente sustentáveis, por exemplo, pesquise se o mesmo que está acontecendo na pesquisa aconteceu em pesquisas anteriores (Nye, 2022).

Achar que nenhum ajuste deve ser feito num determinado modelo de medida validado em pesquisas anteriores, e seguir a pesquisa com desajuste substancial, pode ser um problema: as falhas de ajuste na AFC podem proliferar para o modelo estrutural (Brown, 2023), e em certa extensão, alguns ajustes na AFC podem dirimir problemas na estimação das relações estruturais (Flake et al., 2017; Jackson et al., 2009).

No entanto, não considere mudanças drásticas nos modelos de medida (Brown, 2023): cogite voltar um ou dois passos atrás, empregar uma AFE ou considerar outra escala, por exemplo, ou seguir um passo à frente: buscar ajustar modelos ESEM (Exploratory SEM) para modelar eficientemente os cross-loadings (Crede & Harms, 2019).

Em tese, o pesquisador pode modificar o modelo até alcançar um ajuste perfeito (modelo saturado), porém sem nenhuma generalização (validade externa): lembre-se que as modificações mudará o status epistemológico de confirmatório para exploratório (West et al., 2023). No bojo das principais modificações temos a previsão de correlações entre os itens do modelo de medida, que devem ser encorajadas se: i) os itens fazem parte do mesmo construto; ii) há justificativa teórica; iii) os itens são antônimos; e iv) há itens inversos. De uma forma geral, quando a correlação se justifica para dirimir o problema de CMB (Brown, 2023; Nye, 2022).

Nesse sentido, apesar de questionável (West et al., 2023), toda e qualquer mudança no modelo de medida deve ser relatada (Flake & Fried, 2020). Como se falou, o ideal é que esses potenciais ajustes sejam conhecidos *a priori* (Flake & Fried, 2020), para evitar embates epistemológicos (confirmatório *versus* exploratório), mas a verdade é que, na

prática, as modificações nos modelos de medidas são regras e não exceções (Flake et al., 2017; Nye, 2022). Apenas seja transparente (Flake et al., 2022; Flake & Fried, 2020). Exclusões de itens podem ser facilmente identificadas a partir dos outputs da pesquisa, no entanto, contemplar correlações entre itens não: relate toda e qualquer correlação entre itens que foi prevista para melhorar o ajuste do modelo e descreva a justificativa teórica (Nye, 2022).

Seja transparente e reporte o máximo de informações que puder sobre o ajuste do modelo de medida (Flake et al., 2022; Flake & Fried, 2020). Atualmente, não mais se sustenta a desculpa de limitação de espaço dos periódicos, pois o pesquisador pode deixar disponível, permanentemente, qualquer tipo de arquivo em um dos diversos repositórios Open Access existentes, e citá-lo no corpo do artigo. Esse artigo-tutorial é prova disso.

Porém, quais medidas se ancorar para comparar e selecionar modelos alternativos? Como relatado, os índices de ajuste discutidos na etapa anterior (SRMR, RMSEA e CFI) são limitados para comparar modelos (Preacher & Yaremych, 2023), apesar de algumas evidências favoráveis, seja para comparações aninhadas (aqueles pares para os quais os parâmetros livres de um modelo são um subconjunto daqueles do outro modelo) ou não-aninhadas (P.-H. Huang, 2017), dados com desvio de normalidade (Lai, 2020) e/ou categóricos (Lai, 2021a). Essas evidências sugerem pontos de cortes para variações de SRMR, RMSEA ou CFI (Preacher & Yaremych, 2023).

No caso de modelos aninhados podemos utilizar o χ^2 ajustado para comparações entre modelos (Brown, 2015). O teste de diferença do χ^2 ajustado pode ser realizado com as estatísticas produzidas pelo MLM (Satorra-Bentler scaled χ^2), ou como sugerido, pelo estimador MLR (Yuan-Bentler scaled χ^2). Não utilize o χ^2 sem o devido ajuste para comparar modelos (Brown, 2015). Ao contrário da análise baseada em ML, esses testes não podem ser realizados simplesmente calculando a diferença nos valores de χ^2 produzidos pelos modelos aninhados e de comparação. Isso ocorre porque uma diferença entre dois valores de χ^2 para modelos aninhados estimados por MLM ou MLR não é distribuída como χ^2 . Assim, deve-se utilizar um teste de diferença escalonada (Brown, 2015).

Para comparar modelos não aninhados (ou aninhados) a recomendação seria utilizar os critérios de informação AIC (Akaike Information Criterion) e BIC (Bayesian IC) (Preacher & Yaremych, 2023). Existem algumas formulações diferentes desses dois critérios, mas são assintoticamente equivalentes (Preacher & Yaremych, 2023). Esses dois critérios equilibram o ajuste e a parcimônia de diferentes maneiras, são baseados na log-verossimilhança (função discrepância) originadas na estimação ML, e por isso, herdam alguns dos aspectos problemáticos dos índices de ajuste absoluto, como falta de robustez para violações distribucionais, sensibilidade a diferentes tipos de má especificação, e pressupõe dados completos (Preacher & Yaremych, 2023). O AIC e BIC não devem ser usados para comparar modelos estimados por FIML (Lai, 2021b).

Em amostras relativamente pequenas, a penalidade por complexidade do AIC tem uma influência maior e modelos mais simples são selecionados. O BIC é similar ao AIC, mas com uma penalidade mais forte para a complexidade na maioria das situações, o que significa que tende a selecionar modelos mais parcimoniosos do que o AIC. O BIC enfatiza a consistência: se um modelo verdadeiro existe e está no conjunto a ser comparado, o BIC o seleciona medida que n aumenta (P.-H. Huang, 2017). O BIC selecionará o modelo no conjunto que fica mais próximo do verdadeiro processo gerador dos dados. Consistência e eficiência não podem ser maximizadas simultaneamente. O AIC é um

critério que enfatize a eficiência. Assim, geralmente é sensato relatar e interpretar o BIC e AIC (Preacher & Yaremych, 2023).

Considerando a literatura ainda incipiente sobre a seleção de modelos na SEM (Preacher & Yaremych, 2023) e as limitações das opções disponíveis, a recomendação principal é que a decisão seja baseada na experiência e conhecimento do pesquisador (Preacher & Yaremych, 2023). Sem um julgamento teórico, a aplicação de qualquer critério de seleção de modelo se torna ineficaz. Antes de iniciar a análise, é essencial usar a teoria subjacente para estabelecer um conjunto limitado de modelos defensáveis, conforme sugerimos desde o início. Além da adequação do modelo, a teoria e o julgamento são necessários durante a seleção do modelo para decidir quais modelos devem ser descartados ou mantidos, levando em consideração a interpretabilidade. Por fim, a teoria é empregada para guiar a interpretação dos resultados com base no(s) modelo(s) escolhido(s). Os critérios de seleção de modelos servem como ferramentas de apoio à decisão, mas não são os decisores finais (Preacher & Yaremych, 2023).

Mesmo com evidências acumuladas que validam o(s) modelo(s) de medida em estudo, se ainda existirem dúvidas significativas sobre a estrutura fatorial teórica e/ou nível de desajuste, o pesquisador tem a opção de prosseguir para a comparação de alternativas usando a SMC (Leite et al., 2023). Caso o pesquisador já tenha navegado pela SMC na fase de Análise de Poder (etapa 2), avançar na comparação dos modelos não exigirá esforços adicionais. Esse argumento torna-se ainda mais plausível se o pesquisador utilizou a abordagem FCO na etapa anterior, que também pode ser utilizada para comparar modelos aninhados (Mai et al., 2021; Niemand & Mai, 2018).

3 Seleção do modelo de medida

Utilizamos como exemplo a World Health Organization Quality of Life – Abbreviated Version (WHOQOL-Bref), um instrumento de autorrelato amplamente empregado na avaliação da qualidade de vida em diferentes populações e contextos culturais (Lin & Yao, 2022; Mosqueira Taipe et al., 2026; Skevington & Epton, 2018). O instrumento contém 26 itens com cinco categorias de resposta. Os dois primeiros abordam a percepção geral da qualidade de vida e a satisfação com a saúde; os demais 24 compõem os domínios físico (FIS), psicológico (PSI), relações sociais (SOC) e ambiente (AMB).

A escolha da WHOQOL-Bref permite desenvolver a recomendação apresentada na Seção 2.1: partir de um instrumento com estrutura teórica definida e evidências psicométricas acumuladas, cujos itens admitam uma estratégia de análise com dados que podem ser considerados contínuos. A presença de cinco categorias de resposta oferece suporte inicial a essa estratégia, conforme a fundamentação anterior, e suas implicações serão examinadas na descrição dos itens (Seção 5.3) e na estimação robusta (Capítulo 6). O objetivo do exemplo é explicitar as decisões de uma AFC e suas justificativas, preservando o conteúdo e o formato de resposta do instrumento.

As sínteses da literatura sustentam a estrutura de quatro domínios, embora também indiquem que sua aplicação exige atenção às relações entre determinados itens. Lin & Yao (2022) integraram resultados de 16 estudos de análise fatorial exploratória e corroboram a solução de quatro fatores pela sua interpretabilidade e parcimônia. Nessa solução, Q8, referente à segurança na vida diária, apresentou relação mais forte com o domínio psicológico do que com o ambiental, ao qual pertence teoricamente. Esse resultado mostra que o suporte à organização geral em quatro fatores pode coexistir com

relações entre itens e domínios que não correspondem a uma estrutura simples.

A revisão sistemática de Mosqueira Taipe et al. (2026) amplia essa discussão: dos 439 registros identificados, 36 estudos foram incluídos, e a estrutura de quatro fatores também foi identificada em 64% deles. A revisão sustenta a estrutura original, mas documenta modificações relacionadas a contextos culturais e clínicos, além de heterogeneidade nos procedimentos e no relato dos índices de ajuste. Portanto, esse conjunto de evidências justifica tomar os quatro domínios como ponto de partida e explicitar antecipadamente quais relações adicionais serão avaliadas.

Nesse sentido, a partir da leitura de Lin & Yao (2022), formulamos nosso modelo de análise primário, que inclui uma covariância residual entre Q3, sobre dor e desconforto, e Q4, sobre a necessidade de tratamento médico (Figura 1). Ambos pertencem ao domínio físico e são formulados em direção negativa à qualidade de vida. Sua proximidade de conteúdo e a formulação compartilhada tornam plausível uma associação que não seja inteiramente explicada pelo fator físico. Essa especificação também encontra precedente em estudos reunidos por Mosqueira Taipe et al. (2026). No contexto da discussão sobre Common Method Bias (CMB), tratamos essa covariância como uma hipótese de dependência local compatível com conteúdo ou método compartilhado.




Figura 1: Modelo de quatro fatores correlacionados com covariância residual entre Q3 e Q4. *Nota.* PSI = psicológico; FIS = físico; SOC = relações sociais; AMB = ambiente. A figura representa a especificação (cargas fixas) do modelo populacional. Ao estimarmos com parâmetros livres, as cargas e a covariância residual são ajustadas para a amostra, e temos nosso modelo de análise (H_0)

O segundo modelo mantém a covariância residual Q3–Q4 e acrescenta três cargas cruzadas: Q8 e Q9 no domínio psicológico e Q15 no domínio ambiental (Figura 2). A seleção dessas relações é informada pela solução exploratória de quatro fatores apresentada na Tabela 3 de Lin & Yao (2022). A segurança percebida em Q8 e a avaliação do ambiente físico em Q9 podem compartilhar aspectos com o bem-estar psicológico, enquanto a mobilidade avaliada por Q15 pode envolver, além da capacidade física, condições ambientais. Essas interpretações constituem justificativas substantivas para testar as relações selecionadas; não são conclusões já estabelecidas para a amostra deste tutorial.

Preservamos as cargas de Q8 e Q9 no domínio ambiental e a de Q15 no domínio físico, acrescentando as relações propostas em vez de transferir os itens de domínio. Também não reproduzimos todas as cargas secundárias da solução exploratória de Lin & Yao (2022). O segundo modelo é uma especificação delimitada para este tutorial, apoiada naquela evidência e na interpretação do conteúdo dos itens, e não uma AFC anteriormente validada pelos autores com essa exata configuração.




Figura 2: Modelo de quatro fatores correlacionados com covariância residual Q3–Q4 e três cargas cruzadas. *Nota.* PSI = psicológico; FIS = físico; SOC = relações sociais; AMB = ambiente. Mantém-se a estrutura do primeiro modelo e acrescentam-se as cargas do fator psicológico em Q8 e Q9 e do fator ambiental em Q15. A figura representa a especificação (cargas fixas) do modelo populacional alternativo. Ao estimarmos com parâmetros livres, as cargas e a covariância residual são ajustadas para a amostra, e temos nosso modelo alternativo (H_1)

4 Análise de poder

Em muitas pesquisas empíricas, uma escala não constitui o desfecho final, mas o modelo de medida de construtos posteriormente relacionados em um modelo estrutural. O planejamento amostral deve, portanto, considerar o instrumento e a estrutura que se pretende estimar, em vez de depender de regras gerais sobre o número de itens ou parâmetros (Kline, 2023). Nesta seção, tratamos poder como a probabilidade de detectar uma omissão estrutural definida antes da coleta.

4.1 Pressupostos a priori

A análise de poder foi planejada a partir dos dois modelos de medida fundamentados na Capítulo 3. A segunda especificação do modelo não é tratada como um modelo concorrente a ser diretamente estimado e comparado com o primeiro. Em vez disso, representa uma condição populacional alternativa na qual o ajuste do modelo mais parcimonioso implica a omissão deliberada das três cargas cruzadas.

As cargas fatoriais principais, as correlações entre os fatores e as variâncias residuais foram definidas com base nas evidências meta-analíticas e nas revisões apresentadas anteriormente (Lin & Yao, 2022; Mosqueira Taipe et al., 2026; Skevington & Epton, 2018). Consequentemente, a análise de poder é conduzida *a priori*: as características da população e a magnitude da misspecificação são estabelecidas antes do acesso aos dados empíricos utilizados nas seções subsequentes.

Além da estrutura fatorial, as simulações incorporam duas condições frequentemente encontradas em aplicações reais da análise fatorial confirmatória: não normalidade e dados ausentes. A distribuição dos indicadores admite assimetrias entre -1 e $+1$ e valores de curtose entre aproximadamente 1,7 e 2,0, representando desvios moderados da normalidade compatíveis com resultados anteriores obtidos com o WHOQOL-Bref (Yoshitake et al., 2015).

Também se pressupõe que 10% das respostas estejam ausentes segundo um mecanismo completamente ao acaso. A adoção do mecanismo MCAR permite representar a perda de informação decorrente dos dados ausentes sem exigir a formulação adicional de um padrão prospectivo de ausência dependente de variáveis observadas. Em todas as condições, os modelos são estimados por máxima verossimilhança robusta, enquanto os dados ausentes são tratados por máxima verossimilhança com informação completa. A Tabela 1 sintetiza essas decisões.

Tabela 1: Pressupostos da análise de poder a priori.

Componente	Especificação	Base
Modelo de referência	Quatro fatores correlacionados e covariância residual Q3–Q4	Lin e Yao (2022)
Misspecificação	Omissão de três cargas cruzadas	Mosqueira-Taipe et al. (2026)
Não normalidade	Assimetria de -1 a +1; curtose entre 1,7 e 2,0	Yoshitake et al. (2015)
Dados ausentes	10% MCAR	Mosqueira-Taipe et al. (2026)
Estimação	MLR + FIML	Cenário realístico

Tabela 1: Pressupostos da análise de poder a priori.

Componente	Especificação	Base
Erro tipo I	0.05	Definido a priori
Poder-alvo	0.80	Definido a priori

4.2 Abordagem analítica de poder

A primeira estimativa do tamanho amostral é obtida pelo método analítico baseado em modelos. Nessa análise, a estrutura populacional contém as três cargas cruzadas, enquanto o modelo submetido ao teste mantém apenas as cargas principais e a covariância residual entre Q3 e Q4. Assim, a magnitude do efeito não é definida por um valor convencional de RMSEA ou por outra regra geral, mas pela discrepância entre a matriz de covariâncias populacional e as restrições impostas pelo modelo de análise (Moshagen & Bader, 2024).

Como não é especificado um segundo modelo livremente estimado para uma comparação aninhada, o procedimento avalia o ajuste global do modelo de análise em relação ao modelo saturado. Portanto, a hipótese testada não corresponde à comparação direta entre o modelo parcimonioso e o modelo livre com cargas cruzadas. Ela expressa a capacidade de rejeitar globalmente o modelo que omite as relações presentes na população.

Considerando nível de significância de 5% e poder desejado de 80%, o método analítico indicou um tamanho amostral mínimo de 106 participantes. Esse valor é utilizado como ponto de partida para a etapa de simulação, e não como recomendação amostral definitiva.

A Figura 3 apresenta as distribuições central e não central do qui-quadrado. A distribuição sob a hipótese nula representa o comportamento esperado da estatística quando as restrições do modelo são adequadas, enquanto a distribuição não central representa o comportamento esperado diante da discrepância populacional especificada. A região de rejeição e a sobreposição entre as duas distribuições permitem visualizar conjuntamente o erro tipo I e o poder estatístico.

semPower: A priori power analysis

F0	0.578978
RMSEA	0.048612
SRMR	0.066543
Mc	0.748646
GFI	0.953973
AGFI	0.943640
CFI	0.959955
df	245
Required Num Observations	106
Critical Chi-Square	282.5114
NCP	60.79267

Alpha	0.050000
Beta	0.196821
Power (1 - Beta)	0.803179
Implied Alpha/Beta Ratio	0.254037




Figura 3: Distribuições central e não central do qui-quadrado na análise analítica de poder baseada nos modelos.

4.3 Simulação Monte Carlo

Embora a abordagem analítica forneça um ponto de partida objetivo, ela não representa integralmente as condições realísticas previstas na literatura. Por esse motivo, a etapa seguinte utiliza uma simulação Monte Carlo que combina não normalidade moderada e 10% de dados ausentes MCAR, mantendo a estimação por máxima verossimilhança robusta (MLR) com tratamento dos dados ausentes por informação completa (FIMLR).

Os tamanhos amostrais variam de 101 a 400 participantes. Em cada tamanho, são realizadas dez replicações sob duas condições populacionais. Na condição de referência, os dados seguem a estrutura de quatro fatores sem cargas cruzadas. Na condição alternativa, os dados são gerados com as três cargas cruzadas, mas analisados pelo modelo que as omite. A comparação entre essas condições permite estimar a capacidade de RMSEA, SRMR, CFI e TLI para identificar a misspecificação previamente definida.

Duas representações das relações entre tamanho amostral e poder são apresentadas. A primeira utiliza suavização logística para representar a tendência geral de crescimento do poder ao longo da faixa amostral (Figura 4). A segunda mostra diretamente as proporções de rejeição observadas nas replicações realizadas em cada tamanho (Figura 5).




Figura 4: Curvas de poder com suavização logística sob não normalidade leve e 10% de dados ausentes MCAR.




Figura 5: Poder empírico sem suavização logística sob não normalidade leve e 10% de dados ausentes MCAR.

As curvas apresentadas em Figura 4 e Figura 5 sugerem que uma amostra próxima de 150 participantes pode ser suficiente para que os índices globais detectem a omissão das cargas cruzadas. O poder e os pontos de corte empíricos são, então, calculados

especificamente para $N = 150$. Essa avaliação permite verificar se o tamanho indicado visualmente pelas curvas oferece desempenho consistente entre os quatro índices ou se permanece excessivamente próximo do limite adotado.

Tabela 2: Poder e pontos de corte calibrados pelo modelo para $N = 150$.

	RMSEA	SRMR	CFI	TLI
Poder	0.864	0.999	0.847	0.847
Ponto de corte	0.046	0.068	0.957	0.951

Em $N = 150$, o poder estimado foi de 0.864 para o RMSEA, 0.999 para o SRMR, 0.847 para o CFI e 0.847 para o TLI.

Entretanto, essa primeira simulação examina somente a capacidade dos índices globais de ajuste para detectar a misspecificação. Ela não avalia recuperação das cargas fatoriais, viés absoluto ou relativo dos parâmetros, viés dos erros-padrão, cobertura dos intervalos de confiança ou poder de parâmetros individuais. Assim, uma amostra que pareça suficiente para o teste global não necessariamente garante precisão adequada para todos os parâmetros do modelo (Feng & Hancock, 2023; Pornprasertmanit et al., 2022).

4.4 SMC com tamanho amostral fixo

Diante da possibilidade de que 150 participantes representem uma solução limítrofe, adota-se $N = 200$ como tamanho amostral de planejamento. Essa decisão não constitui uma regra universal para análise fatorial confirmatória. Trata-se de uma escolha prudencial que considera, simultaneamente, os resultados das curvas de poder, a complexidade do modelo de medida, as condições não ideais de distribuição e missing e a ausência, neste tutorial, de uma avaliação completa da recuperação dos parâmetros.

A análise com tamanho amostral fixo utiliza 1.000 replicações para cada condição populacional. Na primeira, são gerados dados de acordo com o modelo de referência. Na segunda, os dados são gerados sob a estrutura que contém as três cargas cruzadas, mas continuam sendo analisados pelo modelo que as omite. Diferentemente da etapa anterior, na qual dez replicações foram distribuídas em cada um dos diversos tamanhos amostrais, esta etapa concentra todas as 1.000 replicações em $N = 200$. Isso permite obter estimativas mais estáveis do poder e das distribuições empíricas dos índices de ajuste nesse tamanho específico.

Como o tamanho amostral permanece constante, não é necessária uma suavização logística. A Figura 6 mostra diretamente o comportamento empírico dos índices nas duas condições populacionais. A separação entre as distribuições é a representação gráfica da capacidade de identificar a misspecificação.




Figura 6: Distribuições empíricas dos índices de ajuste em 1.000 replicações com $N = 200$.

Em seguida, são calculados o poder de detecção da misspecificação e os pontos de corte correspondentes a RMSEA, SRMR, CFI e TLI. Esses pontos são derivados da distribuição dos índices quando o modelo está corretamente especificado, considerando simultaneamente o tamanho amostral, a não normalidade, o percentual de dados ausentes e o método de estimação. A Tabela 3 apresenta os resultados para $N = 200$.

Tabela 3: Poder e pontos de corte calibrados pelo modelo em 1.000 replicações com $N = 200$.

	TRADITIONALCHI	RMSEA	SRMR	CFI	TLI
Poder	0.999	0.984	1.000	0.982	0.982
Ponto de corte	0.036	0.056	0.974	0.971	0.036

4.5 Comparação com pontos de corte tradicionais

Finalmente, o desempenho dos pontos de corte calibrados é comparado ao desempenho dos limites tradicionalmente utilizados para interpretar o ajuste global. Para RMSEA e SRMR, a rejeição ocorre quando os valores ultrapassam os respectivos limites; para CFI e TLI, ocorre quando os valores ficam abaixo deles.

A mesma simulação com tamanho amostral fixo é reavaliada, mantendo constantes o tamanho amostral, os modelos de geração e análise e todas as características dos dados. Apenas o critério de decisão é alterado. A Figura 7 apresenta a classificação obtida com os pontos de corte tradicionais, e a Tabela 4 apresenta o poder resultante.




Figura 7: Distribuições dos índices de ajuste avaliadas por pontos de corte tradicionais em 1.000 replicações com $N = 200$.

Tabela 4: Poder obtido com pontos de corte tradicionais em 1.000 replicações com $N = 200$.

	CFI	TLI	RMSEA	SRMR
Poder	0.496	0.678	0.062	1

Com os pontos de corte tradicionais, o poder foi de 0.062 para o RMSEA, 1.000 para o SRMR, 0.496 para o CFI e 0.678 para o TLI.

Essa comparação permite verificar que os critérios tradicionais produzem conclusões completamente diferente às obtidas com as distribuições simuladas, com a sensibilidade para a misspecificação considerada consideravelmente distorcida (Groskurth et al., 2024; McNeish & Wolf, 2023b).

Em conjunto, as três etapas cumprem funções complementares. A abordagem analítica oferece uma estimativa inicial baseada na discrepância populacional; a simulação com tamanho variável mostra como o poder evolui entre 101 e 400 participantes; e a simulação com 1.000 replicações em $N = 200$ fornece uma avaliação mais estável do planejamento amostral escolhido.

5 Pré-processamento

O pré-processamento em questionários de autorelato tem como finalidade proteger as análises vindouras de vieses introduzidos por respostas descuidadas ou com esforço insuficiente (*Careless or Insufficient Effort Responding* — C/IER), registros incompletos

ou com respostas inconsistentes, e a inspeção preliminar das variáveis. Nas seções anteriores não precisamos dos dados coletados, mas a partir de agora, temos que fazer exercícios com dados brutos, e por isso, vamos utilizar a mesma base de dados empregada por Rogers (2024) e Rogers (2022).

Neste tutorial, entretanto, o processamento parte dos 1.546 registros brutos e explicita tanto os critérios procedurais quanto os indicadores estatísticos de triagem C/IER. Os dados, o codebook e os procedimentos necessários à execução acompanham o projeto. Como os trabalhos anteriores (Rogers, 2022, 2024) partiram de uma base pré-processada de 1.047 participantes, eventuais diferenças entre seus resultados e os deste tutorial não devem ser atribuídas exclusivamente ao tratamento ordinal ou contínuo dos itens. Após a verificação da integridade do banco e a remoção de registros sem identificação ou com mais de cinco respostas ausentes na WHOQOL-Bref (como veremos adiante, o objetivo é simular estimação com dados *missings*), a amostra elegível foi submetida a um protocolo sequencial de triagem C/IER.

Para essa triagem e o tratamento das respostas C/IER, adotou-se a abordagem de múltiplos obstáculos (*multiple-hurdle approach*) indicada por Curran (2016) e DeSimone et al. (2015). Como os índices de desatenção mensuram manifestações comportamentais distintas, como respostas aleatórias, padrões invariantes e preenchimento apressado, e podem apresentar correlações baixas ou nulas entre si (Biemann et al., 2025; Goldammer et al., 2020; Meade & Craig, 2012), a literatura recomenda a aplicação combinada de critérios de triagem (Arthur et al., 2021; Curran, 2016; Ulitzsch et al., 2022). No presente tutorial, cada critério foi tratado como uma barreira obrigatória, de modo que a falha em qualquer obstáculo determinou a exclusão do participante da amostra final (Curran, 2016; Goldammer et al., 2020).

5.1 Exclusões procedurais

No âmbito dos controles *ex-ante*, utilizamos itens de atenção inseridos no instrumento e a duração total de preenchimento do questionário (Curran, 2016; Ward & Meade, 2023). A falha em pelo menos dois dos três itens de atenção incluídos no questionário foi interpretada como evidência de C/IER, reduzindo a possibilidade de excluir respondentes atentos por um lapso pontual (Chauliac et al., 2023; DeSimone et al., 2015). Também foram excluídos os questionários de indivíduos com velocidade inferior a quatro segundos por item, limiar considerado incompatível com o processamento semântico reflexivo requerido pelo instrumento (Curran, 2016; Huang et al., 2012; Jones et al., 2023).

5.2 Critérios estatísticos

Como critérios *ex-post* empregamos a medida de *Longstring*, o IRV e a Distância de Mahalanobis (Biemann et al., 2025; A. M. Dunn et al., 2018). O primeiro permite identificar padrões mecânicos de marcação uniforme; o segundo detecta tanto variabilidade anormalmente baixas quanto dispersão alta; e o terceiro identifica padrões multivariados distantes do comportamento normativo da amostra, condizentes com aleatoriedade excessiva (Curran, 2016; DeSimone et al., 2015; Hong et al., 2020; Meade & Craig, 2012). Considerou-se problemática uma sequência contínua (*Longstring*) superior à metade dos itens da WHOQOL-BREF; para o IRV, utilizaram-se os percentis 1% e 99%; e, para a Distância de Mahalanobis, o percentil 99%. Esses limiares foram definidos *a priori* com base na extensão da escala e nas caudas extremas das distribuições amostrais, buscando

equilibrar sensibilidade à desatenção e preservação de respondentes sinceros (Arthur et al., 2021; Goldammer et al., 2020; Steedle, 2018).

Tabela 5: Pontos de corte dos indicadores estatísticos.

Indicador	Mé- dia	Desvio- padrão	Medi- ana	1º percentil	99º percentil	Regra de exclusão
Longstring	5.216	2.734	4.000	2.000	15.000	longstring > 13
IRV	1.025	0.207	1.027	0.552	1.491	IRV p1 ou IRV p99
Distância de Mahalanobis	26.000	15.336	22.060	5.844	80.639	Mahalanobis p99

5.2.1 Decisão final e amostra de análise

Tabela 6: Frequência de falhas em cada obstáculo de limpeza.

Critério	N sinalizado	Percentual (%)
Itens de atenção	28	2.1
Tempo de resposta	8	0.6
Longstring	21	1.6
IRV	28	2.1
Distância de Mahalanobis	14	1.1

Tabela 7: Trajetória da amostra durante o pré-processamento.

Etapa	N
Banco bruto	1546
Dropouts removidos	223
Elegíveis aos obstáculos	1323
Excluídos por pelo menos um obstáculo	80
Amostra analítica final	1243

5.3 Descrição dos itens

Tabela 8: Estatísticas descritivas dos itens utilizados na AFC.

Item	Respostas válidas	Média	Desvio-padrão	Assimetria	Curtose	VIF
Q3	1242	4.136	0.941	-0.910	0.076	1.624
Q4	1241	4.089	1.009	-0.983	0.183	1.473
Q5	1230	3.283	0.818	-0.472	-0.008	2.140
Q6	1238	3.895	0.974	-0.871	0.534	1.752
Q7	1241	3.586	0.858	-0.489	0.059	1.706

Tabela 8: Estatísticas descritivas dos itens utilizados na AFC.

Item	Respostas válidas	Média	Desvio-padrão	Assimetria	Curtose	VIF
Q8	1240	2.933	0.979	-0.098	-0.459	1.317
Q9	1239	3.471	0.884	-0.569	0.216	1.475
Q10	1241	3.587	0.903	-0.164	-0.368	2.226
Q11	1241	3.798	0.996	-0.615	-0.087	1.611
Q12	1242	3.414	1.099	-0.241	-0.530	1.825
Q13	1243	3.896	0.828	-0.570	0.235	1.545
Q14	1240	3.331	0.956	-0.281	-0.245	1.927
Q15	1243	4.398	0.807	-1.513	2.455	1.504
Q16	1232	3.485	1.035	-0.124	-1.165	1.430
Q17	1242	3.711	0.921	-0.504	-0.538	3.689
Q18	1243	3.730	0.955	-0.488	-0.659	3.247
Q19	1240	3.691	0.942	-0.400	-0.706	2.661
Q20	1239	3.608	0.891	-0.237	-0.674	1.893
Q21	1242	3.420	1.009	-0.003	-1.111	1.316
Q22	1241	3.554	0.884	-0.131	-0.703	1.730
Q23	1237	3.973	0.949	-0.686	-0.413	1.392
Q24	1242	3.725	0.963	-0.400	-0.771	1.389
Q25	1241	3.821	0.978	-0.489	-0.737	1.402
Q26	1243	3.891	0.930	-1.160	1.535	1.559




Figura 8: Distribuição das categorias de resposta Likert no construto Relações sociais.

6 Processo de estimação

7 Ajuste do modelo

8 Comparações e modificações dos modelos

9 Conclusões

Referências

- AERA, APA, & NCME. (1999). *Standards for Educational and Psychological Testing*. American Educational Research Association, American Psychological Association, & National Council on Measurement in Education.
- AERA, APA, & NCME. (2014). *Standards for Educational and Psychological Testing*. American Educational Research Association, American Psychological Association & National Council on Measurement in Education.
- Arthur, W., Hagen, E., & George, F. (2021). The Lazy or Dishonest Respondent: Detection and Prevention. *Annu. Rev. Organ. Psychol. Organ. Behav.*, 8, 105–137. <https://doi.org/10.1146/annurev-orgpsych-012420-055324>
- Bandalos, D. L. (2014). Relative Performance of Categorical Diagonally Weighted Least Squares and Robust Maximum Likelihood Estimation. *Structural Equation Modeling*, 21(1), 102–116. <https://doi.org/10.1080/10705511.2014.859510>
- Bandalos, D. L. (2018). *Measurement Theory and Applications for the Social Sciences*. Guilford Press.
- Bell, S. M., Chalmers, R. P., & Flora, D. B. (2023). The Impact of Measurement Model Misspecification on Coefficient Omega Estimates of Composite Reliability. *Educational and Psychological Measurement*, 1–36. <https://doi.org/10.1177/00131644231155804>
- Biemann, T., Koch-Bayram, I. F., Meier-Barthold, M., & Aguinis, H. (2025). Using Markov Chains to Detect Careless Responding in Survey Research. *Organ. Res. Methods*, 28(4), 543–568. <https://doi.org/10.1177/10944281251334778>
- Brown, T. A. (2015). *Confirmatory Factor Analysis for Applied Research*. The Guilford Press.
- Brown, T. A. (2023). Confirmatory Factor Analysis. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.
- Byrne, B. M. (2016). *Structural Equation Modeling with AMOS: Basic Concepts, Application, and Programming*. Routledge Taylor & Francis Group.
- Chauliac, M., Willems, J., Gijbels, D., & Donche, V. (2023). The Prevalence of Careless Response Behaviour and Its Consequences on Data Quality in Self-Report Questionnaires on Student Learning. *Front. Educ.*, 8. <https://doi.org/10.3389/feduc.2023.1197324>
- Cho, E. (2022). Reliability and Omega Hierarchical in Multidimensional Data: A Comparison of Various Estimators. *Psychological Methods*. <https://doi.org/10.1037/met0000525>
- Cohen, R. J., Schneider, J. W., & Tobin, R. M. (2022). *Psychological Testing and Assessment: An Introduction to Test and Measurement*. McGraw Hill LLC.
- Collier, J. E. (2020). *Applied Structural Equation Modeling Using AMOS: Basic to Advanced Techniques*. Routledge.

- Crede, M., & Harms, P. (2019). Questionable Research Practices When Using Confirmatory Factor Analysis. *Journal of Managerial Psychology*, 34(1), 18–30. <https://doi.org/10.1108/JMP-06-2018-0272>
- Curran, P. G. (2016). Methods for the Detection of Carelessly Invalid Responses in Survey Data. *J. Exp. Soc. Psychol.*, 66, 4–19. <https://doi.org/10.1016/j.jesp.2015.07.006>
- Davvetas, V., Diamantopoulos, A., Zaefarian, G., & Sichtmann, C. (2020). Ten Basic Questions about Structural Equations Modeling You Should Know the Answers to – But Perhaps You Don’t. *Industrial Marketing Management*, 90, 252–263. <https://doi.org/10.1016/j.indmarman.2020.07.016>
- DeSimone, J. A., Harms, P. D., & DeSimone, A. J. (2015). Best Practice Recommendations for Data Screening. *J. Organ. Behav.*, 36(2), 171–181. <https://doi.org/10.1002/job.1962>
- Dunn, A. M., Heggstad, E. D., Shanock, L. R., & Theilgard, N. (2018). Intra-Individual Response Variability as an Indicator of Insufficient Effort Responding: Comparison to Other Indicators and Relationships with Individual Differences. *J. Bus. Psychol.*, 33(1), 105–121. <https://doi.org/10.1007/s10869-016-9479-0>
- Dunn, T. J., Baguley, T., & Brunsden, V. (2014). From Alpha to Omega: A Practical Solution to the Pervasive Problem of Internal Consistency Estimation. *British Journal of Psychology*, 105(3), 399–412. <https://doi.org/10.1111/bjop.12046>
- Enders, C. (2023). Fitting Structural Equation Models with Missing Data. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.
- Feng, Y., & Hancock, G. R. (2023). Power Analysis within a Structural Equation Modeling Framework. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.
- Flake, J. K., Davidson, I. J., Wong, O., & Pek, J. (2022). Construct Validity and the Validity of Replication Studies: A Systematic Review. *American Psychologist*, 77(4), 576–588. <https://doi.org/10.1037/amp0001006>
- Flake, J. K., & Fried, E. I. (2020). Measurement Schmeasurement: Questionable Measurement Practices and How to Avoid Them. *Advances in Methods and Practices in Psychological Science*, 3(4), 456–465. <https://doi.org/10.1177/2515245920952393>
- Flake, J. K., Pek, J., & Hehman, E. (2017). Construct Validation in Social and Personality Research: Current Practices and Recommendations. *Social Psychological and Personality Science*, 8(4), 370–378. <https://doi.org/10.1177/1948550617693063>
- Flora, D. B. (2020). Your Coefficient Alpha Is Probably Wrong, but Which Coefficient Omega Is Right? A Tutorial on Using R to Obtain Better Reliability Estimates. *Advances in Methods and Practices in Psychological Science*, 3(4), 484–501. <https://doi.org/10.1177/2515245920951747>
- Flora, D. B., & Flake, J. K. (2017). The Purpose and Practice of Exploratory and Confirmatory Factor Analysis in Psychological Research: Decisions for Scale Development and Validation. *Canadian Journal of Behavioural Science*, 49(2), 78–88. <https://doi.org/10.1037/cbs0000069>
- Flora, D. B., LaBrish, C., & Chalmers, R. P. (2012). Old and New Ideas for Data Screening and Assumption Testing for Exploratory and Confirmatory Factor Analysis. *Frontiers in Psychology*, 3(MAR), 55. <https://doi.org/10.3389/fpsyg.2012.00055>
- Furr, M. R. (2021). *Psychometrics: An Introduction*. SAGE Publications.
- Gilroy, S. P., & Kaplan, B. A. (2019). Furthering Open Science in Behavior Analysis: An Introduction and Tutorial for Using GitHub in Research. *Perspectives on Behavior Science*, 42(3), 565–581. <https://doi.org/10.1007/s40614-019-00202-5>
- Goldammer, P., Annen, H., Stöckli, P. L., & Jonas, K. (2020). Careless Responding

- in Questionnaire Measures: Detection, Impact, and Remedies. *Leadersh. Q.*, 31(4), 101384. <https://doi.org/10.1016/j.leaqua.2020.101384>
- Goodboy, A. K., & Martin, M. M. (2020). Omega over Alpha for Reliability Estimation of Unidimensional Communication Measures. *Annals of the International Communication Association*, 44(4), 422–439. <https://doi.org/10.1080/23808985.2020.1846135>
- Green, S. B., & Yang, Y. (2015). Evaluation of Dimensionality in the Assessment of Internal Consistency Reliability: Coefficient Alpha and Omega Coefficients. *Educational Measurement: Issues and Practice*, 34(4), 14–20. <https://doi.org/10.1111/emip.12100>
- Grewal, R., Cote, J. A., & Baumgartner, H. (2004). Multicollinearity and Measurement Error in Structural Equation Models: Implications for Theory Testing. *Marketing Science*, 23(4), 519–529. <https://doi.org/10.1287/mksc.1040.0070>
- Groskurth, K., Bluemke, M., & Lechner, C. M. (2024). Why We Need to Abandon Fixed Cutoffs for Goodness-of-Fit Indices: An Extensive Simulation and Possible Solutions. *Behav. Res. Methods*, 56(4), 3891–3914. <https://doi.org/10.3758/s13428-023-02193-3>
- Hair, J. F., Hult, T. M. G., Ringle, C. M., & Sarstedt, M. (2022). *A Primer on Partial Least Squares Structural Equation Modeling (PLS-SEM)*. Sage Publications.
- Hair, J. F., Sarstedt, M., Ringle, C., & Gudergan, S. P. (2017). *Advanced Issues in Partial Least Squares Structural Equation Modeling*. SAGE Publications, Inc.
- Hair, J., Black, W., Babin, B., & Anderson, R. (2019). *Multivariate Data Analysis*. Cengage Learning.
- Harpe, S. E. (2015). How to Analyze Likert and Other Rating Scale Data. *Curr. Pharm. Teach. Learn.*, 7(6), 836–850. <https://doi.org/10.1016/j.cptl.2015.08.001>
- Harrington, D. (2009). *Confirmatory Factor Analysis*. Oxford University Press.
- Hayes, A. F., & Coutts, J. J. (2020). Use Omega Rather than Cronbach's Alpha for Estimating Reliability. But.... *Communication Methods and Measures*, 14(1), 1–24. <https://doi.org/10.1080/19312458.2020.1718629>
- Henseler, J. (2021). *Composite-Based Structural Equation Modeling: Analyzing Latent and Emergent Variables*. The Guilford Press.
- Holgado-Tello, F., Morata-Ramirez, M., & García, M. (2016). Robust Estimation Methods in Confirmatory Factor Analysis of Likert Scales: A Simulation Study. *International Review of Social Sciences and Humanities*, 11(2), 80–96.
- Hong, M., Steedle, J. T., & Cheng, Y. (2020). Methods of Detecting Insufficient Effort Responding: Comparisons and Practical Recommendations. *Educ. Psychol. Meas.*, 80(2), 312–345. <https://doi.org/10.1177/0013164419865316>
- Hoyle, R. H. (2023). Structural Equation Modeling: An Overview. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. Guilford Press.
- Huang, J. L., Curran, P. G., Keeney, J., Poposki, E. M., & DeShon, R. P. (2012). Detecting and Deterring Insufficient Effort Responding to Surveys. *J. Bus. Psychol.*, 27(1), 99–114. <https://doi.org/10.1007/s10869-011-9231-8>
- Huang, J. L., Liu, M., & Bowling, N. A. (2015). Insufficient Effort Responding: Examining an Insidious Confound in Survey Data. *J. Appl. Psychol.*, 100(3), 828–845. <https://doi.org/http://dx.doi.org/10.1037/a0038510>
- Huang, J. L., Wang, Z., Huang, R., Wu, D., & Shi, H. (2026). *Insufficient Effort Responding in Management Research: A Critical Review and Future Directions*. 52(1). <https://doi.org/10.1177/01492063251330268>
- Huang, P.-H. (2017). Asymptotics of AIC, BIC, and RMSEA for Model Selection in Structural Equation Modeling. *Psychometrika*, 82(2), 407–426. <https://doi.org/10.1007/s11336-017-9572-y>
- Hughes, D. J. (2018). Psychometric Validity: Establishing the Accuracy and Appropria-

- teness of Psychometric Measures. Em P. Irwing, T. Booth, & D. J. Hughes (Org.), *The Wiley Handbook of Psychometric Testing: A Multidisciplinary Reference on Survey, Scale and Test Development*. John Wiley & Sons Ltd.
- Jackson, D. L., Gillaspay, J. A., & Purc-Stephenson, R. (2009). Reporting Practices in Confirmatory Factor Analysis: An Overview and Some Recommendations. *Psychological Methods*, 14(1). <https://doi.org/10.1037/a0014694>
- Jak, S., Jorgensen, T. D., Verdam, M. G. E., Oort, F. J., & Elffers, L. (2021). Analytical Power Calculations for Structural Equation Modeling: A Tutorial and Shiny App. *Behavior Research Methods*, 53, 1385–1406. <https://doi.org/10.3758/s13428-020-01479-0/Published>
- Jobst, L. J., Bader, M., & Moshagen, M. (2023). A Tutorial on Assessing Statistical Power and Determining Sample Size for Structural Equation Models. *Psychological Methods*, 28(1), 207–221. <https://doi.org/10.1037/met0000423>
- Jones, E. A., Wind, S. A., Tsai, C.-L., & Ge, Y. (2023). Comparing Person-Fit and Traditional Indices Across Careless Response Patterns in Surveys. *Appl. Psychol. Meas.*, 47(5-6), 365–385. <https://doi.org/10.1177/01466216231194358>
- Kalkbrenner, M. T. (2023). Alpha, Omega, and H Internal Consistency Reliability Estimates: Reviewing These Options and When to Use Them. *Counseling Outcome Research and Evaluation*, 14(1), 77–88. <https://doi.org/10.1080/21501378.2021.1940118>
- Kathawalla, U.-K., Silverstein, P., & Syed, M. (2021). Easing Into Open Science: A Guide for Graduate Students and Their Advisors. *Collabra: Psychology*, 7(1), 18684. <https://doi.org/10.1525/collabra.18684>
- Klein, O., Hardwicke, T. E., Aust, F., Breuer, J., Danielsson, H., Mohr, A. H., IJzerman, H., Nilsson, G., Vanpaemel, W., & Frank, M. C. (2018). A Practical Guide for Transparency in Psychological Science. *Collabra: Psychology*, 4(1), 20. <https://doi.org/10.1525/collabra.158>
- Kline, R. B. (2016). *Principles and Practice of Structural Equation Modeling*. The Guilford Press.
- Kline, R. B. (2023). *Principles and Practice of Structural Equation Modeling* (Fifth Edition). The Guilford Press.
- Kyriazos, T. A. (2018). Applied Psychometrics: Sample Size and Sample Power Considerations in Factor Analysis (EFA, CFA) and SEM in General. *Psychology*, 09(08), 2207–2230. <https://doi.org/10.4236/psych.2018.98126>
- Lai, K. (2020). Confidence Interval for RMSEA or CFI Difference Between Nonnested Models. *Structural Equation Modeling: A Multidisciplinary Journal*, 27(1), 16–32. <https://doi.org/10.1080/10705511.2019.1631704>
- Lai, K. (2021a). Fit Difference Between Nonnested Models Given Categorical Data: Measures and Estimation. *Structural Equation Modeling: A Multidisciplinary Journal*, 28(1), 99–120. <https://doi.org/10.1080/10705511.2020.1763802>
- Lai, K. (2021b). Using Information Criteria Under Missing Data: Full Information Maximum Likelihood Versus Two-Stage Estimation. *Structural Equation Modeling: A Multidisciplinary Journal*, 28(2), 278–291. <https://doi.org/10.1080/10705511.2020.1780925>
- Leite, W. L., Bandalos, D. L., & Shen, Z. (2023). Simulation Methods in Structural Equation Modeling. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.
- Li, C. H. (2016). Confirmatory Factor Analysis with Ordinal Data: Comparing Robust Maximum Likelihood and Diagonally Weighted Least Squares. *Behavior Research*

- Methods*, 48(3), 936–949. <https://doi.org/10.3758/s13428-015-0619-7>
- Limongi, R., & Rogers, P. (2025a). Open Science in Three Acts: Foundations, Practice, and Implementation - First Act. *BAR - Brazilian Administration Review*, 22(1), e250079. <https://doi.org/10.1590/1807-7692bar2025250079>
- Limongi, R., & Rogers, P. (2025b). Open Science in Three Acts: Foundations, Practice, and Implementation - Second Act. *BAR - Brazilian Administration Review*, 22(2), e250116. <https://doi.org/10.1590/1807-7692bar2025250116>
- Lin, L.-C., & Yao, G. (2022). Validation of the Factor Structure of the WHOQOL-BREF Using Meta-Analysis of Exploratory Factor Analysis and Social Network Analysis. *Psychological Assessment*, 34(7), 660–670. <https://doi.org/10.1037/pas0001122>
- Mai, R., Niemand, T., & Kraus, S. (2021). A Tailored-Fit Model Evaluation Strategy for Better Decisions about Structural Equation Models. *Technological Forecasting and Social Change*, 173, 121142. <https://doi.org/10.1016/j.techfore.2021.121142>
- Marcoulides, K. M., & Yuan, K. H. (2017). New Ways to Evaluate Goodness of Fit: A Note on Using Equivalence Testing to Assess Structural Equation Models. *Structural Equation Modeling*, 24(1), 148–153. <https://doi.org/10.1080/10705511.2016.1225260>
- Marsh, H. W., Dowson, M., Pietsch, J., & Walker, R. (2004). Why Multicollinearity Matters: A Reexamination of Relations Between Self-Efficacy, Self-Concept, and Achievement. *Journal of Educational Psychology*, 96(3), 518–522. <https://doi.org/10.1037/0022-0663.96.3.518>
- Martins, H. C. (2021). Tutorial-Articles: The Importance of Data and Code Sharing. *Revista de Administração Contemporânea*, 25(1), e200212. <https://doi.org/10.1590/1982-7849rac2021200212>
- Maydeu-Olivares, A., Fairchild, A. J., & Hall, A. G. (2017). Goodness of Fit in Item Factor Analysis: Effect of the Number of Response Alternatives. *Structural Equation Modeling: A Multidisciplinary Journal*, 24(4), 495–505. <https://doi.org/10.1080/10705511.2017.1289816>
- McNeish, D. (2018). Thanks Coefficient Alpha, We'll Take It from Here. *Psychological Methods*, 23(3), 412–433. <https://doi.org/10.1037/met0000144>
- McNeish, D. (2023a). Dynamic Fit Index Cutoffs for Factor Analysis with Likert, Ordinal, or Binary Responses. *PsyArXiv Preprints*. <https://doi.org/10.31234/osf.io/tp35s>
- McNeish, D. (2023b). Generalizability of Dynamic Fit Index, Equivalence Testing, and Hu & Bentler Cutoffs for Evaluating Fit in Factor Analysis. *Multivariate Behavioral Research*, 58(1), 195–219. <https://doi.org/10.1080/00273171.2022.2163477>
- McNeish, D., & Wolf, M. G. (2023a). *Direct Discrepancy Dynamic Fit Index Cutoffs for Arbitrary Covariance Structure Models* [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/4r9fq>
- McNeish, D., & Wolf, M. G. (2023b). Dynamic Fit Index Cutoffs for Confirmatory Factor Analysis Models. *Psychological Methods*, 28(1), 61–88. <https://doi.org/10.1037/met0000425>
- Meade, A. W., & Craig, S. B. (2012). Identifying Careless Responses in Survey Data. *Psychol. Methods*, 17(3), 437–455. <https://doi.org/10.1037/a0028085>
- Mendes-Da-Silva, W. (2023). What Lectures and Research in Business Management Need to Know About Open Science. *Revista de Administração de Empresas*, 63(4), e0000–0033. <https://doi.org/10.1590/s0034-759020230408x>
- Moshagen, M., & Bader, M. (2024). semPower: General Power Analysis for Structural Equation Models. *Behav. Res. Methods*, 56(4), 2901–2922. <https://doi.org/10.3758/s13428-023-02254-7>
- Mosqueira Taipe, C. M., Amador Campos, J. A., Krieger, V., Miaso, A. I., Molina, N.

- P. F. M., & dos Santos, P. L. (2026). Systematic Review of the Factor Structure of WHOQOL-bref in Adult Population. *Quality of Life Research*, 35(17), 1–18. <https://doi.org/10.1007/s11136-025-04115-6>
- Nalbantoğlu-Yılmaz, F. (2019). Comparison of Different Estimation Methods Used in Confirmatory Factor Analyses in Non-Normal Data: A Monte Carlo Study. *International Online Journal of Educational Sciences*, 11(4). <https://doi.org/10.15345/iojes.2019.04.010>
- Niemand, T., & Mai, R. (2018). Flexible Cutoff Values for Fit Indices in the Evaluation of Structural Equation Models. *Journal of the Academy of Marketing Science*, 46(6), 1148–1172. <https://doi.org/10.1007/s11747-018-0602-9>
- Norman, G. (2010). Likert Scales, Levels of Measurement and the “Laws” of Statistics. *Adv. Health Sci. Educ.*, 15(5), 625–632. <https://doi.org/10.1007/s10459-010-9222-y>
- Nye, C. D. (2022). Reviewer Resources: Confirmatory Factor Analysis. *Organizational Research Methods*, 109442812211205. <https://doi.org/10.1177/10944281221120541>
- Pilcher, N., & Cortazzi, M. (2023). ‘Qualitative’ and ‘quantitative’ Methods and Approaches across Subject Fields: Implications for Research Values, Assumptions, and Practices. *Quality & Quantity*. <https://doi.org/10.1007/s11135-023-01734-4>
- Podsakoff, P. M., MacKenzie, S. B., & Podsakoff, N. P. (2012). Sources of Method Bias in Social Science Research and Recommendations on How to Control It. *Annual Review of Psychology*, 63(1), 539–569. <https://doi.org/10.1146/annurev-psych-120710-100452>
- Pornprasertmanit, S., Miller, P., Jorgensen, T. D., & Corbin, Q. (2022). *Simsem: SIMulated Structural Equation Modeling*. R package. www.simsem.org
- Preacher, K. J., & Yaremych, H. E. (2023). Model Selection in Structural Equation Modeling. Em R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.
- Reeves, T. D., & Marbach-Ad, G. (2016). Contemporary Test Validity in Theory and Practice: A Primer for Discipline-Based Education Researchers. *CBE Life Sciences Education*, 15(1). <https://doi.org/10.1187/cbe.15-08-0183>
- Rhemtulla, M., Brosseau-Liard, P. É., & Savalei, V. (2012). When Can Categorical Variables Be Treated as Continuous? A Comparison of Robust Continuous and Categorical SEM Estimation Methods under Suboptimal Conditions. *Psychological Methods*, 17(3), 354–373. <https://doi.org/10.1037/a0029315>
- Rios, J., & Wells, C. (2014). Validity Evidence Based on Internal Structure. *Psicothema*, 26(1), 108–116. <https://doi.org/10.7334/psicothema2013.260>
- Robitzsch, A. (2020). Why Ordinal Variables Can (Almost) Always Be Treated as Continuous Variables: Clarifying Assumptions of Robust Continuous and Ordinal Factor Analysis Estimation Methods. *Frontiers in Education*, 5. <https://doi.org/10.3389/feduc.2020.589965>
- Robitzsch, A. (2022). On the Bias in Confirmatory Factor Analysis When Treating Discrete Variables as Ordinal Instead of Continuous. *Axioms*, 11(4). <https://doi.org/10.3390/axioms11040162>
- Rogers, P. (2022). Best Practices for Your Exploratory Factor Analysis: A Factor Tutorial. *Revista de Administração Contemporânea*, 26(6). <https://doi.org/10.1590/1982-7849rac2022210085.en>
- Rogers, P. (2024). Best Practices for Your Confirmatory Factor Analysis: A JASP and Lavaan Tutorial. *Behavior Research Methods*. <https://doi.org/10.3758/s13428-024-02375-7>
- Rogers, P., & Limongi, R. (2025). Open Science in Three Acts: Foundations, Practice, and Implementation - Third Act. *BAR - Brazilian Administration Review*, 22(3),

- e250162. <https://doi.org/10.1590/1807-7692bar2025250162>
- Rossee, Y. (2012). Lavaan: An R Package for Structural Equation Modeling. *Journal of Statistical Software*, 48(2), 1–36. <https://doi.org/10.18637/jss.v048.i02>
- Rossee, Y. (2023). *The Lavaan Tutorial*. Department of Data Analysis, Ghent University.
- Schumacker, R. E., Wind, S. A., & Holmes, L. F. (2021). Resources for Identifying Measurement Instruments for Social Science Research. *Measurement: Interdisciplinary Research and Perspectives*, 19(4), 250–257. <https://doi.org/10.1080/15366367.2021.1950486>
- Shek, D. T. L., & Yu, L. (2014). Use of Structural Equation Modeling in Human Development Research. *International Journal on Disability and Human Development*, 13(2), 157–167. <https://doi.org/10.1515/ijdh-2014-0302>
- Shi, D., & Maydeu-Olivares, A. (2020). The Effect of Estimation Methods on SEM Fit Indices. *Educational and Psychological Measurement*, 80(3), 421–445. <https://doi.org/10.1177/0013164419885164>
- Shi, D., Maydeu-Olivares, A., & Rossee, Y. (2020). Assessing Fit in Ordinal Factor Analysis Models: SRMR vs. RMSEA. *Structural Equation Modeling: A Multidisciplinary Journal*, 27(1), 1–15. <https://doi.org/10.1080/10705511.2019.1611434>
- Sireci, S. G., & Sukin, T. (2013). Test Validity. In *APA Handbook of Testing and Assessment in Psychology, Vol. 1: Test Theory and Testing and Assessment in Industrial and Organizational Psychology*. (p. 61–84). American Psychological Association. <https://doi.org/10.1037/14047-004>
- Skevington, S. M., & Epton, T. (2018). How Will the Sustainable Development Goals Deliver Changes in Well-Being? A Systematic Review and Meta-Analysis to Investigate Whether WHOQOL-BREF Scores Respond to Change. *BMJ Glob. Health*, 3. <https://doi.org/10.1136/bmjgh-2017-000609>
- Steedle, J. (2018). *Detecting Inattentive Responding on a Psychosocial Measure of College Readiness*. ACT.org.
- Trizano-Hermosilla, I., & Alvarado, J. M. (2016). Best Alternatives to Cronbach’s Alpha Reliability in Realistic Conditions: Congeneric and Asymmetrical Measurements. *Frontiers in Psychology*, 7(MAY). <https://doi.org/10.3389/fpsyg.2016.00769>
- Ullrich, E., Pohl, S., Khorramdel, L., Kroehne, U., & Davier, M. von. (2022). A Response-Time-Based Latent Response Mixture Model for Identifying and Modeling Careless and Insufficient Effort Responding in Survey Data. *Psychometrika*, 87(2), 593–619. <https://doi.org/10.1007/s11336-021-09817-7>
- Urbina, S. (2014). *Essentials of Psychological Testing*. John Wiley & Sons.
- Wang, Y. A. (2023). *How to Conduct Power Analysis for Structural Equation Models: A Practical Primer* [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/4n3uk>
- Wang, Y. A., & Rhemtulla, M. (2021). Power Analysis for Parameter Estimation in Structural Equation Modeling: A Discussion and Tutorial. *Advances in Methods and Practices in Psychological Science*, 4(1), 1–17. <https://doi.org/10.1177/2515245920918253>
- Ward, M. K., & Meade, A. W. (2023). Dealing with Careless Responding in Survey Data: Prevention, Identification, and Recommended Best Practices. *Annu. Rev. Psychol.*, 74(Volume 74, 2023), 577–596. <https://doi.org/10.1146/annurev-psych-040422-045007>
- West, S. G., Wu, W., McNeish, D., & Savord, A. (2023). Model Fit in Structural Equation Modeling. In R. H. Hoyle (Org.), *Handbook of Structural Equation Modeling*. The Guilford Press.
- Westland, C. J. (2010). Lower Bounds on Sample Size in Structural Equation Modeling.

- Electronic Commerce Research and Applications*, 9(6). <https://doi.org/10.1016/j.elerap.2010.07.003>
- Whittaker, T. A., & Schumacker, R. E. (2022). *A Beginner's Guide to Structural Equation Modeling* (Fifth Edition). Routledge Taylor & Francis Group.
- Widodo, E. (2018). Some Notes on the Contemporary Views of Validity in Psychological and Educational Assessment. *Advances in Social Science, Education and Humanities Research*, 231, 732–734. <https://doi.org/10.3968/8877>
- Wilkinson, M. D., Dumontier, M., Aalbersberg, Ij. J., Appleton, G., Axton, M., Baak, A., Blomberg, N., Boiten, J.-W., Da Silva Santos, L. B., Bourne, P. E., Bouwman, J., Brookes, A. J., Clark, T., Crosas, M., Dillo, I., Dumon, O., Edmunds, S., Evelo, C. T., Finkers, R., ... Mons, B. (2016). The FAIR Guiding Principles for Scientific Data Management and Stewardship. *Scientific Data*, 3(1), 160018. <https://doi.org/10.1038/sdata.2016.18>
- Wolf, M. G., & McNeish, D. (2023). Dynamic : An R Package for Deriving Dynamic Fit Index Cutoffs for Factor Analysis. *Multivariate Behavioral Research*, 58(1), 189–194. <https://doi.org/10.1080/00273171.2022.2163476>
- Xia, Y., & Yang, Y. (2019). RMSEA, CFI, and TLI in Structural Equation Modeling with Ordered Categorical Data: The Story They Tell Depends on the Estimation Methods. *Behavior Research Methods*, 51(1), 409–428. <https://doi.org/10.3758/s13428-018-1055-2>
- Yang, Y., & Liang, X. (2013). Confirmatory Factor Analysis under Violations of Distributional and Structural Assumptions. *Int. J. Quantitative Research in Education*, 1(1), 61–84.
- Yang-Wallentin, F., Jöreskog, K. G., & Luo, H. (2010). Confirmatory Factor Analysis of Ordinal Variables with Misspecified Models. *Structural Equation Modeling*, 17(3), 392–423. <https://doi.org/10.1080/10705511.2010.489003>
- Yoshitake, N., Sun, Y., Sugawara, M., Matsumoto, S., Sakai, A., Takaoka, J., & Goto, N. (2015). The Psychometric Properties of the WHOQOL-BREF in Japanese Couples. *Health Psychology Open*, 2(2), 1–9. <https://doi.org/10.1177/2055102915598089>
- Yuan, K. H., Chan, W., Marcoulides, G. A., & Bentler, P. M. (2016). Assessing Structural Equation Models by Equivalence Testing With Adjusted Fit Indexes. *Structural Equation Modeling*, 23(3), 319–330. <https://doi.org/10.1080/10705511.2015.1065414>
- Zhang, Z., & Yuan, K.-H. (2018). *Practical Statistical Power Analysis Using Webpower and R*. ISDSA Press. <https://doi.org/10.35566/power>